

Temas Selectos de Ingeniería Petrolera

28 de agosto de 2026

Moisés Velasco Lozano

PhD

PROFESOR

Universidad Nacional Autónoma de México

GUEST SCIENTIST

Los Alamos National Laboratory

Índice

1	Introducción	3
1.1	Estatus actual y comparación de las reservas de aceite en el mundo y México	5
1.1.1	Panorama mundial	5
1.1.2	Relevancia actual del petróleo	6
1.1.3	Situación de México	6
1.2	El papel de la tecnología	7
1.3	Temas Selectos de Geociencias	8
1.4	Referencias	10
2	Herramientas computacionales para el desarrollo científico	13
2.1	Python Orientado a Ciencia de Datos	13
2.1.1	Python	13
2.1.2	Manipulación y tratamiento de datos con NumPy y Pandas	15
2.1.3	Técnicas de visualización de datos usando Matplotlib y Seaborn	16
2.2	Gestión de Datos y Programación Colaborativa	17
2.2.1	Creación y administración de repositorios	18
2.2.2	Desarrollo de proyectos en entornos colaborativos	19
3	Análisis de Datos	22
3.1	Generalidades: datasets, variables, características (features) y etiquetas (labels)	22
3.1.1	Ciencia de Datos y Machine Learning	22
3.2	Estadística descriptiva	23
3.2.1	Medidas de Tendencia Central	23
3.2.2	Medidas de Dispersión	24
3.2.3	Medidas de Posición	25
3.3	Variables	26
3.4	Procesamiento de los datos	27
3.4.1	Muestreo de los datos	28
3.4.2	Técnicas para resolver el muestreo sesgado	30
3.5		37

1 Introducción

La asignatura *Temas Selectos de Ingeniería Petrolera* tiene como objetivo proporcionar a los estudiantes una visión actualizada de las tendencias científicas, tecnológicas y de investigación que están redefiniendo el ejercicio profesional de la ingeniería petrolera. El curso se enfoca en el estudio de temas emergentes con alto impacto en la industria energética, promoviendo el análisis crítico de nuevas metodologías, el conocimiento de tecnologías de vanguardia y la comprensión de los desafíos técnicos, económicos y ambientales que enfrenta el sector en el contexto de la transición energética global.

Uno de los ejes principales del curso será el estudio de las aplicaciones del Machine Learning, la inteligencia artificial y la ciencia de datos en la ingeniería de yacimientos. Se analizarán técnicas modernas para el procesamiento e interpretación de grandes conjuntos de datos, el desarrollo de modelos predictivos, la caracterización de propiedades petrofísicas, la estimación de parámetros de yacimientos, la optimización de la producción, el análisis de incertidumbre y el apoyo a la toma de decisiones mediante herramientas de aprendizaje supervisado, no supervisado y aprendizaje profundo. Asimismo, se discutirán las ventajas, limitaciones y oportunidades que estas tecnologías representan para la industria petrolera, así como los retos asociados con la calidad de los datos, la interpretabilidad de los modelos y su integración con los métodos convencionales de la ingeniería.



Figura 1: Tendencias tecnológicas en la ingeniería petrolera

Uno de los temas relevantes será la recuperación de hidrocarburos, considerando las tecnologías emergentes. Se discutirán procesos de flujo en yacimientos como lo es la inyección de agua, recuperación de petróleo con químicos, y modelado de trazadores como herramienta de caracterización. El análisis de estas temáticas se abordará de forma teórica-práctica con base en los conocimientos adquiridos durante las diversas clases cursadas del programa de estudios como lo son:

- Propiedades de los fluidos petroleros
- Caracterización dinámica de yacimientos
- Simulación matemática
- Recuperación mejorada

Atendiendo las necesidades actuales, el curso está diseñado para el desarrollo de metodologías de solución basadas en la aplicación del análisis de datos y machine learning en geociencias, las cuales son temáticas emergentes en formación profesional de ingenieras e ingenieros petroleros.

En respuesta a los nuevos desafíos energéticos y ambientales, la asignatura también incorpora temas relacionados con la descarbonización y el aprovechamiento integral del subsuelo. Se estudiarán los fundamentos y aplicaciones de la captura, utilización y almacenamiento geológico de carbono (CCUS), incluyendo los mecanismos de almacenamiento, la selección de sitios, el monitoreo de la integridad de los yacimientos y la evaluación de riesgos asociados. Estos conocimientos representan una de las áreas de mayor crecimiento dentro de la ingeniería del subsuelo debido a su potencial para reducir las emisiones de gases de efecto invernadero y contribuir al cumplimiento de los objetivos internacionales de mitigación del cambio climático.

Asimismo, se analizarán las aplicaciones de la ingeniería petrolera en el desarrollo de recursos geotérmicos, considerando las similitudes existentes entre los sistemas geotérmicos y los yacimientos de hidrocarburos en aspectos relacionados con la caracterización del subsuelo, la perforación de pozos, la simulación de reservorios y el manejo de fluidos. Se revisarán las oportunidades que representa la geotermia como fuente de energía renovable, así como el papel que los ingenieros petroleros pueden desempeñar en el diseño, operación y optimización de estos proyectos.




Figura 2: Temáticas con aplicación de ciencia de datos en geociencias

Finalmente, si el tiempo lo permite, el curso abordará el creciente interés por la exploración y aprovechamiento de minerales críticos y estratégicos, indispensables para la fabricación de baterías, sistemas de almacenamiento de energía, vehículos eléctricos, tecnologías digitales e infraestructura para energías renovables. Se analizarán los fundamentos geológicos de estos recursos, las metodologías modernas de exploración, el uso de herramientas geofísicas y geoquímicas, así como las aplicaciones del aprendizaje automático y la inteligencia artificial para la identificación de zonas prospectivas y la evaluación de recursos minerales. Este tema permitirá comprender la creciente convergencia entre la ingeniería petrolera, la geociencia y la minería dentro del contexto de la transición energética.

El desarrollo de la asignatura combinará la revisión de literatura científica reciente, el análisis de artículos especializados, estudios de caso provenientes de la industria, conferencias sobre tecnologías emergentes y la discusión de aplicaciones prácticas apoyadas en herramientas computacionales. Se fomentará el pensamiento crítico, la capacidad de evaluar nuevas tecnologías y el desarrollo de criterios técnicos para seleccionar metodologías apropiadas según el problema de ingeniería planteado.

1.1 Estatus actual y comparación de las reservas de aceite en el mundo y México

Las reservas de aceite constituyen uno de los principales indicadores para evaluar la disponibilidad futura de hidrocarburos y la capacidad de un país para sostener su producción petrolera. Sin embargo, es importante distinguir entre recursos y reservas. La existencia de hidrocarburos en el subsuelo no implica necesariamente que estos puedan clasificarse como reservas. En términos generales, las reservas probadas corresponden a los volúmenes que, con base en información geológica y de ingeniería, pueden recuperarse con un grado razonable de certidumbre bajo las condiciones económicas y operativas existentes (U.S. Energy Information Administration [EIA]).

Por esta razón, las reservas no representan un volumen estático. Pueden incrementarse como resultado de nuevos descubrimientos, delimitación de campos, incorporación de nuevas áreas productivas, mejor caracterización del yacimiento, aplicación de tecnologías de recuperación mejorada o cambios favorables en las condiciones económicas. De manera similar, pueden disminuir debido a la producción acumulada, revisiones de los modelos geológicos y dinámicos, modificaciones en los costos de desarrollo o cambios en las expectativas de recuperación. En consecuencia, el concepto de reserva integra aspectos geológicos, tecnológicos y económicos (EIA, 2014).

1.1.1 Panorama mundial

A escala global, el petróleo continúa representando un recurso energético de gran importancia. De acuerdo con la Annual Statistical Bulletin 2025 de la Organization of the Petroleum Exporting Countries (OPEC), las reservas probadas mundiales de petróleo crudo alcanzaron aproximadamente 1.567 billones de barriles al cierre de 2024. De este volumen, aproximadamente 1.241 billones de barriles correspondieron a los países miembros de OPEC, lo que revela la elevada concentración geográfica de las reservas petroleras mundiales (OPEC, 2025).

La distribución de las reservas, sin embargo, no coincide necesariamente con la distribución de la producción. Un país puede poseer grandes reservas y mantener una producción relativamente moderada, mientras que otro con una base de reservas menor puede alcanzar tasas de producción considerablemente mayores mediante inversión, infraestructura y tecnologías avanzadas. En 2024, por ejemplo, Estados Unidos fue el mayor productor mundial de petróleo y aportó aproximadamente una quinta parte de la producción global, a pesar de que otros países poseen reservas probadas considerablemente mayores (Energy Institute, 2025).




Figura 3: Panorama Mundial de las reservas de aceite

1.1.2 Relevancia actual del petróleo

A pesar de la transformación del sistema energético mundial, el petróleo continúa ocupando una posición central. El Energy Institute reportó que en 2024 el petróleo representó aproximadamente 34 % de la demanda energética mundial y que la demanda global superó por primera vez los 101 millones de barriles diarios (Energy Institute, 2025).

Al mismo tiempo, existen señales de transformación estructural. La International Energy Agency señaló que el crecimiento de la demanda mundial de petróleo se desaceleró durante 2024, influenciado, entre otros factores, por cambios en movilidad, actividad económica y creciente penetración de vehículos eléctricos (International Energy Agency [IEA], 2025).

Por lo tanto, el escenario actual presenta una aparente dualidad: el petróleo continúa siendo fundamental para satisfacer la demanda energética mundial, pero su producción y aprovechamiento ocurren dentro de un sistema energético que está experimentando importantes transformaciones tecnológicas y ambientales.

1.1.3 Situación de México

México cuenta con una extensa historia de exploración y producción de hidrocarburos y mantiene una base significativa de reservas. Para su evaluación se emplean las categorías 1P, 2P y 3P, utilizadas para representar diferentes niveles de certidumbre en los volúmenes recuperables. La Comisión Nacional de Hidrocarburos ha establecido procedimientos para la cuantificación anual, certificación, clasificación y consolidación de estas reservas (Comisión Nacional de Hidrocarburos [CNH], 2024).

En términos generales:

1P = Reservas probadas

2P = Reservas probadas + probables

3P = Reservas probadas + probables + posibles

La diferencia entre estas categorías es importante porque permite incorporar explícitamente la incertidumbre asociada con la caracterización y recuperación futura de los hidrocarburos.




Figura 4: Situación en México

De acuerdo con el Programa Sectorial de Energía 2025–2030, México reportó en 2024 aproximadamente 8,383 millones de barriles de petróleo crudo equivalente (MMbpce) de reservas 1P, 15,530 MMbpce de reservas 2P y 23,146 MMbpce de reservas 3P. Como referencia, en 2018 estos valores eran 8,484, 16,162 y 25,467 MMbpce, respectivamente. Esto representa disminuciones aproximadas de 1 % para 1P, 4 % para 2P y 9 % para 3P durante dicho periodo (Secretaría de Energía [SENER], 2025).

Es importante señalar que estas cifras corresponden a petróleo crudo equivalente, por lo que no deben compararse directamente con estadísticas internacionales que reportan exclusivamente reservas probadas de petróleo crudo. Esta diferencia metodológica constituye, de hecho, un buen ejemplo de por qué cualquier comparación internacional de reservas debe revisar cuidadosamente las definiciones, unidades y criterios utilizados por cada fuente.

1.2 El papel de la tecnología

Para México, uno de los retos centrales no consiste únicamente en descubrir nuevos campos, sino también en incrementar la recuperación de hidrocarburos de los yacimientos existentes.

En particular, la innovación tecnológica resulta fundamental en cuatro áreas: la caracterización de yacimientos, mediante la integración de información geológica, geofísica, petrofísica y dinámica; el modelado de procesos, para representar fenómenos complejos de flujo y transporte de fluidos en medios porosos; la predicción del comportamiento de los yacimientos, utilizando datos históricos y resultados de simulación; y la optimización de la producción, para identificar estrategias operativas que permitan incrementar la recuperación y utilizar de manera más eficiente los recursos disponibles.

Dentro de este contexto, Machine Learning (ML) representa una alternativa y, principalmente, una herramienta complementaria a los métodos tradicionales de ingeniería. Su capacidad para analizar grandes volúmenes de información, identificar relaciones complejas entre variables y construir modelos predictivos permite desarrollar nuevas

estrategias para problemas en los que las simulaciones convencionales pueden resultar computacionalmente costosas o donde existen grandes cantidades de datos históricos.

La industria energética se encuentra en un proceso de transformación sin precedentes, impulsado por la convergencia de avances tecnológicos, la digitalización, la transición hacia sistemas energéticos más sostenibles y la creciente necesidad de optimizar el aprovechamiento de los recursos naturales. En este escenario, la ingeniería petrolera ha evolucionado más allá de las actividades tradicionales de exploración y producción de hidrocarburos, incorporando nuevas disciplinas, metodologías y herramientas computacionales que permiten enfrentar problemas de alta complejidad con mayor precisión, rapidez y eficiencia. La disponibilidad de grandes volúmenes de datos, el desarrollo de algoritmos de inteligencia artificial y el incremento en la capacidad de cómputo han abierto nuevas oportunidades para transformar la manera en que se caracterizan los yacimientos, se diseñan estrategias de explotación y se gestionan los recursos del subsuelo.



Figura 5: Transformación de la industria energética

1.3 Temas Selectos de Geociencias

La transformación del sector energético está ampliando significativamente el campo de acción de la ingeniería petrolera. Los conocimientos tradicionales relacionados con geología, petrofísica, perforación, producción, flujo de fluidos y caracterización de yacimientos constituyen una base sólida que puede aplicarse a problemas que van más allá de la explotación convencional de hidrocarburos. En este contexto, resulta cada vez más importante que los ingenieros petroleros diversifiquen su formación e incorporen conocimientos provenientes de otras áreas de las geociencias, la energía y las ciencias computacionales.

Esta diversificación no implica abandonar las competencias tradicionales de la profesión, sino ampliarlas y adaptarlas a nuevos problemas tecnológicos y energéticos. Muchas de las herramientas utilizadas para caracterizar y modelar yacimientos de petróleo y gas son directamente transferibles al estudio de otros sistemas del subsuelo,

donde también es necesario comprender la geología, caracterizar propiedades de la roca, modelar el flujo de fluidos, cuantificar incertidumbre y optimizar operaciones.

Entre las áreas con creciente relevancia para la formación del ingeniero petrolero se encuentran:

1. Ciencia de datos y Machine Learning: permiten analizar grandes volúmenes de información geológica, petrofísica y operacional, desarrollar modelos predictivos, identificar patrones y complementar las herramientas tradicionales de simulación y optimización.
2. Energía geotérmica: aprovecha conocimientos de perforación, caracterización de formaciones, flujo en medios porosos, transferencia de calor, producción de fluidos y modelado de yacimientos para evaluar y desarrollar recursos térmicos del subsuelo.
3. Captura y Almacenamiento de Carbono (CCS): requiere caracterizar formaciones geológicas, simular la inyección y migración del CO_2 , evaluar mecanismos de entrapamiento, analizar riesgos de fuga y diseñar estrategias de monitoreo para garantizar un almacenamiento seguro a largo plazo.
4. Almacenamiento subterráneo de energía: incluye problemas relacionados con el almacenamiento geológico de gases como hidrógeno y gas natural, donde la interacción roca-fluido, la integridad de los pozos y el comportamiento dinámico de las formaciones son aspectos fundamentales.
5. Exploración y caracterización de recursos minerales: integra información geológica, geoquímica, geofísica, geoespacial y de sensores remotos para identificar zonas prospectivas y caracterizar recursos, incluyendo minerales críticos necesarios para nuevas tecnologías.



Figura 6: Tendencias en geociencias

De esta manera, el perfil contemporáneo del ingeniero petrolero puede evolucionar hacia el de un especialista en sistemas energéticos y recursos del subsuelo, capaz de aplicar principios de ingeniería, geociencias, modelado numérico y análisis de datos a una variedad creciente de problemas.

1.4 Referencias

- Comisión Nacional de Hidrocarburos. (2024, 11 de junio). Cuantificación y certificación de reservas. Gobierno de México. CNH – Cuantificación y certificación de reservas
- Energy Institute. (2025). Statistical review of world energy 2025 (74th ed.). Energy Institute. Statistical Review of World Energy
- Ersoy, E., & Schaffer, M. E. (2025). Statistical review of world energy 2025 (74th ed.). Energy Institute.
- International Energy Agency. (2025). Global energy review 2025. IEA. Global Energy Review 2025
- Organization of the Petroleum Exporting Countries. (2025). Annual statistical bulletin 2025. OPEC. OPEC Annual Statistical Bulletin 2025
- Secretaría de Energía. (2025). Programa Sectorial de Energía 2025–2030. Gobierno de México. Programa Sectorial de Energía 2025–2030

- U.S. Energy Information Administration. (2014, September 2). Oil and natural gas resource categories reflect varying degrees of certainty. U.S. Energy Information Administration
- U.S. Energy Information Administration. (n.d.). Glossary: Proved energy reserves. EIA – Proved reserves definition

2 Herramientas computacionales para el desarrollo científico

COMPUTATIONAL TOOLS FOR SCIENTIFIC DEVELOPMENT

From Data to Insights • From Code to Collaboration

1. TOOLS FOR SCIENTIFIC COMPUTING

Powerful tools for data analysis, visualization, and modeling

Key Libraries

- NumPy**: Numerical computing
- pandas**: Data manipulation and analysis
- Matplotlib**: Data visualization and plotting
- SciPy**: Scientific computing
- tealens**: Machine learning and statistics
- xarray**: Multi-dimensional array analysis

Applications in Geosciences

- Data Analysis**: Explore and clean geoscience data
- Visualization**: Create 2D/3D plots and maps
- Geospatial Analysis**: Work with spatial data and GIS formats
- Modeling & Simulation**: Build and analyze geoscience models
- Machine Learning**: Apply ML to predict and classify geoscience data

Example: 3D Visualization of Geological Data

```
import numpy as np
import xarray as xr
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D

# Load data
data = xr.open_dataset('seismic.nc')
x, y, z = data.x, data.y, data.depth, data.amplitude

# 3D Visualization
fig = plt.figure(figsize=(8,8))
ax = fig.add_subplot(111, projection='3d')
ax.plot_surface(x, y, z, cmap='seismic', rstride=5, cstride=5)
ax.set_xlabel('X (km)')
ax.set_ylabel('Y (km)')
ax.set_zlabel('Depth (m)')
plt.title('Seismic Amplitude (Depth Slice)')
plt.tight_layout()
plt.show()
```

Seismic Amplitude (Depth Slice)

2. DATA MANAGEMENT & COLLABORATIVE DEVELOPMENT WITH GITHUB

Organize data, track changes, and work together efficiently

Why GitHub?

- Centralize and organize your data and code
- Track changes with version control
- Collaborate with others seamlessly
- Backend, secure and reproducible workflows
- Enable reproducible research

Collaborative Workflow

- Clone Repository**: Get a local copy of the project
- Create Branch**: Work on a new feature or fix
- Make Changes**: Edit code and analyze data
- Commit Changes**: Save your changes with a message
- Push to GitHub**: Upload your branch to the remote repo
- Open Pull Request**: Propose your changes for review
- Review & Merge**: Discuss, review and merge into main

Example Repository Structure

```
geoscience-project/
├── data/
│   ├── raw/
│   └── processed/
├── notebooks/
│   └── 01_exploratory_analysis.ipynb
├── scripts/
│   ├── data_cleaning.py
│   └── modeling.py
├── results/
│   └── figures/
├── README.md
└── environment.yml
```

Example: Working with Git

```
$ git clone https://github.com/user/geoscience-project.git
$ cd geoscience-project
$ git checkout -b feature/data-analysis
# make changes...
$ git add .
$ git commit -m "Add data analysis notebook"
$ git push origin feature/data-analysis
# open Pull Request on GitHub
# after review and approval
# your changes are merged!
```

Better Analysis
Better Decisions

Reproducible
Research

Stronger Collaboration
Greater Impact

Open Science
Open Future

2 Herramientas computacionales para el desarrollo científico

El desarrollo científico en geociencias depende cada vez más del uso de herramientas computacionales capaces de facilitar el procesamiento, análisis, visualización y modelado de grandes volúmenes de información. En áreas como la ingeniería petrolera, los datos pueden provenir de fuentes muy diversas, incluyendo registros de pozos, análisis petrofísicos, información sísmica, modelos geológicos, simulaciones numéricas, datos experimentales y mediciones de producción. La correcta integración y análisis de esta información constituye una parte fundamental del proceso de investigación y de la toma de decisiones.

Dentro del ecosistema de programación científica, Python se ha consolidado como uno de los lenguajes más utilizados debido a su sintaxis accesible, flexibilidad y amplio conjunto de librerías especializadas. Adicionalmente los sistemas de control de versiones como Git, junto con plataformas como GitHub, proporcionan un entorno para organizar y documentar el desarrollo de proyectos computacionales. Su utilización permite mantener un historial de modificaciones, recuperar versiones anteriores, desarrollar nuevas funcionalidades de manera independiente e integrar posteriormente las contribuciones realizadas por diferentes participantes.

2.1 Python Orientado a Ciencia de Datos

Objetivo específico: Comprender los fundamentos de Python y su importancia como lenguaje líder para el desarrollo de aplicaciones de Ciencia de Datos e Inteligencia Artificial.

2.1.1 Python

Python es un lenguaje de programación interpretado, de alto nivel, multiparadigma y de código abierto. Su sintaxis sencilla y su amplio ecosistema de bibliotecas lo han convertido en el lenguaje predominante para el análisis de datos, la inteligencia artificial y el aprendizaje automático. Entre sus principales ventajas destacan:

- Sintaxis clara y legible.
- Gran comunidad de desarrolladores.
- Amplio conjunto de bibliotecas científicas.
- Compatibilidad con múltiples sistemas operativos.
- Integración con herramientas de Big Data y computación en la nube.

Una de las principales ventajas de Python para el desarrollo científico es su amplio ecosistema de bibliotecas especializadas (**Figura 7**), las cuales permiten implementar tareas complejas sin necesidad de desarrollar todas las herramientas desde cero. Bibliotecas como NumPy facilitan el cálculo numérico y manejo de arreglos multidimensionales; pandas permite organizar, procesar y analizar conjuntos de datos; Matplotlib proporciona herramientas para su visualización; y SciPy incorpora métodos para optimización, integración, interpolación y análisis estadístico. Adicionalmente, bibliotecas como scikit-learn, TensorFlow y PyTorch permiten implementar algoritmos de Machine Learning y Deep Learning.




Figura 7: Librerías en Python para el análisis de datos y desarrollo de modelos de machine learning

Estas herramientas permiten cubrir todo el ciclo de vida de un proyecto de Machine Learning (**Figura 8**):

1. Obtención de datos.
2. Limpieza y preparación.
3. Exploración.
4. Entrenamiento del modelo.
5. Evaluación.
6. Implementación.




Figura 8: Etapas de desarrollo de un proyecto de machine learning

2.1.2 Manipulación y tratamiento de datos con NumPy y Pandas

Objetivo específico. Aplicar técnicas de manipulación de datos utilizando las bibliotecas NumPy y Pandas (**Figura**) para preparar conjuntos de datos destinados al entrenamiento de modelos de Machine Learning.

En cualquier proyecto de Ciencia de Datos, aproximadamente entre el 70% y el 80% del tiempo se dedica a la preparación de los datos. Las bibliotecas/librerías más utilizadas son:

1. NumPy

NumPy es una biblioteca fundamental de Python para el cálculo numérico y científico. Permite trabajar eficientemente con arreglos multidimensionales y realizar operaciones matemáticas, estadísticas, matriciales y algebraicas, siendo la base de muchas otras bibliotecas utilizadas en ciencia de datos, machine learning e ingeniería.

2. Pandas

Pandas es una biblioteca de Python diseñada para la manipulación, organización y análisis de datos. Utiliza estructuras como DataFrame y Series, que permiten importar, limpiar, filtrar, transformar y combinar grandes conjuntos de información de manera eficiente.




Figura 9: Librerías NumPy y Pandas

2.1.3 Técnicas de visualización de datos usando Matplotlib y Seaborn

Objetivo específico. Revisar las librerías Matplotlib y Seaborn, las cuales permiten representar gráficamente la información, facilitar la exploración de datos y apoyar en la toma de decisiones durante el desarrollo de análisis de datos.

La visualización permite:

1. Detectar valores atípicos.
2. Identificar correlaciones.
3. Comprender distribuciones.
4. Descubrir patrones ocultos.
5. Comunicar resultados.

Existen diversas librerías especializadas para la visualización de datos y resultados, entre las cuales se tienen:

1. Matplotlib

Matplotlib es una biblioteca de Python utilizada para la visualización de datos mediante la creación de gráficos y figuras. Permite representar información de forma clara a través de gráficas de líneas, dispersión, barras, histogramas, mapas de calor y otros tipos de visualizaciones. Es ampliamente utilizada en ciencia, ingeniería y geociencias para explorar datos, identificar tendencias y comunicar resultados.

2. Seaborn

Seaborn es una biblioteca de Python especializada en la visualización estadística de datos. Está construida sobre Matplotlib y facilita la creación de gráficos atractivos y útiles para explorar distribuciones, relaciones entre variables, correlaciones y patrones presentes en los datos.

Estas librerías (**Figura 10**) tienen funcionalidades que permiten explicar de manera eficiente el comportamiento de los datos, tendencias, y modelos dinámicos.




Figura 10: Librerías Matplotlib y Seaborn

2.2 Gestión de Datos y Programación Colaborativa

Objetivo específico. Comprender los fundamentos y utilización de GitHub para administrar el ciclo de vida de proyectos de ciencia de datos aplicados a geociencias.

La utilización de repositorios de información es fundamental en el desarrollo de modelos basados en datos. Adicionalmente, el control de versiones y uso de plataformas colaborativas permiten gestionar proyectos aplicando buenas prácticas en el desarrollo de software, la administración de base de datos y la colaboración en equipos multidisciplinares de investigación.

Los proyectos de machine learning suelen involucrar múltiples archivos, modelos, bases de datos, experimentos y colaboradores. Sin una adecuada gestión del código fuente, resulta difícil controlar cambios, reproducir experimentos o trabajar en equipo.

El control de versiones permite registrar la evolución de un proyecto, recuperar versiones anteriores y coordinar el trabajo entre varios desarrolladores sin sobrescribir cambios. En este contexto, Git es el sistema de control de versiones distribuido más utilizado en el mundo, mientras que GitHub constituye una plataforma basada en la nube que facilita el almacenamiento, la colaboración y la gestión integral de proyectos de software.

GitHub (Figura 11) es una plataforma de alojamiento de repositorios Git que incorpora herramientas para la colaboración, documentación, automatización e integración continua. Entre sus funcionalidades destacan:

- Repositorios públicos y privados.
- Gestión de proyectos




Figura 11: Funcionalidades de la herramienta GitHub

GitHub se ha convertido en un estándar para proyectos de software, investigación científica y desarrollo de inteligencia artificial.

2.2.1 Creación y administración de repositorios

Objetivo específico. Diseñar y administrar repositorios que faciliten la organización, documentación, reproducibilidad y difusión de proyectos de investigación en Ciencia de Datos y Machine Learning.

La reproducibilidad es uno de los pilares de la investigación científica. Un repositorio bien organizado permite que otros investigadores comprendan, ejecuten y validen los resultados obtenidos. GitHub se ha consolidado como una plataforma para compartir código, datos y documentación, promoviendo la ciencia abierta y el trabajo colaborativo. La (Figura) ilustra la principales funcionalidades de GitHub como herramienta de almacenamiento de información.




Figura 12: GitHub como repositorio de información

2.2.2 Desarrollo de proyectos en entornos colaborativos

Objetivo específico. Aplicar metodologías y herramientas colaborativas para desarrollar proyectos de manera organizada, eficiente y reproducible.

Los proyectos actuales de Machine Learning rara vez son desarrollados por una sola persona. Generalmente participan:

Científicos de datos	Ingenieros de software	Especialistas del dominio	Analistas de negocio	Administradores de bases de datos
----------------------	------------------------	---------------------------	----------------------	-----------------------------------

El desarrollo colaborativo consiste en que múltiples desarrolladores trabajan simultáneamente sobre un mismo proyecto sin generar conflictos importantes. Principios fundamentales:

Comunicación	Desarrollo de versiones	Documentación	Automatización	Revisión entre pares
--------------	-------------------------	---------------	----------------	----------------------

La (Figura) muestra algunas de las funcionalidades de GitHub para el desarrollo de proyectos colaborativos.





Figura 13: GitHub para desarrollo colaborativo

Flujo de trabajo colaborativo. Un flujo típico comprende (Figura):



Figura 14: Flujo de trabajo colaborativo

3 Análisis de Datos



3 Análisis de Datos

Objetivo general. Al finalizar esta unidad, el estudiante comprenderá los fundamentos de la Ciencia de Datos y del Machine Learning, identificando los elementos que conforman un conjunto de datos, aplicando técnicas de análisis exploratorio, comprendiendo el flujo metodológico para el desarrollo de proyectos predictivos y evaluando modelos mediante métricas apropiadas para problemas de aprendizaje supervisado y no supervisado.

3.1 Generalidades: datasets, variables, características (features) y etiquetas (labels)

Objetivo específico. Comprender la estructura de los conjuntos de datos utilizados en Machine Learning, diferenciando sus componentes fundamentales y su importancia dentro del proceso de construcción de modelos predictivos.

La materia prima de cualquier sistema de Inteligencia Artificial son los datos. La calidad, cantidad y representatividad de estos determinan, en gran medida, el desempeño de los algoritmos de aprendizaje automático.

Antes de entrenar un modelo, es indispensable comprender cómo están organizados los datos, qué representan sus variables y cuál es el objetivo del aprendizaje.

3.1.1 Ciencia de Datos y Machine Learning

La Ciencia de Datos es una disciplina interdisciplinaria que combina estadística, informática, matemáticas y conocimiento del dominio para extraer información útil a partir de grandes volúmenes de datos.

Por su parte, el Machine Learning constituye una rama de la Inteligencia Artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos y realizar predicciones o tomar decisiones sin haber sido programados explícitamente para cada situación.

En términos generales, la Ciencia de Datos abarca todo el proceso de obtención, preparación, análisis e interpretación de datos, mientras que el Machine Learning se enfoca en la construcción de modelos predictivos.


Dataset. Un dataset o conjunto de datos es una colección organizada de observaciones utilizadas para entrenar, validar y evaluar modelos de aprendizaje automático. Cada dataset está compuesto por:

- Filas (observaciones o registros).
- Columnas (variables o atributos).
- Valores.

Tipos de datos

Los datos representan características observables de los objetos de estudio.

TIPOS DE DATOS



3.2 Estadística descriptiva

3.2.1 Medidas de Tendencia Central

Las medidas de tendencia central buscan identificar un valor representativo o central alrededor del cual se distribuyen las observaciones.

- **Media:** Es el promedio aritmético de todos los valores. Se obtiene sumando las observaciones y dividiendo entre el número total de datos. Es muy útil para resumir una variable, pero puede verse fuertemente afectada por valores atípicos.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Mediana:** Es el valor que se encuentra en el centro después de ordenar los datos de menor a mayor. El 50 % de las observaciones queda por debajo y el otro 50 % por encima. Es especialmente útil cuando existen outliers o distribuciones asimétricas, ya que es menos sensible a valores extremos.
- **Moda:** Es el valor que aparece con mayor frecuencia en el conjunto de datos. Puede existir una moda, varias modas o ninguna claramente definida. Es particularmente útil para analizar variables categóricas o discretas.

1. TENDENCIA CENTRAL
Indica el valor típico o representativo de los datos.

$\bar{x}$ MEDIA ($\bar{x}$)

Promedio aritmético de todos los valores.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Ejemplo:
2, 4, 4, 6, 8

$$\bar{x} = \frac{2 + 4 + 4 + 6 + 8}{5} = 4.8$$

Media ($\bar{x} = 4.8$)

Me MEDIANA (Me)

Valor central cuando los datos están ordenados.

Ejemplo:
2, 4, 4, 6, 8 → Me = 4

Mediana (valor central)

Mo MODA (Mo)

Valor que más se repite.

Ejemplo:
2, 4, 4, 6, 8 → Mo = 4

Moda (más frecuente)

IDEA CLAVE

Media, mediana y moda son medidas de tendencia central que nos ayudan a identificar el valor típico de un conjunto de datos desde diferentes perspectivas.

- Media: sensible a valores extremos.
- Mediana: menos sensible a valores extremos.
- Moda: útil para datos categóricos o con repeticiones.

3.2.2 Medidas de Dispersión

Mientras que la tendencia central indica dónde se concentran los datos, las medidas de dispersión describen qué tan separados o variables son los valores.

- **Varianza:** Cuantifica la dispersión de los datos respecto a la media mediante el promedio de las desviaciones al cuadrado. Una varianza pequeña indica datos relativamente homogéneos; una varianza grande indica mayor variabilidad.

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

Una desventaja es que sus unidades están elevadas al cuadrado. Por ejemplo, si la permeabilidad está expresada en mD, su varianza estará expresada en mD²

- **Desviación estándar:** Es la raíz cuadrada de la varianza y representa una medida de la distancia típica de las observaciones respecto a la media.

$$\sigma$$

Su principal ventaja es que conserva las mismas unidades de la variable original, haciendo más sencilla su interpretación.

- **Rango:** Es la diferencia entre el valor máximo y el valor mínimo del conjunto de datos.

$$R = x_{max} - x_{min}$$

Permite obtener una primera idea de la amplitud de los datos, aunque es muy sensible a valores extremos porque depende únicamente del mínimo y máximo.

2. DISPERSIÓN

Mide cuánto se alejan los datos del valor central.

VARIANZA (s^2)

Promedio de los cuadrados de las desviaciones respecto a la media.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Ejemplo (2, 4, 4, 6, 8)

$s^2 = 5.2$

$\bar{x} = 4.8$

La varianza se expresa en las mismas unidades al cuadrado.

DESVIACIÓN ESTÁNDAR (s)

Raíz cuadrada de la varianza.
En las mismas unidades que los datos.

$$s = \sqrt{s^2}$$

Ejemplo (2, 4, 4, 6, 8)

$s = \sqrt{5.2} = 2.28$

Indica la desviación típica: cuánto se alejan, en promedio, los datos de la media.

RANGO (R)

Diferencia entre el valor máximo y el mínimo.

$$R = \text{Max} - \text{Min}$$

Ejemplo (2, 4, 4, 6, 8)

$R = 8 - 2 = 6$

Mín = 2 **Máx = 8**

Mide la amplitud total del conjunto de datos.

EN RESUMEN

- La **varianza (s^2)** cuantifica la variabilidad total al cuadrado.
- La **desviación estándar (s)** expresa la dispersión promedio en las mismas unidades.
- El **rango (R)** indica la distancia entre el valor máximo y el mínimo.

3.2.3 Medidas de Posición

Las medidas de posición permiten determinar dónde se encuentra una observación con respecto al resto de los datos una vez que estos han sido ordenados.

- Cuartiles:** Dividen los datos ordenados en cuatro partes. El primer cuartil (Q1) deja aproximadamente el 25 % de los datos por debajo; Q2 corresponde al 50 % y coincide con la mediana; y Q3 representa el 75 %. Los cuartiles son fundamentales para construir el boxplot y analizar la distribución y posibles valores atípicos.
- Percentiles:** Dividen los datos ordenados en 100 partes. Por ejemplo, el percentil 90 (P90) representa el valor por debajo del cual se encuentra aproximadamente el 90 % de las observaciones. Son muy útiles para comparar observaciones y establecer valores de referencia dentro de una distribución.



3. POSICIÓN


Indica la ubicación relativa de los datos dentro del conjunto.

CUARTILES

Dividen los datos ordenados en 4 partes iguales.

Ejemplo:

1, 3, 7, 9, 12, 15, 17




- **Q1 (25%):** 25% de los datos están por debajo de este valor.
- **Q2 (Mediana, 50%):** 50% de los datos están por debajo de este valor.
- **Q3 (75%):** 75% de los datos están por debajo de este valor.

PERCENTILES

Dividen los datos en 100 partes iguales.

Ejemplo:

- **P₉₀:** el valor por debajo del cual se encuentra el 90% de los datos.
- **P₁₀:** el valor por debajo del cual se encuentra el 10% de los datos.




IDEA CLAVE

Las medidas de posición permiten saber dónde se encuentran los datos dentro del conjunto, lo que facilita su interpretación y comparación.

3.3 Variables

Características (Features): Se representan normalmente mediante la matriz X . Generalmente se denominan como las **variables independientes** (X), las cuales contienen la información de entrada utilizada para realizar una predicción

Etiquetas (Labels): Se representan mediante la variable y (Y si es un matriz de etiquetas). Generalmente se denomina como la **variable dependiente** (y) ya que representa el resultado esperado.



3.4 Procesamiento de los datos

El procesamiento de los datos constituye una de las etapas más importantes dentro de cualquier proyecto de Machine Learning. Aunque con frecuencia se presta mayor atención al desarrollo de modelos y algoritmos, la calidad de las predicciones depende en gran medida de la calidad de la información utilizada durante el entrenamiento. En la práctica, se estima que aproximadamente el 80 % del tiempo y esfuerzo de un proyecto de aprendizaje automático se dedica a la preparación, limpieza, transformación y organización de los datos.

En esta etapa se realizan actividades como la identificación y tratamiento de valores faltantes, la detección de datos atípicos, la corrección de inconsistencias, la integración de múltiples fuentes de información y la transformación de variables para que puedan ser utilizadas de manera eficiente por los algoritmos de Machine Learning. Asimismo, es común aplicar técnicas de normalización, estandarización, codificación de variables categóricas y generación de nuevas características que permitan representar mejor el fenómeno bajo estudio.

En el ámbito de las geociencias, el procesamiento de los datos adquiere una relevancia aún mayor debido a la naturaleza heterogénea de la información disponible. Es frecuente trabajar simultáneamente con registros de pozos, datos sísmicos, propiedades petrofísicas, información geoespacial, imágenes satelitales y resultados de simulación numérica, los cuales presentan diferentes formatos, escalas espaciales y temporales, unidades de medición y niveles de incertidumbre. Un procesamiento adecuado permite integrar todas estas fuentes de información en un conjunto de datos consistente y confiable.



3.4.1 Muestreo de los datos

La información recopilada tiene como objetivo modelar el comportamiento de un fenómeno para poder predecir su comportamiento en base a los datos observados en el sistema de interés. Sin embargo, una de las dificultades más importantes es el determinar la calidad y representatividad de las observaciones obtenidas. En el caso de ingeniería petrolera, los datos recolectados corresponden generalmente a las zonas del yacimiento con las mejores características, es decir, los datos generados corresponden a las formaciones con mejor porosidad, permeabilidad, y espesor. Esta situación, aunque sustentada técnica y económicamente, resulta en un sesgo (bias) en los datos utilizados en modelos de machine learning ya que no se tienen datos que cubran en su totalidad las propiedades del yacimiento.


En general, se tienen dos métodos para el muestreo de los datos:

1. Muestreo aleatorio.
 - (a) cada objeto en la población tiene la misma probabilidad de ser elegido
 - (b) la elección de cada objeto es independiente de otra elección
 - (c) la población de las posibles muestras es mayor en comparación al tamaño del muestreo
2. Muestreo regular
 - (a) las muestras son tomadas en intervalos regulares (igualmente espaciadas)
 - (b) menos confiable que el muestreo aleatorio

En general, se tienen dos métodos para el muestreo de los datos:

1. Muestreo aleatorio

Los datos se seleccionan al azar de toda la población. Cada punto tiene la misma probabilidad de ser elegido.



● Población (todos los datos) ● Muestra aleatoria

Ventajas

- Reduce el sesgo de selección.
- Representativo de la población.

Cuándo usarlo


- Cuando la distribución espacial o temporal de los datos no es relevante.



Ejemplo: 20% de los datos

2. Muestreo regular

Los datos se seleccionan en intervalos o espacios uniformes a lo largo de la población.



● Población (todos los datos) ● Muestra regular

Ventajas

- Cobertura uniforme del espacio o del tiempo.
- Fácil de implementar.

Cuándo usarlo

- Cuando se desea una cobertura uniforme del área o del periodo de estudio.



Ejemplo: 20% de los datos

Consideración importante

La elección del método de muestreo depende del objetivo del estudio y de la naturaleza de los datos.

Objetivo:

Obtener una muestra representativa y eficiente.


Calidad del modelo:

Mejores resultados con un muestreo adecuado.

En la realidad, el muestreo de los datos se realiza únicamente en las localizaciones/condiciones de interés económico y técnico de nuestro sistema, pero esto no indica que se tenga la suficiente información y variabilidad para modelar el sistema en su totalidad. En otras palabras nuestros datos están sesgados (biased) por la naturaleza propia del problema en estudio.

¿Es factible proponer un muestreo aleatorio en el Golfo de México con un costo de \$150 M por pozo?

- Pozos son perforados en la zona del yacimiento identificada con el espesor con mayor potencial en base a los datos sísmicos
- Núcleos recuperados corresponden al espesor con las mejores condiciones de contenido de fluidos
- Las propiedades petrofísicas son estimadas de las muestras de roca mejor preservadas



3.4.2 Técnicas para resolver el muestreo sesgado

Existen diversas técnicas para reducir y corregir los efectos del muestreo sesgado, cuya aplicación depende de las características de los datos, su distribución espacial y el objetivo del análisis. Estas estrategias buscan mejorar la representatividad de la información disponible y evitar que las zonas o grupos con mayor cantidad de observaciones tengan una influencia desproporcionada sobre los resultados.

En aplicaciones geocientíficas, donde los datos suelen presentar una distribución espacial irregular, estas técnicas permiten reconocer zonas con diferente densidad de información, ajustar la contribución de las observaciones y reducir los efectos del muestreo preferencial. Entre las principales estrategias se encuentran:

1. **Uso de regiones:** divide el dominio de estudio en diferentes regiones para analizar y controlar la representatividad de los datos dentro de cada una.
- 2.


1 USO DE REGIONES

Divide el área de estudio en regiones o dominios con características similares para analizar y controlar la representatividad de los datos dentro de cada región.

PROBLEMA

El muestreo no es uniforme: hay muchas muestras en algunas zonas y muy pocas en otras.

Datos originales (sesgados)



● Cada punto = una muestra



Las zonas con muchas muestras pueden dominar los resultados y generar sesgo.

SOLUCIÓN: DIVIDIR EN REGIONES

El área de estudio se divide en regiones con características geológicas o espaciales similares.

Análisis por regiones



■ Región 1 ■ Región 2 ■ Región 3 ■ Región 4

ANÁLISIS POR REGIONES

Se calcula la estadística dentro de cada región y luego se combinan los resultados.

Región 1



Media: 52
N: 38

Región 2



Media: 48
N: 32

Región 3



Media: 46
N: 30

Región 4



Media: 50
N: 28



BENEFICIOS



Cada región aporta de forma equilibrada al análisis.



Se evitan conclusiones dominadas por zonas sobre-muestreadas.



Resultados más representativos del área de estudio.



IDEA CLAVE: Al usar regiones, se reconoce que el área de estudio es heterogénea y que cada parte debe estar adecuadamente representada para obtener resultados confiables.


1. **Mapeo:** permite visualizar la distribución espacial de las observaciones e identificar zonas con alta o baja densidad de muestreo

2 MAPEO

Representa espacialmente los datos para identificar visualmente zonas con alta concentración de muestras y áreas con poca o ninguna información.

1 ¿POR QUÉ ES IMPORTANTE?

El mapeo permite diagnosticar el muestreo sesgado al visualizar la distribución espacial de las observaciones.




● Cada punto = una muestra

Se observa una fuerte concentración de muestras en el noroeste y grandes áreas con poca o ninguna información.

2 ¿CÓMO SE APLICA?

Se representan los datos en mapas para analizar su distribución espacial y detectar patrones de muestreo.

Mapa de densidad de muestras



Densidad de muestras
Alta Baja

Mapa de celdas (hexagonal)



Número de muestras por celda
Muy alta Muy baja

Otras representaciones útiles

Mapas de puntos: muestran la ubicación exacta de las muestras.

Mapas de grilla: resumen la cantidad de muestras por celda.

Mapas de contornos de densidad: resaltan zonas de agrupamiento.

3 ¿QUÉ PERMITE IDENTIFICAR?

El mapeo ayuda a detectar problemas de muestreo y a planificar nuevas campañas.

- Zonas sobre-muestreadas**
Áreas con demasiadas observaciones que pueden dominar los resultados.
- Zonas sub-muestreadas**
Áreas con pocas muestras que pueden generar incertidumbre.
- Zonas sin información**
Áreas sin datos; requieren muestreo adicional o fuentes alternativas.
- Planificación del muestreo**
Guía para diseñar campañas de muestreo más equilibradas y representativas.

BENEFICIOS DEL MAPEO

- ✓ Detecta rápidamente sesgos espaciales.
- ✓ Facilita decisiones basadas en evidencia.
- ✓ Mejora la representatividad de los análisis y modelos.

IDEA CLAVE Mapear antes de analizar permite ver lo que los números por sí solos no muestran: dónde están los datos, dónde hacen falta y cómo el muestreo puede estar influyendo en los resultados.




1. **Desagrupamiento (Declustering)**: asigna diferentes pesos a las observaciones para reducir la influencia de las zonas densamente muestreadas y aumentar la representatividad de aquellas con menor cantidad de datos.

Cell Declustering. En muchos estudios geocientíficos los datos no están distribuidos de manera uniforme en el espacio. Por ejemplo, en yacimientos o áreas de exploración es común que existan muchas muestras cerca de carreteras, afloramientos o pozos, y pocas en zonas remotas. Esta distribución irregular o agrupada (clustering) hace que las estimaciones globales, como la media o la varianza de la porosidad o permeabilidad, estén sesgadas hacia las regiones sobremuestreadas.

El desagrupamiento por celdas es una técnica que corrige este sesgo asignando pesos a las muestras de tal forma que cada región del área de estudio tenga una influencia equivalente en las estadísticas globales. El método consiste en dividir el área en una malla regular de celdas y ponderar las muestras según la cantidad de datos que contiene cada celda.

STEPS OF CELL DECLUSTERING


1



Define the study area and cell size

The area of interest is delineated and a regular grid (square or rectangular) is established. The cell size must be larger than the local sampling scale, but small enough to capture spatial variability. An appropriate cell size is selected by testing several values and checking the stability of results.

2



Assign each sample to a cell

Each sample is assigned to the cell that contains it. Several samples may fall in the same cell; other cells may remain empty.


3

3	1	1	0	2
0	2	2	1	0
1	0	3	2	1
0			0	3

Count the number of samples per cell

For each occupied cell, count how many samples it contains (n_j). This count reflects the data density in space.

4



Calculate and assign weights to samples

Each sample is assigned a weight inversely proportional to the number of samples in its cell and to the total number of occupied cells (N_c):

$$w_i = \frac{1}{N_c n_j}$$

where:

- w_i = weight of sample i
- n_j = number of samples in cell j
- N_c = total number of occupied cells

5



Compute declustered statistics

Use the weights to calculate the mean, variance, or other statistics of interest. In this way, each occupied cell contributes equally, reducing the bias caused by clustered sampling.

Example of declustered mean:

$$\bar{z}_d = \sum_{i=1}^n w_i z_i \quad \text{where } z_i \text{ is the value of sample } i.$$



Important notes

- Cell declustering does not remove natural variability; it only corrects bias due to uneven spatial distribution.
- It is recommended to evaluate the sensitivity of results to cell size and grid origin.
- This technique is a common preprocessing step before geostatistical analysis or simulations.

Esta técnica es ampliamente utilizada antes de realizar análisis estadísticos, modelado geoestadístico o simulaciones, ya que permite obtener estimaciones más representativas del conjunto de datos y del fenómeno estudiado.


3 DESAGRUPAMIENTO (DECLUSTERING)

Asigna diferentes pesos a las observaciones según su distribución espacial para reducir la influencia de las zonas densamente muestreadas y aumentar la representatividad de aquellas con menor cantidad de datos.

1 ¿POR QUÉ ES NECESARIO?

El muestreo suele estar agrupado en zonas de fácil acceso o mayor interés, lo que puede sesgar las estadísticas y modelos.

Distribución de muestras (sesgada)



● Cada punto = una muestra.

Las zonas con muchas muestras pueden dominar los resultados (por ejemplo, la media puede sobreestimar zonas de alta ley o concentración).


2 ¿CÓMO FUNCIONA?

Se calcula un peso para cada muestra en función de la densidad de muestreo alrededor de ella:

Zonas con muchas muestras cercanas
→ menor peso

Zonas con pocas muestras cercanas
→ mayor peso

Esquema de desagrupamiento



Pesos asignados a las muestras

Menor peso → Mayor peso

Ejemplo de peso basado en densidad

$$w_i = \frac{1}{n_i}$$

donde w_i = peso de la muestra i
 n_i = número de muestras en la celda o vecindad


3 ¿QUÉ SE OBTIENE?

Al aplicar los pesos en el cálculo de estadísticas o en el entrenamiento de modelos, se obtiene una representación más equilibrada del área.

Resultados: comparación de la media

Sin desagrupamiento
(media simple)

Con desagrupamiento
(media ponderada)



BENEFICIOS DEL DESAGRUPAMIENTO

- ✓ Reduce el sesgo causado por el muestreo agrupado.
- ✓ Produce estadísticas y modelos más representativos del dominio.
- ✓ Mejora la estimación de recursos, reservas y riesgos.
- ✓ Se puede aplicar antes de análisis estadístico o modelado (geostatístico o de machine learning).




IDEA CLAVE

El desagrupamiento no elimina datos; ajusta su influencia para que todas las zonas del área de estudio cuenten.



Resultados más representativos y confiables


1. **Corrección de sesgo (Debiasing):** aplica métodos estadísticos o de remuestreo para corregir diferencias sistemáticas en la representación de los datos y obtener una muestra más representativa de la población.



Bootstrap. El bootstrap es una técnica estadística de remuestreo que permite evaluar la variabilidad, incertidumbre y posible sesgo de un estimador a partir de un conjunto limitado de observaciones. Su principal ventaja es que no requiere conocer de manera explícita la distribución de probabilidad de la población. En su lugar, utiliza repetidamente los datos disponibles para construir nuevos conjuntos de muestras y analizar cómo cambia una estadística de interés, como la media, mediana, varianza, percentiles o coeficientes de un modelo.

El principio fundamental del bootstrap consiste en generar múltiples muestras aleatorias con reemplazo a partir del conjunto de datos original. Cada nueva muestra contiene el mismo número de observaciones que el conjunto original, pero algunos valores pueden aparecer varias veces y otros no ser seleccionados. Para cada muestra se calcula la estadística de interés y, después de repetir el procedimiento un gran número de veces, se obtiene una distribución bootstrap. Esta distribución permite analizar qué tan estable es la estimación original y cuantificar su incertidumbre.

En geociencias, el bootstrap puede ser particularmente útil para evaluar la incertidumbre asociada con propiedades como porosidad, permeabilidad, saturación de fluidos o concentraciones geoquímicas, especialmente cuando el número de observaciones disponibles es limitado.



Assumption.

1. Bootstrap assumes that the original dataset is sufficiently large and representative of the population being studied. Since bootstrap generates new samples only by resampling the existing observations, it cannot introduce information that is absent from the original dataset. For example, if porosity samples adequately represent the different geological conditions of a reservoir, bootstrap can provide a reasonable estimate of the uncertainty in the mean porosity. However, if most samples come from high-porosity zones, the bootstrap procedure will repeatedly reproduce this sampling bias.

Limitations.

1. Assumes the samples are representative. This is closely related to the main assumption. Bootstrap treats the empirical distribution of the observed data as an approximation of the actual population distribution. If certain geological conditions are missing from the dataset, they cannot appear in the bootstrap realizations.
2. Only accounts for uncertainty due to too few samples; e.g., no uncertainty due to changes away from data.

Bootstrap is mainly designed to quantify sampling uncertainty: how much a statistic could change if a different set of observations had been collected from the same underlying population.

3. Does not account for area of interest. Ordinary bootstrap does not explicitly consider the geometry, dimensions, or spatial extent of the study area. For example, imagine that you have 50 porosity measurements describing a reservoir. Those same 50 observations could represent an area of 1km or 100 km, from the perspective of ordinary bootstrap, the dataset still contains the same 50 values. The method does not automatically recognize that using those observations to characterize a much larger spatial domain could introduce additional uncertainty.
4. Assumes the samples are independent. Standard bootstrap assumes that observations can be independently resampled. This is particularly important in geosciences because spatial observations are frequently correlated.
5. Assumes stationarity. Standard bootstrap generally treats the observations as if they originate from the same underlying statistical population. In geosciences, this means assuming that the statistical behavior of the variable does not systematically change across the domain being analyzed.

3.5