

Temas Selectos de Ingeniería Petrolera

21 de septiembre de 2026

Moisés Velasco Lozano

PhD

PROFESOR

Universidad Nacional Autónoma de México


FACULTY RESEARCH GUEST

Los Alamos National Laboratory

Índice

1	Análisis de Datos	4
1.1	Generalidades: datasets, variables, características (features) y etiquetas (labels)	4
1.1.1	Ciencia de Datos y Machine Learning	4
1.2	Estadística descriptiva	6
1.2.1	Medidas de Tendencia Central	6
1.2.2	Medidas de Dispersión	6
1.2.3	Medidas de Posición	7
1.3	Variables	9
1.4	Procesamiento de los datos	10
1.4.1	Muestreo de los datos	10
1.4.2	Técnicas para resolver el muestreo sesgado	12
1.5	Análisis exploratorio de datos	20
1.5.1	Objetivos del EDA	20
1.5.2	Calidad de los datos	20
1.5.3	Datos faltantes	23
1.5.4	Valores atípicos (Outliers)	24
1.5.5	Distribuciones	27
1.6	Correlación bivariada entre variables	33
1.6.1	Pearson's correlation coefficient	34
1.6.2	Spearman's correlation coefficient	35
1.6.3	Matriz de correlación	35
1.6.4	Mapa de calor (Heatmap)	36
1.6.5	Correlación vs Causalidad	37
1.6.6	Visualización en el EDA	38
1.7	Feature selection	40
1.7.1	Dimensionalidad	40
1.7.2	Selección de features	42
1.7.3	Feature Engineering	44
1.7.4	Dimensionality reduction	45
1.8	Data Splitting	46
1.8.1	Conjuntos de datos	46
1.8.2	Métodos de división de datos	47
1.9	Feature transformation	49
1.9.1	Truncamiento de variables (Feature Truncation)	49
1.9.2	Transformación Afín (Affine correction)	50
1.9.3	Estandarización (Standarization)	50
1.9.4	Normalización Min-Max (Min-Max Normalization)	51

3 Análisis de Datos



1 Análisis de Datos

Objetivo general. Al finalizar esta unidad, el estudiante comprenderá los fundamentos de la Ciencia de Datos y del Machine Learning, identificando los elementos que conforman un conjunto de datos, aplicando técnicas de análisis exploratorio, comprendiendo el flujo metodológico para el desarrollo de proyectos predictivos y evaluando modelos mediante métricas apropiadas para problemas de aprendizaje supervisado y no supervisado.

1.1 Generalidades: datasets, variables, características (features) y etiquetas (labels)

Objetivo específico. Comprender la estructura de los conjuntos de datos utilizados en Machine Learning, diferenciando sus componentes fundamentales y su importancia dentro del proceso de construcción de modelos predictivos.

La materia prima de cualquier sistema de Inteligencia Artificial son los datos. La calidad, cantidad y representatividad de estos determinan, en gran medida, el desempeño de los algoritmos de aprendizaje automático.

Antes de entrenar un modelo, es indispensable comprender cómo están organizados los datos, qué representan sus variables y cuál es el objetivo del aprendizaje.

1.1.1 Ciencia de Datos y Machine Learning

La Ciencia de Datos es una disciplina interdisciplinaria que combina estadística, informática, matemáticas y conocimiento del dominio para extraer información útil a partir de grandes volúmenes de datos.

Por su parte, el Machine Learning constituye una rama de la Inteligencia Artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos y realizar predicciones o tomar decisiones sin haber sido programados explícitamente para cada situación.

En términos generales, la Ciencia de Datos abarca todo el proceso de obtención, preparación, análisis e interpretación de datos, mientras que el Machine Learning se enfoca en la construcción de modelos predictivos.


Dataset. Un dataset o conjunto de datos es una colección organizada de observaciones utilizadas para entrenar, validar y evaluar modelos de aprendizaje automático. Cada dataset está compuesto por:

- Filas (observaciones o registros).
- Columnas (variables o atributos).
- Valores.

Tipos de datos

Los datos representan características observables de los objetos de estudio.

TIPOS DE DATOS



1.2 Estadística descriptiva

1.2.1 Medidas de Tendencia Central

Las medidas de tendencia central buscan identificar un valor representativo o central alrededor del cual se distribuyen las observaciones.

- **Media:** Es el promedio aritmético de todos los valores. Se obtiene sumando las observaciones y dividiendo entre el número total de datos. Es muy útil para resumir una variable, pero puede verse fuertemente afectada por valores atípicos.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Mediana:** Es el valor que se encuentra en el centro después de ordenar los datos de menor a mayor. El 50 % de las observaciones queda por debajo y el otro 50 % por encima. Es especialmente útil cuando existen outliers o distribuciones asimétricas, ya que es menos sensible a valores extremos.
- **Moda:** Es el valor que aparece con mayor frecuencia en el conjunto de datos. Puede existir una moda, varias modas o ninguna claramente definida. Es particularmente útil para analizar variables categóricas o discretas.

1. TENDENCIA CENTRAL
Indica el valor típico o representativo de los datos.


$\bar{x}$ MEDIA ($\bar{x}$)

Promedio aritmético de todos los valores.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Ejemplo:
2, 4, 4, 6, 8

$$\bar{x} = \frac{2+4+4+6+8}{5} = 4.8$$




Media ($\bar{x} = 4.8$)

Me MEDIANA (Me)

Valor central cuando los datos están ordenados.

Ejemplo:
2, 4, 4, 6, 8 → Me = 4




Mediana (valor central)

Mo MODA (Mo)

Valor que más se repite.

Ejemplo:
2, 4, 4, 6, 8 → Mo = 4



Moda (más frecuente)

IDEA CLAVE

Media, mediana y moda son medidas de tendencia central que nos ayudan a identificar el valor típico de un conjunto de datos desde diferentes perspectivas.

- **Media:** sensible a valores extremos.
- **Mediana:** menos sensible a valores extremos.
- **Moda:** útil para datos categóricos o con repeticiones.

1.2.2 Medidas de Dispersión

Mientras que la tendencia central indica dónde se concentran los datos, las medidas de dispersión describen qué tan separados o variables son los valores.

- **Varianza:** Cuantifica la dispersión de los datos respecto a la media mediante el promedio de las desviaciones al cuadrado. Una varianza pequeña indica datos relativamente homogéneos; una varianza grande indica mayor variabilidad.

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

Una desventaja es que sus unidades están elevadas al cuadrado. Por ejemplo, si la permeabilidad está expresada en mD, su varianza estará expresada en mD²

- **Desviación estándar:** Es la raíz cuadrada de la varianza y representa una medida de la distancia típica de las observaciones respecto a la media.

$$\sigma$$

Su principal ventaja es que conserva las mismas unidades de la variable original, haciendo más sencilla su interpretación.

- **Rango:** Es la diferencia entre el valor máximo y el valor mínimo del conjunto de datos.

$$R = x_{max} - x_{min}$$

Permite obtener una primera idea de la amplitud de los datos, aunque es muy sensible a valores extremos porque depende únicamente del mínimo y máximo.

2. DISPERSIÓN

Mide cuánto se alejan los datos del valor central.

VARIANZA (s²) Promedio de los cuadrados de las desviaciones respecto a la media.	DESVIACIÓN ESTÁNDAR (s) Raíz cuadrada de la varianza. En las mismas unidades que los datos.	RANGO (R) Diferencia entre el valor máximo y el mínimo.
$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$ Ejemplo (2, 4, 4, 6, 8) $s^2 = 5.2$ $\bar{x} = 4.8$ La varianza se expresa en las mismas unidades al cuadrado.	$s = \sqrt{s^2}$ Ejemplo (2, 4, 4, 6, 8) $s = \sqrt{5.2} = 2.28$ Indica la desviación típica: cuánto se alejan, en promedio, los datos de la media.	$R = Max - Min$ Ejemplo (2, 4, 4, 6, 8) $R = 8 - 2 = 6$ Mín = 2 Máx = 8 Mide la amplitud total del conjunto de datos.

EN RESUMEN

- La **varianza (s²)** cuantifica la variabilidad total al cuadrado.
- La **desviación estándar (s)** expresa la dispersión promedio en las mismas unidades.
- El **rango (R)** indica la distancia entre el valor máximo y el mínimo.

1.2.3 Medidas de Posición

Las medidas de posición permiten determinar dónde se encuentra una observación con respecto al resto de los datos una vez que estos han sido ordenados.

- **Cuartiles:** Dividen los datos ordenados en cuatro partes. El primer cuartil (Q1) deja aproximadamente el 25 % de los datos por debajo; Q2 corresponde al 50 % y coincide con la mediana; y Q3 representa el 75 %. Los cuartiles son fundamentales para construir el boxplot y analizar la distribución y posibles valores atípicos.
- **Percentiles:** Dividen los datos ordenados en 100 partes. Por ejemplo, el percentil 90 (P90) representa el valor por debajo del cual se encuentra aproximadamente el 90 % de las observaciones. Son muy útiles para comparar observaciones y establecer valores de referencia dentro de una distribución.



3. POSICIÓN


Indica la ubicación relativa de los datos dentro del conjunto.

CUARTILES

Dividen los datos ordenados en 4 partes iguales.

Ejemplo:

1, 3, 7, 9, 12, 15, 17




- **Q1 (25%):** 25% de los datos están por debajo de este valor.
- **Q2 (Mediana, 50%):** 50% de los datos están por debajo de este valor.
- **Q3 (75%):** 75% de los datos están por debajo de este valor.

PERCENTILES

Dividen los datos en 100 partes iguales.

Ejemplo:

- **P₉₀:** el valor por debajo del cual se encuentra el 90% de los datos.
- **P₁₀:** el valor por debajo del cual se encuentra el 10% de los datos.




IDEA CLAVE

Las medidas de posición permiten saber dónde se encuentran los datos dentro del conjunto, lo que facilita su interpretación y comparación.

1.3 Variables

Características (Features): Se representan normalmente mediante la matriz X . Generalmente se denominan como las **variables independientes** (X), las cuales contienen la información de entrada utilizada para realizar una predicción

Etiquetas (Labels): Se representan mediante la variable y (Y si es un matriz de etiquetas). Generalmente se denomina como la **variable dependiente** (y) ya que representa el resultado esperado.




1.4 Procesamiento de los datos

El procesamiento de los datos constituye una de las etapas más importantes dentro de cualquier proyecto de Machine Learning. Aunque con frecuencia se presta mayor atención al desarrollo de modelos y algoritmos, la calidad de las predicciones depende en gran medida de la calidad de la información utilizada durante el entrenamiento. En la práctica, se estima que aproximadamente el 80 % del tiempo y esfuerzo de un proyecto de aprendizaje automático se dedica a la preparación, limpieza, transformación y organización de los datos.

En esta etapa se realizan actividades como la identificación y tratamiento de valores faltantes, la detección de datos atípicos, la corrección de inconsistencias, la integración de múltiples fuentes de información y la transformación de variables para que puedan ser utilizadas de manera eficiente por los algoritmos de Machine Learning. Asimismo, es común aplicar técnicas de normalización, estandarización, codificación de variables categóricas y generación de nuevas características que permitan representar mejor el fenómeno bajo estudio.

En el ámbito de las geociencias, el procesamiento de los datos adquiere una relevancia aún mayor debido a la naturaleza heterogénea de la información disponible. Es frecuente trabajar simultáneamente con registros de pozos, datos sísmicos, propiedades petrofísicas, información geoespacial, imágenes satelitales y resultados de simulación numérica, los cuales presentan diferentes formatos, escalas espaciales y temporales, unidades de medición y niveles de incertidumbre. Un procesamiento adecuado permite integrar todas estas fuentes de información en un conjunto de datos consistente y confiable



1.4.1 Muestreo de los datos

La información recopilada tiene como objetivo modelar el comportamiento de un fenómeno para poder predecir su comportamiento en base a los datos observados en el sistema de interés. Sin embargo, una de las dificultades más importantes es el determinar la calidad y representatividad de las observaciones obtenidas. En el caso de ingeniería petrolera, los datos recolectados corresponden generalmente a las zonas del yacimiento con las mejores características, es decir, los datos generados corresponden a las formaciones con mejor porosidad, permeabilidad, y espesor. Esta situación, aunque sustentada técnica y económicamente, resulta en un sesgo (bias) en los datos

utilizados en modelos de machine learning ya que no se tienen datos que cubran en su totalidad las propiedades del yacimiento.


En general, se tienen dos métodos para el muestreo de los datos:

1. Muestreo aleatorio.
 - (a) cada objeto en la población tiene la misma probabilidad de ser elegido
 - (b) la elección de cada objeto es independiente de otra elección
 - (c) la población de las posibles muestras es mayor en comparación al tamaño del muestreo
2. Muestreo regular
 - (a) las muestras son tomadas en intervalos regulares (igualmente espaciadas)
 - (b) menos confiable que el muestreo aleatorio

En general, se tienen dos métodos para el muestreo de los datos:

1. Muestreo aleatorio

Los datos se seleccionan al azar de toda la población. Cada punto tiene la misma probabilidad de ser elegido.



● Población (todos los datos) ● Muestra aleatoria

Ventajas

- Reduce el sesgo de selección.
- Representativo de la población.

Cuándo usarlo


- Cuando la distribución espacial o temporal de los datos no es relevante.



Ejemplo: 20% de los datos

2. Muestreo regular

Los datos se seleccionan en intervalos o espacios uniformes a lo largo de la población.



● Población (todos los datos) ● Muestra regular

Ventajas

- Cobertura uniforme del espacio o del tiempo.
- Fácil de implementar.

Cuándo usarlo

- Cuando se desea una cobertura uniforme del área o del periodo de estudio.



Ejemplo: 20% de los datos

Consideración importante

La elección del método de muestreo depende del objetivo del estudio y de la naturaleza de los datos.

Objetivo:

Obtener una muestra representativa y eficiente.

Calidad del modelo:


Mejores resultados con un muestreo adecuado.

En la realidad, el muestreo de los datos se realiza únicamente en las localizaciones/condiciones de interés económico y técnico de nuestro sistema, pero esto no indica que se tenga la suficiente información y variabilidad para modelar el sistema en su totalidad. En otras palabras nuestros datos están sesgados (biased) por la naturaleza propia del problema en estudio.

¿Es factible proponer un muestreo aleatorio en el Golfo de México con un costo de \$150 M por pozo?

- Pozos son perforados en la zona del yacimiento identificada con el espesor con mayor potencial en base a los datos sísmicos

- Núcleos recuperados corresponden al espesor con las mejores condiciones de contenido de fluidos
- Las propiedades petrofísicas son estimadas de las muestras de roca mejor preservadas



1.4.2 Técnicas para resolver el muestreo sesgado


Existen diversas técnicas para reducir y corregir los efectos del muestreo sesgado, cuya aplicación depende de las características de los datos, su distribución espacial y el objetivo del análisis. Estas estrategias buscan mejorar la representatividad de la información disponible y evitar que las zonas o grupos con mayor cantidad de observaciones tengan una influencia desproporcionada sobre los resultados.

En aplicaciones geocientíficas, donde los datos suelen presentar una distribución espacial irregular, estas técnicas permiten reconocer zonas con diferente densidad de información, ajustar la contribución de las observaciones y reducir los efectos del muestreo preferencial. Entre las principales estrategias se encuentran:

1. Uso de regiones: divide el dominio de estudio en diferentes regiones para analizar y controlar la representatividad de los datos dentro de cada una.

1 USO DE REGIONES

Divide el área de estudio en regiones o dominios con características similares para analizar y controlar la representatividad de los datos dentro de cada región.



2. Mapeo: permite visualizar la distribución espacial de las observaciones e identificar zonas con alta o baja densidad de muestreo


2 MAPEO

Representa espacialmente los datos para identificar visualmente zonas con alta concentración de muestras y áreas con poca o ninguna información.

1 ¿POR QUÉ ES IMPORTANTE?

El mapeo permite diagnosticar el muestreo sesgado al visualizar la distribución espacial de las observaciones.

Distribución de muestras (ejemplo)



● Cada punto = una muestra




Se observa una fuerte concentración de muestras en el noroeste y grandes áreas con poca o ninguna información.

2 ¿CÓMO SE APLICA?


Se representan los datos en mapas para analizar su distribución espacial y detectar patrones de muestreo.

Mapa de densidad de muestras



Densidad de muestras
Alta Baja

Mapa de celdas (hexagonal)



Número de muestras por celda
Muy alta Muy baja

Otras representaciones útiles



Mapas de puntos: muestran la ubicación exacta de las muestras.



Mapas de grilla: resumen la cantidad de muestras por celda.



Mapas de contornos de densidad: resaltan zonas de agrupamiento.

3 ¿QUÉ PERMITE IDENTIFICAR?

El mapeo ayuda a detectar problemas de muestreo y a planificar nuevas campañas.



Zonas sobre-muestreadas

Áreas con demasiadas observaciones que pueden dominar los resultados.



Zonas sub-muestreadas

Áreas con pocas muestras que pueden generar incertidumbre.



Zonas sin información

Áreas sin datos; requieren muestreo adicional o fuentes alternativas.



Planificación del muestreo

Guía para diseñar campañas de muestreo más equilibradas y representativas.

BENEFICIOS DEL MAPEO

- ✓ Detecta rápidamente sesgos espaciales.
- ✓ Facilita decisiones basadas en evidencia.
- ✓ Mejora la representatividad de los análisis y modelos.



IDEA CLAVE

Mapear antes de analizar permite ver lo que los números por sí solos no muestran: dónde están los datos, dónde hacen falta y cómo el muestreo puede estar influyendo en los resultados.



Datos



Mapeo



Mejores decisiones

3. Desagrupamiento (Declustering): asigna diferentes pesos a las observaciones para reducir la influencia de las zonas densamente muestreadas y aumentar la representatividad de aquellas con menor cantidad de datos.


3 DESAGRUPAMIENTO (DECLUSTERING)

Asigna diferentes pesos a las observaciones según su distribución espacial para reducir la influencia de las zonas densamente muestreadas y aumentar la representatividad de aquellas con menor cantidad de datos.

1 ¿POR QUÉ ES NECESARIO?

El muestreo suele estar agrupado en zonas de fácil acceso o mayor interés, lo que puede sesgar las estadísticas y modelos.

Distribución de muestras (sesgada)



● Cada punto = una muestra

Las zonas con muchas muestras pueden dominar los resultados (por ejemplo, la media puede sobreestimar zonas de alta ley o concentración).

2 ¿CÓMO FUNCIONA?

Se calcula un peso para cada muestra en función de la densidad de muestreo alrededor de ella:




Zonas con muchas muestras cercanas
→ menor peso



Zonas con pocas muestras cercanas
→ mayor peso

Esquema de desagrupamiento



Densidad de muestreo (por celda)

Alta
Media
Baja

Pesos asignados a las muestras



Ejemplo de peso basado en densidad

$$w_i = \frac{1}{n_i}$$


donde w_i = peso de la muestra i
 n_i = número de muestras en la celda o vecindad

3 ¿QUÉ SE OBTIENE?

Al aplicar los pesos en el cálculo de estadísticas o en el entrenamiento de modelos, se obtiene una representación más equilibrada del área.


Resultados: comparación de la media

Sin desagrupamiento (media simple)



Baja Alta

Con desagrupamiento (media ponderada)



Baja Alta

BENEFICIOS DEL DESAGRUPAMIENTO

- ✓ Reduce el sesgo causado por el muestreo agrupado.
- ✓ Produce estadísticas y modelos más representativos del dominio.
- ✓ Mejora la estimación de recursos, reservas y riesgos.
- ✓ Se puede aplicar antes de análisis estadístico o modelado (geoestadístico o de machine learning).



IDEA CLAVE

El desagrupamiento no elimina datos; ajusta su influencia para que todas las zonas del área de estudio cuenten.



Datos originales



Calcular densidad (de vecindad o celda)



Asignar pesos



Estadísticas / Modelos ponderados




Resultados más representativos y confiables

Cell Declustering. En muchos estudios geocientíficos los datos no están distribuidos de manera uniforme en el espacio. Por ejemplo, en yacimientos o áreas de exploración es común que existan muchas muestras cerca de carreteras, afloramientos o pozos, y pocas en zonas remotas. Esta distribución irregular o agrupada (clustering) hace que las estimaciones globales, como la media o la varianza de la porosidad o permeabilidad, estén sesgadas hacia las regiones sobremuestreadas. El desagrupamiento por celdas es una técnica que corrige este sesgo asignando pesos a las muestras de tal forma que cada región del área de estudio tenga una influencia equivalente en las estadísticas globales. El método consiste en dividir el área en una malla regular de celdas y ponderar las muestras según la cantidad de datos que contiene cada celda.


STEPS OF CELL DECLUSTERING

1

**Define the study area and cell size**

The area of interest is delineated and a regular grid (square or rectangular) is established. The cell size must be larger than the local sampling scale, but small enough to capture spatial variability. An appropriate cell size is selected by testing several values and checking the stability of results.

2

**Assign each sample to a cell**

Each sample is assigned to the cell that contains it. Several samples may fall in the same cell; other cells may remain empty.


3

3	1	1	0	2
0	2	2	1	0
1	0	3	2	1
0			0	3

Count the number of samples per cell

For each occupied cell, count how many samples it contains (n_j). This count reflects the data density in space.

4

**Calculate and assign weights to samples**

Each sample is assigned a weight inversely proportional to the number of samples in its cell and to the total number of occupied cells (N_c):

$$w_i = \frac{1}{N_c n_j}$$

where:

- w_i = weight of sample i
- n_j = number of samples in cell j
- N_c = total number of occupied cells

5

**Compute declustered statistics**

Use the weights to calculate the mean, variance, or other statistics of interest. In this way, each occupied cell contributes equally, reducing the bias caused by clustered sampling.

Example of declustered mean:

$$\bar{z}_d = \sum_{i=1}^n w_i z_i \quad \text{where } z_i \text{ is the value of sample } i.$$

**Important notes**

- Cell declustering does not remove natural variability; it only corrects bias due to uneven spatial distribution.
- It is recommended to evaluate the sensitivity of results to cell size and grid origin.
- This technique is a common preprocessing step before geostatistical analysis or simulations.

Esta técnica es ampliamente utilizada antes de realizar análisis estadísticos, modelado geoestadístico o simulaciones, ya que permite obtener estimaciones más representativas del conjunto de datos y del fenómeno estudiado.

4. Corrección de sesgo (Debiasing): aplica métodos estadísticos o de remuestreo para corregir diferencias sistemáticas en la representación de los datos y obtener una muestra más representativa de la población.


4 CORRECCIÓN DE SESGO (DEBIASING)

Aplica métodos estadísticos o de remuestreo para corregir diferencias sistemáticas en la representación de los datos y obtener una muestra más representativa de la población o del área de estudio.

1 ¿POR QUÉ ES NECESARIO?

El muestreo puede estar sesgado por la ubicación, el acceso, el interés económico o factores operativos, generando diferencias sistemáticas.

Ejemplo: muestreo sesgado



● = Muestra (observación)



Las zonas sobre-muestreadas pueden hacer que las estadísticas y los modelos reflejen el patrón del muestreo y no la realidad del área.

2 ¿CÓMO FUNCIONA?

Se identifican y corrigen los sesgos mediante estadísticas, ponderaciones o remuestreo para obtener una muestra más representativa.

Principales enfoques



Ponderación
Se asignan pesos a las observaciones para compensar la sobre o sub-representación.



Remuestreo
Se genera una nueva muestra más equilibrada (submuestreo o sobremuestreo).



Ajuste estadístico
Se ajustan las distribuciones o se eliminan tendencias sistemáticas en los datos.



Modelos de corrección
Se utilizan modelos que consideran el mecanismo de muestreo para corregir el sesgo.

Ejemplo: ponderación (basado en densidad)


Las muestras en zonas densas reciben menor peso y las de zonas poco muestreadas, mayor peso.




3 ¿QUÉ SE OBTIENE?

Se obtiene una distribución y estadísticas más cercanas a la realidad del área de estudio.

Comparación de distribuciones



Representación espacial



4 ¿PARA QUÉ SIRVE?

Para obtener análisis y modelos más confiables que generalicen mejor a todo el dominio.

Ejemplos de aplicación



Exploración minera y petrolera: estimaciones de recursos más confiables.



Modelos de machine learning: mejor desempeño y menor sesgo en las predicciones.



Geomodelado y simulaciones: representaciones más realistas del subsuelo.



Análisis estadístico: medias, varianzas y percentiles más representativos.

BENEFICIOS PRINCIPALES

- ✓ Reduce diferencias sistemáticas en los datos.
- ✓ Evita que zonas sobre-muestreadas dominen los resultados.
- ✓ Mejora la representatividad y la incertidumbre de las estimaciones.
- ✓ Aumenta la capacidad de generalización de los modelos.



IDEA CLAVE


La corrección de sesgo busca que los datos reflejen el área de estudio y no el patrón del muestreo. Así, las decisiones basadas en análisis y modelos serán más sólidas y confiables.



Bootstrap. El bootstrap es una técnica estadística de remuestreo que permite evaluar la variabilidad, incertidumbre y posible sesgo de un estimador a partir de un conjunto limitado de observaciones. Su principal ventaja es que no requiere conocer de manera explícita la distribución de probabilidad de la población. En su lugar, utiliza repetidamente los datos disponibles para construir nuevos conjuntos de muestras y analizar cómo cambia una estadística de interés, como la media, mediana, varianza, percentiles o coeficientes de un modelo.

El principio fundamental del bootstrap consiste en generar múltiples muestras aleatorias con reemplazo a partir del conjunto de datos original. Cada nueva muestra contiene el mismo número de observaciones que el conjunto original, pero algunos valores pueden aparecer varias veces y otros no ser seleccionados. Para cada muestra se calcula la estadística de interés y, después de repetir el procedimiento un gran número de veces, se obtiene una distribución bootstrap. Esta distribución permite analizar qué tan estable es la estimación original y cuantificar su incertidumbre.

En geociencias, el bootstrap puede ser particularmente útil para evaluar la incertidumbre asociada con propiedades como porosidad, permeabilidad, saturación de fluidos o concentraciones geoquímicas, especialmente cuando el número de observaciones disponibles es limitado.



Assumption.

1. Bootstrap assumes that the original dataset is sufficiently large and representative of the population being studied. Since bootstrap generates new samples only by resampling the existing observations, it cannot introduce information that is absent from the original dataset. For example, if porosity samples adequately represent the different geological conditions of a reservoir, bootstrap can provide a reasonable estimate of the uncertainty in the mean porosity. However, if most samples come from high-porosity zones, the bootstrap procedure will repeatedly reproduce this sampling bias.

Limitations.


1. Assumes the samples are representative. This is closely related to the main assumption. Bootstrap treats the empirical distribution of the observed data as an approximation of the actual population distribution. If certain geological conditions are missing from the dataset, they cannot appear in the bootstrap realizations.
2. Only accounts for uncertainty due to too few samples; e.g., no uncertainty due to changes away from data. Bootstrap is mainly designed to quantify sampling uncertainty: how much a statistic could change if a different set of observations had been collected from the same underlying population.
3. Does not account for area of interest. Ordinary bootstrap does not explicitly consider the geometry, dimensions, or spatial extent of the study area. For example, imagine that you have 50 porosity measurements describing a reservoir. Those same 50 observations could represent an area of 1km or 100 km, from the perspective of ordinary bootstrap, the dataset still contains the same 50 values. The method does not automatically

recognize that using those observations to characterize a much larger spatial domain could introduce additional uncertainty.

4. Assumes the samples are independent. Standard bootstrap assumes that observations can be independently resampled. This is particularly important in geosciences because spatial observations are frequently correlated.
5. Assumes stationarity. Standard bootstrap generally treats the observations as if they originate from the same underlying statistical population. In geosciences, this means assuming that the statistical behavior of the variable does not systematically change across the domain being analyzed.

A **confidence interval (CI)** is a range of values used to express the uncertainty associated with an estimated parameter, such as the mean permeability.

$$CI_{95\%} = [P_{2.5}, P_{97.5}]$$




1.5 Análisis exploratorio de datos

Objetivo específico. Aplicar técnicas de exploración y análisis exploratorio para comprender la estructura de los datos e identificar patrones relevantes antes del entrenamiento de modelos.

El Análisis Exploratorio de Datos (Exploratory Data Analysis, EDA) constituye el primer acercamiento sistemático al conjunto de datos. Su propósito es comprender la información disponible, detectar problemas y generar hipótesis que orienten el desarrollo del modelo.

1.5.1 Objetivos del EDA

$$EDA\ target = \left\{ \begin{array}{l} \text{Conocer la estructura del dataset} \\ \text{Detectar valores faltantes} \\ \text{Identificar valores atípicos} \\ \text{Analizar distribuciones} \\ \text{Descubrir relaciones entre variables} \\ \text{Detectar sesgos} \\ \text{Comprender la variable objetivo} \end{array} \right.$$



1.5.2 Calidad de los datos

La calidad de los datos constituye uno de los factores más importantes para el desarrollo de modelos de machine learning confiables. Un modelo será tan bueno como la información utilizada para entrenarlo; por ello, incluso los

algoritmos más avanzados pueden producir resultados deficientes si los datos contienen errores, inconsistencias o no representan adecuadamente el fenómeno de interés.


En aplicaciones de geociencias e ingeniería, este aspecto adquiere especial relevancia debido a que los datos suelen provenir de múltiples fuentes, escalas y métodos de adquisición, como registros geofísicos de pozo, análisis de núcleos, mediciones de laboratorio, información sísmica, sensores, bases de datos históricas y resultados de simulaciones numéricas. Cada fuente puede presentar diferentes niveles de resolución, incertidumbre y precisión. Por esta razón, antes del entrenamiento es necesario realizar un proceso sistemático de evaluación, limpieza y control de calidad de los datos.

	Well_ID	Depth_m	Porosity_%	Permeability_mD	GammaRay_API	Viscosity_cP	Density_g_cm3
1	W-01	1000	0.18	150	65	2.1	2.65
2	W-01	1005	0.21	210	68	2.0	2.64
3	W-01	1010	0.17	120	70	2.1	2.63
4	W-01	1015	0.19	180	72	2.2	2.66
5	W-01	1020	—	—	75	2.3	—
6	W-01	1025	0.20	190	78	2.2	2.67
7	W-01	1030	0.22	200	80	2.3	2.69
8	W-01	1035	0.25	25000	82	2.2	2.70
9	W-01	1040	0.20	210	85	2.2	2.68
10	W-01	1045	0.18	160	87	2.1	2.65
11	W-01	1050	0.19	170	88	2.2	2.66
12	W-01	1050	0.19	170	88	2.2	2.66
13	W-01	1055	19.5	170	90	2.2	2.66
14	W-01	1060	0.20	180	92	2.2	2.68
15	W-01	1065	0.21	195	95	0.0023	2.69
16	W-01	1070	0.17	150	96	2.1	2.65
17	W-01	1075	0.20	190	98	2.2	2650
18	W-01	1080	0.19	175	100	2.2	2.67
19	W-01	1085	—	5000	—	—	—
20	W-01	1090	0.21	205	102	2.2	2.69

Entre los principales problemas que pueden afectar la calidad de un conjunto de datos se encuentran:

1. **Datos faltantes:** Los datos faltantes (missing data) corresponden a observaciones para las cuales una o más variables no tienen un valor disponible. Pueden originarse por fallas de los instrumentos, ausencia de mediciones, problemas durante la adquisición, pérdida de información o integración de bases de datos provenientes de diferentes fuentes. Su tratamiento depende de la cantidad, distribución y causa de los valores faltantes. Algunas alternativas incluyen eliminar observaciones o variables con información insuficiente, utilizar métodos de imputación estadística (como media o mediana) o aplicar métodos más avanzados basados en vecinos cercanos, interpolación o modelos predictivos. Antes de imputar valores, es importante determinar si la ausencia de información presenta algún patrón sistemático, ya que esto puede introducir sesgos adicionales.
2. **Valores atípicos:** Los valores atípicos u outliers son observaciones considerablemente diferentes del comportamiento general de los datos. Pueden identificarse mediante histogramas, diagramas de caja, o métodos multivariados. Sin embargo, un valor extremo no necesariamente representa un error. En geociencias, por ejemplo, una permeabilidad excepcionalmente alta podría corresponder a una fractura o a una facies geológica particular. Por ello, antes de eliminar un outlier debe analizarse su origen y significado físico. El objetivo no es eliminar automáticamente los valores extremos, sino distinguir entre errores de medición y observaciones geológicamente válidas.

3. **Duplicados:** Los duplicados ocurren cuando una misma observación aparece más de una vez en el conjunto de datos. Pueden producirse durante la integración de bases de datos, procesos de adquisición, combinación de archivos o errores en la administración de la información. Su presencia puede modificar artificialmente la distribución de los datos y otorgar mayor importancia a determinadas observaciones durante el entrenamiento. La identificación de duplicados debe considerar tanto registros completamente idénticos como aquellos que comparten identificadores, coordenadas, profundidad o tiempo de adquisición. Una vez identificados, debe determinarse si corresponden a repeticiones innecesarias o mediciones independientes legítimas.
4. **Inconsistencias:** Las inconsistencias aparecen cuando diferentes registros utilizan formatos, unidades, convenciones o criterios incompatibles. Por ejemplo, una base de datos puede reportar profundidad en metros y otra en pies, permeabilidad en mD y otra en unidades diferentes, o utilizar distintas convenciones para representar categorías geológicas. Antes de combinar información proveniente de diferentes fuentes es fundamental estandarizar unidades, nombres, formatos, sistemas de coordenadas y criterios de clasificación. Estas inconsistencias pueden pasar inadvertidas y generar relaciones artificiales que posteriormente son interpretadas por el modelo como patrones reales.
5. **Errores de captura:** Son valores incorrectos introducidos durante la adquisición, transcripción, digitalización o almacenamiento de la información. Algunos ejemplos son errores decimales, signos incorrectos, intercambio de columnas, unidades equivocadas o valores físicamente imposibles. Estos problemas pueden detectarse mediante reglas de validación y conocimiento del dominio. Por ejemplo, una saturación mayor a 1 (cuando se expresa como fracción), una porosidad negativa o coordenadas fuera del área de estudio indican posibles errores. Por ello, el conocimiento físico y geológico constituye una herramienta fundamental para complementar los procedimientos estadísticos de control de calidad.
6. **Sesgos:** El sesgo ocurre cuando los datos disponibles no representan adecuadamente la población o el fenómeno que se pretende modelar. A diferencia de un error puntual, el sesgo puede afectar sistemáticamente todo el conjunto de datos y, por lo tanto, ser más difícil de identificar. Este problema es especialmente importante en datos geoespaciales. Por ejemplo, los pozos, muestras de núcleos o análisis geoquímicos normalmente no se distribuyen aleatoriamente en el espacio; suelen concentrarse en regiones consideradas previamente de mayor interés. Como consecuencia, ciertas condiciones geológicas pueden estar sobrerrepresentadas mientras que otras aparecen escasamente representadas.




La limpieza de datos constituye una de las etapas más importantes de cualquier proyecto de Ciencia de Datos.

1.5.3 Datos faltantes

Los datos faltantes son frecuentes en conjuntos de datos reales y pueden originarse por errores de medición, problemas en sensores, pérdida de registros o simplemente porque una variable no fue observada. Antes de aplicar cualquier estrategia es importante analizar cuántos datos faltan, dónde se encuentran y si existe algún patrón en su ausencia, ya que el tratamiento seleccionado puede modificar la distribución original de los datos e introducir sesgos. Los datos incompletos pueden afectar significativamente el rendimiento de un modelo. Las estrategias comunes incluyen:

- 1. Eliminación de registros:** Consiste en eliminar las observaciones (generalmente filas) que contienen uno o más valores faltantes. Es una estrategia sencilla y evita introducir valores artificiales; sin embargo, puede provocar una pérdida considerable de información y generar sesgos si los datos faltantes no ocurren de manera aleatoria. Es más apropiada cuando la proporción de datos faltantes es pequeña y se dispone de suficientes observaciones.
- 2. Imputación con media o mediana:** Consiste en reemplazar cada valor faltante con una medida representativa de la variable. La media puede utilizarse cuando la distribución es aproximadamente simétrica y no existen valores atípicos importantes, mientras que la mediana suele ser más robusta para distribuciones sesgadas o con outliers. Es fácil de implementar, pero puede reducir artificialmente la variabilidad de los datos y alterar las relaciones entre variables.
- 3. Imputación mediante modelos predictivos:** Utiliza las demás variables disponibles para construir un modelo capaz de estimar el valor faltante. Pueden emplearse modelos de regresión, árboles de decisión, Random Forest u otros algoritmos. Su ventaja es que aprovecha las relaciones existentes entre las variables y puede producir estimaciones más representativas; sin embargo, requiere mayor procesamiento y una mala predicción también puede introducir errores o sesgos en el dataset.

4. **Métodos basados en vecinos cercanos:** Estiman un valor faltante utilizando observaciones que presentan características similares. Por ejemplo, k-Nearest Neighbors (k-NN) identifica los k registros más cercanos y utiliza sus valores para realizar la imputación. Este enfoque puede preservar mejor la estructura local de los datos, pero es sensible a la escala de las variables, a la selección de k y puede resultar computacionalmente costoso para datasets grandes.



¿Cuál estrategia utilizar?

No existe un método universalmente superior. En un EDA conviene primero determinar la proporción y patrón de datos faltantes, analizar la distribución de cada variable y posteriormente comparar diferentes estrategias de imputación.

En aplicaciones de geociencias, por ejemplo, si falta un valor de permeabilidad, reemplazarlo simplemente con la media global puede ser poco representativo si el yacimiento contiene diferentes tipos de roca. Un método basado en variables como porosidad, facies, profundidad o saturación podría generar una estimación físicamente más consistente.

1.5.4 Valores atípicos (Outliers)

Los outliers son observaciones que presentan un comportamiento considerablemente diferente al resto de los datos. Su presencia no necesariamente significa que exista un error: pueden originarse por problemas de medición o captura, pero también representar condiciones reales y relevantes del sistema. Por ello, antes de eliminarlos es fundamental investigar su origen. Los outliers son observaciones que difieren considerablemente del resto de los datos. Su detección puede realizarse mediante:


1. Diagramas de caja: Permiten visualizar rápidamente la distribución de una variable mediante la mediana, los cuartiles y el rango de los datos. Los valores que aparecen fuera de los llamados bigotes del diagrama son

considerados potenciales outliers. Son especialmente útiles durante el EDA porque permiten identificar visualmente asimetrías, dispersión y valores extremos.

2. Método del rango intercuartílico (IQR). Es un método cuantitativo relacionado directamente con el boxplot. El IQR representa la distancia entre el primer y tercer cuartil:

$$IQR = Q_3 - Q_1$$


Una regla común considera como potenciales outliers aquellos valores menores que $Q_1 - 1.5 \times IQR$ o mayores que $Q_3 + 1.5 \times IQR$. Su principal ventaja es que no depende de la media ni de la desviación estándar, por lo que es relativamente robusto ante distribuciones sesgadas.



3. Puntajes Z: Indica a cuántas desviaciones estándar se encuentra una observación respecto a la media:


$$Z = \frac{x_i - \mu}{\sigma}$$

Un criterio común es considerar como potencialmente atípicos los valores con $|Z| > 3$. Este método funciona especialmente bien cuando los datos presentan una distribución aproximadamente normal, pero puede ser menos apropiado para variables fuertemente sesgadas.



4. Métodos basados en densidad: Analizan una observación considerando su relación con los datos que la rodean. Un punto ubicado en una región con muy pocas observaciones cercanas puede clasificarse como anómalo. Métodos como Local Outlier Factor (LOF) comparan la densidad local de cada observación con la de sus vecinos. Son particularmente útiles para datasets multivariados, donde un outlier puede no ser evidente al analizar cada variable individualmente.

Es importante analizar si representan errores o casos válidos del fenómeno estudiado.



Un punto importante en geociencias


En aplicaciones de ingeniería de yacimientos, un valor extremo de permeabilidad no necesariamente debe eliminarse. Por ejemplo, una permeabilidad de 5,000 mD dentro de un conjunto dominado por valores de 10–500 mD podría parecer un outlier estadístico, pero podría corresponder a una fractura, una región altamente permeable o una zona de flujo preferencial.

Por esta razón, la regla fundamental durante el EDA debería ser: detectar primero, investigar después y eliminar únicamente cuando exista una justificación física o estadística.

1.5.5 Distribuciones

La distribución de los datos describe cómo se encuentran organizados y con qué frecuencia aparecen los diferentes valores de una variable dentro de un conjunto de observaciones. Su análisis permite comprender la estructura estadística de los datos antes de aplicar técnicas de machine learning, identificando características como su tendencia central, dispersión, simetría, presencia de valores extremos y concentración de observaciones en determinados intervalos.

Dos variables pueden presentar valores similares de media y desviación estándar y, sin embargo, poseer distribuciones completamente diferentes. Por esta razón, el análisis de la distribución proporciona información que no puede obtenerse únicamente mediante estadísticas descriptivas.



Herramientas como histogramas, funciones de densidad, boxplots y gráficos de distribución acumulada permiten visualizar estas características. Entre las distribuciones y comportamientos que pueden encontrarse con mayor frecuencia se incluyen:

1. **Distribución normal:** Presenta una forma aproximadamente simétrica de campana, donde la mayoría de las observaciones se concentra alrededor de un valor central. En una distribución normal ideal, media, mediana y moda coinciden. Es importante porque muchos métodos estadísticos parten del supuesto de normalidad y porque permite interpretar fácilmente la dispersión mediante la desviación estándar.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x-\mu)^2}{2\sigma^2} \right]$$


1. DISTRIBUCIÓN NORMAL

Simétrica y con forma de campana.

La mayoría de los datos se concentran alrededor de la media.

Características

- Media = Mediana = Moda
- Simétrica respecto a la media (μ)
- Aproximadamente 68% de los datos están entre $\mu \pm 1\sigma$
- Aproximadamente 95% entre $\mu \pm 2\sigma$
- Aproximadamente 99.7% entre $\mu \pm 3\sigma$



2. **Distribución sesgada:** Es una distribución asimétrica, donde una de las colas se extiende más que la otra. El sesgo positivo presenta una cola hacia valores altos, mientras que el sesgo negativo tiene una cola hacia valores bajos. En estos casos, la media puede dejar de representar adecuadamente el centro de los datos, por lo que la mediana puede ser más informativa. Variables como la permeabilidad frecuentemente presentan distribuciones fuertemente sesgadas. Para geociencias, la distribución lognormal es un buen ejemplo porque variables como la permeabilidad frecuentemente presentan una cola hacia valores altos.

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp \left[-\frac{(\ln x - \mu)^2}{2\sigma^2} \right]$$

2. DISTRIBUCIÓN SESGADA


Asimétrica. Los datos se extienden más hacia un lado de la distribución.

Características


- No es simétrica.
- La cola de la distribución se extiende hacia valores altos (sesgo positivo) o bajos (sesgo negativo).
- Las medidas de tendencia central no coinciden.
- Común en datos naturales y económicos.

--- En sesgo positivo (a la derecha):
 --- < < <
 --- En sesgo negativo (a la izquierda):
 --- < < <

Sesgo positivo (a la derecha)



Sesgo negativo (a la izquierda)



3. **Distribución uniforme:** Los valores dentro de un determinado intervalo presentan una frecuencia o probabilidad aproximadamente constante. Esto significa que no existe una región claramente dominante dentro del rango analizado. Puede aparecer en datos generados mediante ciertos esquemas de muestreo o simulación, aunque es menos frecuente en propiedades naturales del subsuelo.

$$f(x) \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{otro casos} \end{cases}$$

3. DISTRIBUCIÓN UNIFORME

Todos los valores dentro de un intervalo tienen la misma probabilidad de ocurrir.

Características


- Probabilidad constante en todo el intervalo $[a, b]$.
- Todos los valores son igualmente probables.
- No hay valores más frecuentes que otros.

Ecuación (función de densidad)

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{en otro caso} \end{cases}$$

Media: $\mu = \frac{a+b}{2}$

Varianza: $\sigma^2 = \frac{(b-a)^2}{12}$



Interpretación: La probabilidad es la misma para cualquier valor dentro del intervalo $[a, b]$.

4. **Distribución multimodal:** Presenta dos o más máximos o picos claramente diferenciados. Su presencia puede indicar que los datos contienen diferentes poblaciones, procesos o condiciones físicas. Por ejemplo, una distribución multimodal de porosidad podría indicar la presencia de diferentes facies o tipos de roca dentro del mismo dataset. Podemos crear una distribución bimodal combinando dos distribuciones normales:

$$f(x) = w_1 f_1(x) + w_2 f_2(x)$$

$$w_1 + w_2 = 1$$

4. DISTRIBUCIÓN MULTIMODAL

Presenta dos o más picos (modas) claramente diferenciados.
Su presencia puede indicar que los datos provienen de diferentes poblaciones, procesos o condiciones físicas.

Características

- Existen dos o más modas locales.
- Puede indicar la presencia de múltiples grupos o poblaciones en los datos.
- Requiere análisis más detallado para interpretar su origen.

Representación matemática (mezcla de distribuciones)


Una distribución multimodal puede modelarse como la mezcla de K distribuciones:

$$f(x) = \sum_{k=1}^K w_k f_k(x)$$

donde:

- $f_k(x)$: función de densidad de la k -ésima población.
- w_k : peso o proporción de la k -ésima población, $w_k \geq 0$, $\sum_{k=1}^K w_k = 1$.

Ejemplo: distribución bimodal (dos poblaciones normales)



Ejemplo de mezcla de dos normales:


$$f(x) = w_1 \mathcal{N}(x | \mu_1, \sigma_1^2) + w_2 \mathcal{N}(x | \mu_2, \sigma_2^2)$$

Donde:

- $w_1 + w_2 = 1$
- $w_1, w_2 > 0$

Ejemplo en geociencias (porosidad)

Dos picos pueden representar diferentes facies o tipos de roca.



La presencia de múltiples picos sugiere heterogeneidad en los datos y la existencia de diferentes procesos o condiciones geológicas.


La forma de la distribución influye en la selección de algoritmos y técnicas de preprocesamiento.



Asimetría (Skewness): este parámetro (y su estadístico correspondiente) indica si la distribución es simétrica o asimétrica. Se calcula como la razón entre el promedio de las desviaciones de las observaciones respecto a la media, elevadas al cubo, y la desviación estándar elevada al cubo. Es un parámetro adimensional:

$$g_1 = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^3}{\sigma^3}$$

Si la distribución es unimodal, un valor negativo indica que la distribución presenta una cola larga hacia la izquierda; es decir, existen pocos valores bajos y la mayoría de las observaciones se concentran en valores altos. Un valor de cero indica que la distribución es perfectamente simétrica. Un valor positivo indica una cola larga hacia la derecha, donde la mayoría de los valores se concentran en valores bajos y existen pocas observaciones con valores altos.



Curtosis (Kurtosis): este parámetro mide qué tan pesadas son las colas de la distribución con respecto a su centro. Se utiliza para comparar distribuciones simétricas con la distribución normal:


$$a_4 = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^4}{\sigma^4}$$

La curtosis se utiliza con frecuencia para comparar la forma de una distribución con la distribución normal mediante el cálculo del exceso de curtosis, que se obtiene simplemente restando 3 al valor de la curtosis, ya que una distribución normal tiene una curtosis de 3.

2. CURTOSIS (KURTOSIS)

Mide qué tan pesadas o ligeras son las colas de la distribución en comparación con la distribución normal.

$$\text{Exceso de curtosis} = \text{Curtosis} - 3$$



En geociencias, las distribuciones frecuentemente se alejan de la distribución normal. Propiedades como la permeabilidad pueden presentar distribuciones fuertemente asimétricas y abarcar varios órdenes de magnitud, mientras que variables como porosidad, saturación, contenido mineral o concentraciones geoquímicas pueden mostrar distribuciones complejas relacionadas con diferentes facies, ambientes de depósito o procesos geológicos.

1.6 Correlación bivariada entre variables

La correlación bivariada permite analizar la relación existente entre dos variables, identificando tanto la dirección como el nivel de su correlación. Este análisis constituye una herramienta fundamental durante la exploración de datos, ya que permite reconocer patrones, dependencias y posibles relaciones entre las variables de un conjunto de datos.

Existen diferentes métodos para cuantificar esta relación dependiendo de las características y distribución de los datos. Entre los más utilizados se encuentran el coeficiente de correlación de Pearson, empleado principalmente para evaluar relaciones lineales, y el coeficiente de correlación de Spearman, utilizado para identificar relaciones monotónicas y especialmente útil cuando los datos no cumplen supuestos de normalidad o presentan valores atípicos.

La correlación mide la fuerza y dirección de la relación entre dos variables.

Valores cercanos a:

- +1 indican una relación positiva fuerte. Indica que las dos variables tienden a cambiar en la misma dirección. Cuando una variable aumenta, la otra también tiende a aumentar. Mientras más cercano sea r a +1, más fuerte será la relación lineal. Por ejemplo, en un yacimiento podría existir una correlación positiva entre porosidad y permeabilidad
- -1 indican una relación negativa fuerte. Indica que las variables tienden a cambiar en direcciones opuestas. Cuando una aumenta, la otra tiende a disminuir. Mientras más cercano sea r a -1, mayor será la intensidad de esta relación inversa. Por ejemplo, determinadas propiedades petrofísicas podrían disminuir conforme aumenta la profundidad.
- 0 indican ausencia de relación lineal. Indica que no existe una relación lineal significativa entre las variables. Sin embargo, esto no significa necesariamente que no exista relación. Dos variables pueden presentar una relación no lineal (cuadrática, exponencial u otra) y aun así tener una correlación de Pearson cercana a cero. Por esta razón, siempre es conveniente complementar el coeficiente con gráficas de dispersión.

1 ¿QUÉ ES LA CORRELACIÓN?

La correlación cuantifica cómo cambian conjuntamente dos variables.

El coeficiente de correlación de Pearson (r) varía entre -1 y +1.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Donde:

x_i, y_i : valores de las variables

$\bar{x}, \bar{y}$: medias de las variables

n : número de observaciones


2 INTERPRETACIÓN DEL COEFICIENTE DE CORRELACIÓN (r)

Valores cercanos a:

$r \approx +1$

RELACIÓN POSITIVA FUERTE


A medida que una variable aumenta, la otra también aumenta.



$r \approx -1$

RELACIÓN NEGATIVA FUERTE


A medida que una variable aumenta, la otra disminuye.




$r \approx 0$

AUSENCIA DE RELACIÓN LINEAL

No existe un patrón lineal claro entre las variables.



Escala de interpretación



1.6.1 Pearson's correlation coefficient

Proporciona una medida del grado de correlación lineal entre dos variables

$$\rho_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1)\sigma_x \sigma_y}$$

donde:


n es el número de pares

$\bar{x}$ y $\bar{y}$ son las medias de las variables

σ_x y σ_y son las desviaciones estándar de las variables

Pearson permite identificar rápidamente variables que cambian conjuntamente. En geociencias, por ejemplo, puede utilizarse para estudiar relaciones como porosidad y permeabilidad. Sin embargo, sus principales limitaciones son:

- Solo mide relaciones lineales. Dos variables pueden tener una relación no lineal muy fuerte y aun así presentar $r \approx 0$.
- Es sensible a outliers. Unos pocos valores extremos pueden modificar considerablemente r .



Al analizar ρ_{xy} se tiene que es una representación estandarizada de la covarianza:

$$C_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1)}$$

donde al recordar la definición de la varianza se tiene:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})}{(n-1)}$$

1.6.2 Spearman's correlation coefficient

Proporciona una medida del grado de correlación monótonica entre dos variables. A diferencia de Pearson, no requiere que la relación sea lineal. En lugar de trabajar directamente con los valores originales, Spearman los transforma en rangos:

$$\rho_{R_x R_y} = \frac{\sum_{i=1}^n (R_{x_i} - \bar{R}_x)(R_{y_i} - \bar{R}_y)}{(n-1)\sigma_{R_x}\sigma_{R_y}}$$


donde:

n es el número de pares

$\bar{R}_x$ y $\bar{R}_y$ son las medias de las transformaciones por rango de las variables

σ_{R_x} y σ_{R_y} son las desviaciones estándar de las transformaciones por rango de las variables

Matrices de correlación y mapas de calor permiten visualizar estas relaciones.




1.6.3 Matriz de correlación

Una matriz de correlación contiene los coeficientes calculados entre todas las combinaciones de variables numéricas del dataset. Permite identificar rápidamente qué variables presentan relaciones positivas, negativas o débiles.

La diagonal principal siempre tiene un valor de 1, ya que cada variable está perfectamente correlacionada consigo misma. Además, la matriz es simétrica: la correlación entre X y Y es igual a la correlación entre Y y X . En Machine Learning, esta matriz es particularmente útil para detectar variables que contienen información similar o redundante.

MATRIZ DE CORRELACIÓN

Coefficiente de correlación de Pearson (r) entre variables numéricas




1.6.4 Mapa de calor (Heatmap)

El heatmap es una representación gráfica de la matriz de correlación en la que los valores numéricos son representados mediante una escala de colores. Esto facilita la identificación visual de grupos de variables fuertemente relacionadas, especialmente cuando el dataset contiene muchas características.

En un EDA, el heatmap permite detectar rápidamente correlaciones fuertes, relaciones inversas y posibles problemas de multicolinealidad antes de construir el modelo.

EJEMPLO: MATRIZ DE CORRELACIÓN



1.6.5 Correlación vs Causalidad

Una consideración fundamental es que correlación no significa causalidad. Dos variables pueden presentar una correlación elevada sin que una sea responsable de los cambios observados en la otra. La relación puede estar controlada por una tercera variable o simplemente surgir por las características del dataset.


Por ello, dentro del EDA la correlación debe utilizarse como una herramienta para descubrir relaciones e identificar hipótesis, y posteriormente estas relaciones deben analizarse desde el punto de vista físico y del conocimiento del problema.

CORRELATION vs. CAUSATION

— They are **NOT** the same! —

WHAT IS CORRELATION?

Correlation measures the strength and direction of a relationship between two variables.



- ✓ Shows association
- ✗ Does **NOT** imply that one variable causes the other

WHAT IS CAUSATION?

Causation means one variable directly causes a change in another.

CAUSE

→

EFFECT

- ✓ Shows cause-and-effect relationship
- ✓ Requires strong evidence
- ✓ Cause must occur before the effect
- ✓ Other explanations must be ruled out

EXAMPLE (CORRELATION)



↔



Ice cream sales

Drowning incidents

Both increase in summer.
They are correlated because of **HOT WEATHER**, but ice cream does **NOT** cause drowning.

EXAMPLE (CAUSATION)



→



Regular exercise

Improved heart health

Exercise directly improves cardiovascular fitness.
(One variable causes a change in the other.)

KEY DIFFERENCES	
CORRELATION	CAUSATION
🔗	🎯
Shows an association between variables	Shows a cause-and-effect relationship
📊	🧪
Measured using correlation coefficient (r) (ranges from -1 to +1)	Established through experiments or strong causal analysis
❓	🛡️
Can be due to coincidence or a third variable	Requires evidence that rules out other explanations
≠	✓
Does NOT imply causation	Implies that one variable directly affects the other



IMPORTANT REMINDER

Correlation does **NOT** imply causation.

Always look for evidence before claiming a cause-and-effect relationship.




1.6.6 Visualización en el EDA

Entre las representaciones gráficas más utilizadas se encuentran:

1. **Histogramas.** Representan la distribución de frecuencia de una variable numérica, agrupando sus valores en intervalos. Permiten identificar rápidamente la forma de la distribución, su rango, dispersión, sesgo, presencia de múltiples modas y posibles valores extremos. Por ejemplo, pueden utilizarse para estudiar la distribución de la porosidad o permeabilidad de un yacimiento.
2. **Diagramas de caja.** Resumen la distribución mediante la mediana, los cuartiles y el rango intercuartílico (IQR). Son especialmente útiles para detectar valores atípicos y comparar la misma variable entre diferentes grupos. Por ejemplo, permiten comparar la distribución de permeabilidad entre diferentes facies o unidades geológicas.

3. **Diagramas de dispersión.** Representan pares de valores de dos variables numéricas para analizar su relación o asociación. Permiten observar correlaciones positivas o negativas, agrupamientos, relaciones no lineales y valores atípicos. Por ejemplo, un scatter plot de porosidad vs. permeabilidad permite analizar visualmente cómo se relacionan ambas propiedades petrofísicas.
4. **Gráficos de barras.** Se utilizan principalmente para comparar cantidades, frecuencias o proporciones entre categorías. A diferencia del histograma, donde las barras representan intervalos de una variable continua, cada barra representa una categoría independiente. En geociencias pueden utilizarse para comparar el número de muestras correspondientes a diferentes litologías, facies o formaciones
5. **Mapas de calor.** Utilizan una escala de colores para representar la magnitud de los valores dentro de una matriz. En EDA se emplean frecuentemente para visualizar matrices de correlación y detectar rápidamente variables con relaciones positivas, negativas o débiles. Son particularmente útiles cuando el dataset contiene muchas variables.
6. **Pairplots.** Permiten visualizar simultáneamente las relaciones entre múltiples variables. Generalmente muestran las distribuciones individuales en la diagonal y diagramas de dispersión para cada combinación de variables fuera de ella. Esto permite realizar una exploración multivariada rápida e identificar correlaciones, agrupamientos, outliers y posibles diferencias entre clases

Estas herramientas facilitan la identificación de patrones y anomalías.



¿Cuál utilizar?

No existe una única visualización adecuada para todo el EDA. Una secuencia práctica sería: histogramas y boxplots para comprender cada variable individualmente; scatter plots para analizar relaciones entre dos variables; gráficos de barras para variables categóricas; y finalmente heatmaps y pairplots para explorar conjuntamente múltiples variables.

La idea central es que visualizar los datos antes de modelarlos permite descubrir información que puede permanecer oculta al observar únicamente tablas o estadísticas descriptivas.

1.7 Feature selection

Los problemas actuales en geociencias e ingeniería de yacimientos involucran conjuntos de datos cada vez más grandes y diversos, integrando múltiples propiedades para describir un mismo sistema. En los enfoques tradicionales, la caracterización se realizaba principalmente mediante relaciones entre dos variables:

- Las facies se utilizaban para condicionar la distribución de la porosidad.
- Posteriormente, la permeabilidad podía modelarse considerando su relación con la porosidad.

De esta manera, las dependencias entre propiedades se incorporaban de forma secuencial. Los modelos modernos requieren una caracterización multivariada, donde numerosas propiedades deben analizarse de manera conjunta:

- Facies y propiedades petrofísicas.
- Propiedades geomecánicas y geofísicas.
- Información sísmica.
- Contenido de carbono orgánico total (TOC).
- Madurez térmica y otras propiedades geoquímicas.

Al aumentar el número de variables, también aumenta la dimensionalidad y complejidad del problema. Esto dificulta:

- La visualización e interpretación de los datos.
- La identificación de relaciones entre variables.
- El reconocimiento de patrones multidimensionales.
- La selección de las variables más relevantes.

Por esta razón, el análisis multivariado busca estudiar simultáneamente múltiples variables y sus interacciones, permitiendo obtener una representación más completa de sistemas geológicos complejos.

1.7.1 Dimensionalidad

La maldición de la dimensionalidad (curse of dimensionality) describe un conjunto de problemas que aparecen cuando aumenta considerablemente el número de variables o dimensiones utilizadas para representar los datos. A medida que se incorporan más variables, el espacio multidimensional crece rápidamente y los datos disponibles se vuelven cada vez más dispersos dentro de ese espacio.

Esto significa que agregar variables no siempre proporciona más información útil. Por el contrario, puede hacer que el análisis, la visualización y el desarrollo de modelos de Machine Learning sean considerablemente más difíciles.

¿Qué problemas genera?

1. Datos más dispersos: existen menos observaciones representativas de cada región del espacio multidimensional.
2. Mayor cantidad de datos requerida: se necesitan muchas más observaciones para caracterizar adecuadamente el problema.
3. Dificultad para visualizar: podemos representar fácilmente 2D o 3D, pero no visualizar directamente espacios con decenas de dimensiones.
4. Distancias menos informativas: en alta dimensionalidad, las diferencias entre observaciones "cercañas" y "lejanas" pueden perder poder discriminativo, afectando métodos basados en distancia como KNN o clustering.
5. Mayor riesgo de sobreajuste: un modelo puede encontrar relaciones aparentemente importantes que en realidad corresponden al ruido de los datos.
6. Mayor costo computacional: aumenta la memoria y el tiempo necesarios para procesar y modelar la información.

Ejemplo en caracterización de yacimientos: Consideremos inicialmente un análisis con únicamente:

Porosidad + Permeabilidad

Cada muestra puede representarse como un punto en un espacio 2D, por lo que es relativamente sencillo visualizar la relación entre ambas propiedades. Ahora incorporamos:

Porosidad + Permeabilidad + Saturación de agua

Tenemos un problema 3D, que todavía podemos visualizar. Sin embargo, un modelo integral podría incorporar:


Porosidad + Permeabilidad + Sw + Facies + Presión + TOC + Vsh + impedancia acústica + densidad + atributos sísmicos + ...

El problema puede pasar rápidamente de 2-3 dimensiones a decenas o cientos de dimensiones. Aunque tengamos muchos pozos o muestras, estos pueden representar únicamente una pequeña fracción de todas las combinaciones posibles de propiedades.

Ejemplo en Machine Learning

- Supongamos que tenemos 500 muestras y utilizamos 5 variables $\rightarrow$ 500 observaciones $\times$ 5 features. La cantidad de información puede ser razonable para ciertos modelos.
- Si aumentamos a 500 muestras $\times$ 200 features, tenemos muchas variables en relación con el número de observaciones. El modelo dispone de numerosas formas de ajustar los datos de entrenamiento, aumentando el riesgo de sobreajuste y una pobre capacidad de generalización.
- Por esta razón, en problemas de alta dimensionalidad suelen utilizarse estrategias como selección de variables (feature selection), ingeniería de características, regularización y reducción de dimensionalidad, mediante técnicas como PCA, autoencoders o métodos de selección basados en importancia de variables.

Idea clave: más variables no necesariamente significan más información. El objetivo es conservar aquellas dimensiones que contienen información relevante y reducir las que son redundantes, irrelevantes o dominadas por ruido.



1.7.2 Selección de features

1. Pairwise covariance (covarianza por pares)

La covarianza por pares es una medida estadística que describe cómo varían conjuntamente dos variables. Indica si los cambios en una variable tienden a estar asociados con incrementos o disminuciones en otra. En el análisis de variables, la covarianza puede calcularse entre cada variable predictora (feature) y la variable objetivo o respuesta (target) para identificar posibles relaciones lineales.

En un problema predictivo, como la estimación de la producción de hidrocarburos a partir de propiedades del yacimiento, la covarianza por pares proporciona un método inicial y sencillo para evaluar y ordenar las variables predictoras de acuerdo con su relación con la variable objetivo:

$$Y = f(X_1, X_2, X_3, \dots, X_n)$$

Por ejemplo, un objetivo puede ser el estimar la producción de hidrocarburos:

$$Oil = f(\phi, p, \mu_o, \dots, k)$$


Para cada variable predictora X_j , se calcula su covarianza con la variable objetivo Y :

$$C_{X_j Y} = \frac{\sum_{i=1}^n (X_{j,i} - \bar{X}_j)(Y_i - \bar{Y})}{(n-1)}$$

Interpretación

- Covarianza positiva: ambas variables tienden a cambiar en la misma dirección.
- Covarianza negativa: las variables tienden a cambiar en direcciones opuestas.

- Covarianza cercana a cero: indica poca o ninguna asociación lineal.
- Un valor mayor de $|\text{Cov}(X,Y)|$ indica una mayor variación conjunta, pero no necesariamente una relación más fuerte cuando las variables presentan diferentes escalas.



Consideración importante

La covarianza depende de las unidades, la escala y la varianza de ambas variables. Por esta razón, comparar directamente las covarianzas de variables predictoras expresadas en diferentes unidades puede producir interpretaciones incorrectas.

Por ejemplo, si se desea predecir la producción utilizando porosidad (%), permeabilidad (mD), presión (psi) y espesor (m), la presión podría presentar una covarianza mayor simplemente porque sus valores numéricos y su varianza son considerablemente mayores.

2. Pairwise correlation coefficient

El coeficiente de correlación por pares (Pairwise Correlation Coefficient) es una medida estadística que permite cuantificar la intensidad y dirección de la relación lineal entre cada variable predictor y una variable objetivo o respuesta. En problemas predictivos, puede utilizarse como un método sencillo para evaluar y ordenar las variables de acuerdo con su asociación lineal con la variable que se desea predecir.

A diferencia de la covarianza, el coeficiente de correlación normaliza la relación entre las variables utilizando sus desviaciones estándar, eliminando el efecto de sus unidades, escalas y niveles de dispersión:

$$\rho_{X_j Y} = \frac{C_{X_j Y}}{\sigma_{X_j} \sigma_Y}$$

Como resultado, el coeficiente siempre se encuentra entre -1 y $+1$, lo que facilita la comparación entre diferentes variables predictoras:

- $\rho \approx +1$: relación lineal positiva fuerte.
- $\rho \approx -1$: relación lineal negativa fuerte.
- $\rho \approx 0$: relación lineal débil o inexistente.
- Para ranking, un valor elevado de $|\rho|$ indica una mayor asociación lineal con la variable objetivo.

Idea clave: mientras que la covarianza depende de la escala y unidades de las variables, el coeficiente de correlación es una medida estandarizada, por lo que resulta más apropiado para comparar y ordenar variables predictoras expresadas en diferentes unidades.

3. Rank correlation coefficient

El coeficiente de correlación por rangos (Rank Correlation Coefficient) es una medida estadística que permite evaluar la intensidad y dirección de una relación monótonica entre una variable predictora y una variable objetivo. A diferencia de la correlación de Pearson, no requiere que la relación entre las variables sea estrictamente lineal.

Antes de calcular la correlación, se aplica una transformación por rangos (rank transform), en la cual los valores originales de cada variable son reemplazados por su posición o rango dentro del conjunto de datos. Posteriormente, la correlación se calcula utilizando estos rangos en lugar de los valores originales. En el caso del coeficiente de correlación de Spearman, puede expresarse como:

$$\rho_{R_{X_j} R_Y} = \frac{\sum_{i=1}^n (R_{X_{ji}} - \bar{R}_{X_j})(R_{Yi} - \bar{R}_Y)}{(n-1)\sigma_{R_{X_j}}\sigma_{R_Y}}$$


4. Partial correlation coefficient

5. Mutual information

1.7.3 Feature Engineering

El Feature Engineering o ingeniería de características es el proceso mediante el cual las variables originales de un conjunto de datos son seleccionadas, transformadas, combinadas o reformuladas para generar representaciones que describan de manera más efectiva el problema que se desea modelar. Su objetivo no consiste simplemente en reducir el número de variables, sino en proporcionar al algoritmo información más relevante, compacta y representativa del fenómeno físico.


Esta estrategia es particularmente importante frente a la curse of dimensionality o maldición de la dimensionalidad. Cuando aumenta el número de variables de entrada, el espacio de características crece rápidamente y los datos disponibles se vuelven relativamente más dispersos. Como consecuencia, un modelo puede requerir una cantidad mucho mayor de observaciones para aprender relaciones confiables, además de incrementar el costo computacional y el riesgo de sobreajuste.



1.7.4 Dimensionality reduction

La reducción de dimensionalidad (Dimensionality Reduction) comprende un conjunto de técnicas que buscan representar un dataset con un menor número de variables, tratando de conservar la mayor cantidad posible de información relevante. Cuando un dataset contiene muchas variables, no necesariamente todas proporcionan información independiente. Algunas pueden ser redundantes, altamente correlacionadas, poco informativas o contener principalmente ruido. Reducir la dimensionalidad puede ayudar a:

- Mitigar la curse of dimensionality.
- Reducir redundancia entre variables.
- Disminuir el costo computacional y requerimientos de memoria.
- Facilitar el entrenamiento de modelos de Machine Learning.
- Reducir el riesgo de overfitting, particularmente cuando existen muchas variables y pocas observaciones.
- Facilitar la visualización de datos complejos en dos o tres dimensiones.
- En algunos casos, eliminar parcialmente ruido conservando las estructuras dominantes



1.8 Data Splitting

Una vez que los datos han sido revisados, limpiados y preparados, uno de los pasos fundamentales para desarrollar un modelo de machine learning es la división del conjunto de datos (data splitting). Este procedimiento consiste en separar las observaciones disponibles en subconjuntos independientes que cumplen diferentes funciones durante el desarrollo y evaluación del modelo. El objetivo principal es determinar qué tan bien el modelo puede generalizar hacia datos que no fueron utilizados durante su entrenamiento. Si el desempeño se evalúa utilizando los mismos datos con los que se ajustó el modelo, las métricas obtenidas pueden ser excesivamente optimistas y no representar su comportamiento ante nuevas observaciones. Generalmente, los datos se dividen en tres conjuntos.

1.8.1 Conjuntos de datos

- **Conjunto de entrenamiento (training set).** Es el subconjunto utilizado directamente para ajustar los parámetros del modelo. Durante esta etapa, el algoritmo identifica patrones y relaciones entre las variables de entrada y la variable objetivo.

Normalmente constituye la mayor proporción de los datos disponibles. Una división común puede asignar entre 60 y 80 % de las observaciones al entrenamiento, aunque la proporción adecuada depende del tamaño y características del conjunto de datos.

En modelos de deep learning, por ejemplo, este conjunto es utilizado repetidamente durante diferentes épocas (epochs) para actualizar los pesos de la red neuronal y minimizar la función de pérdida.


- **Conjunto de validación (validation set).** Se utiliza durante el desarrollo del modelo para evaluar diferentes configuraciones y seleccionar aquellas que proporcionan un mejor desempeño. A diferencia del conjunto de entrenamiento, estos datos no se utilizan directamente para ajustar los parámetros internos del modelo. El conjunto de validación permite seleccionar hiperparámetros como la profundidad de un árbol, el número de estimadores, la tasa de aprendizaje (learning rate), el grado de regularización o la arquitectura de una red neuronal. También permite detectar sobreajuste (overfitting). Si el error de entrenamiento continúa disminuyendo mientras que el error de validación comienza a aumentar, el modelo probablemente está aprendiendo características demasiado específicas del conjunto de entrenamiento.

- **Conjunto de prueba (test set).** El conjunto de prueba se reserva para realizar la evaluación final del modelo. Debe permanecer independiente durante las etapas de entrenamiento, selección de hiperparámetros y comparación de configuraciones. Su propósito es simular el comportamiento del modelo ante datos completamente nuevos. Por ello, utilizar repetidamente el conjunto de prueba para modificar el modelo puede producir fuga de información (data leakage), haciendo que deje de funcionar como una evaluación verdaderamente independiente.

Una división típica podría ser:

80 % entrenamiento – 10 % validación – 10 % prueba

Sin embargo, no existe una proporción universal. Con conjuntos de datos pequeños puede ser preferible utilizar validación cruzada, mientras que con bases de datos muy grandes puede ser suficiente reservar porcentajes menores para validación y prueba.



1.8.2 Métodos de división de datos

Existen diferentes estrategias de data splitting. La selección depende de la estructura de los datos y del problema que se pretende resolver.

- **División aleatoria (Random Split).** Es uno de los procedimientos más sencillos. Las observaciones se mezclan aleatoriamente y posteriormente se asignan a los conjuntos de entrenamiento, validación y prueba. Es apropiado cuando las observaciones pueden considerarse aproximadamente independientes e idénticamente distribuidas. Sin embargo, debe utilizarse con precaución en problemas geoespaciales o temporales, donde observaciones cercanas pueden presentar una fuerte dependencia. Por ejemplo, si muestras provenientes de posiciones muy cercanas de un mismo pozo aparecen simultáneamente en entrenamiento y prueba, el desempeño obtenido puede ser artificialmente alto.


- **División estratificada (Stratified Split).** La división estratificada busca mantener aproximadamente la misma proporción de determinadas categorías en cada subconjunto. Es particularmente útil en problemas de clasificación con clases desbalanceadas. Por ejemplo, si solamente el 10 % de las muestras corresponde a una determinada litología, una división completamente aleatoria podría generar conjuntos con proporciones considerablemente diferentes. La estratificación permite conservar una representación similar de cada clase en entrenamiento, validación y prueba.

- **Validación cruzada (K-Fold Cross-Validation).** En K-fold cross-validation, los datos se dividen en K subconjuntos o folds. El modelo se entrena utilizando K-1 subconjuntos y se evalúa utilizando el restante. El proceso se repite hasta que cada subconjunto haya sido utilizado una vez para validación. Por ejemplo, con 5-fold cross-validation, el modelo se entrena y evalúa cinco veces. El desempeño final puede expresarse mediante el promedio y la variabilidad de las métricas obtenidas. Este método permite utilizar eficientemente los datos disponibles y proporciona una estimación más robusta del desempeño, especialmente cuando el conjunto de datos es relativamente pequeño.

• **División espacial (Spatial Split).** En aplicaciones geocientíficas, la dependencia espacial representa un desafío adicional. Dos muestras cercanas pueden tener propiedades similares debido a la autocorrelación espacial. Si se distribuyen aleatoriamente entre entrenamiento y prueba, el modelo puede aparentemente obtener una excelente capacidad predictiva simplemente porque las observaciones de prueba son muy similares a las utilizadas durante el entrenamiento. Una alternativa consiste en dividir los datos mediante regiones, bloques espaciales, pozos, campos o unidades geológicas, reservando regiones completas para validación o prueba.

DATA SPLITTING METHODS

Different strategies to split a dataset into training, validation and test sets.



1.9 Feature transformation

La transformación de variables comprende un conjunto de técnicas utilizadas para modificar la escala, rango o distribución de las variables originales antes de realizar un análisis estadístico o entrenar un modelo de Machine Learning. Estas transformaciones pueden reducir la influencia de valores extremos, corregir diferencias sistemáticas entre conjuntos de datos y evitar que variables con magnitudes numéricas grandes tengan una influencia desproporcionada sobre determinados algoritmos.

La transformación adecuada de los features puede mejorar la estabilidad numérica, comparabilidad entre variables, convergencia del entrenamiento y desempeño de los modelos, especialmente en métodos sensibles a la escala o a las distancias entre observaciones.


1.9.1 Truncamiento de variables (Feature Truncation)

El truncamiento consiste en establecer límites inferiores y/o superiores para una variable, reemplazando los valores que exceden dichos límites por el valor límite correspondiente. Por ejemplo, si se establece:

$$X_{min} = 10$$

$$X_{max} = 100$$

$$X' = \begin{cases} 10 & X < 10 \\ X & 10 \leq X \leq 100 \\ 100 & X > 100 \end{cases}$$



Sus principales características son:

1. Reduce la influencia de valores extremos.
2. Puede utilizarse cuando existen límites físicos conocidos para una propiedad.
3. Evita que observaciones excepcionalmente grandes o pequeñas dominen el análisis.
4. No elimina necesariamente las observaciones; modifica los valores que exceden los límites.
5. Los límites pueden definirse mediante conocimiento físico, percentiles u otros criterios estadísticos.

Por ejemplo, valores extremadamente altos de permeabilidad podrían truncarse cuando se considera que representan anomalías o tienen una influencia excesiva sobre el modelo.

1.9.2 Transformación Afín (Affine correction)

Una transformación afín modifica una variable mediante una combinación de escalamiento y desplazamiento:

$$X' = aX + b$$


donde a controla el cambio de escala y b representa un desplazamiento.

Esta transformación permite ajustar sistemáticamente una variable sin modificar la estructura relativa básica de sus observaciones. Puede utilizarse, por ejemplo, para corregir diferencias de escala o sesgos sistemáticos entre mediciones provenientes de diferentes fuentes o instrumentos. Ejemplo:

$$X' = 1.1X - 2$$

En este caso, todos los valores son escalados por 1.1 y posteriormente desplazados en -2 unidades. Una alternativa más utilizada es:

$$X' = \frac{\sigma_{X'}}{\sigma_X}(X - \bar{X}) + \bar{X}'$$



Idea importante: tanto la estandarización como la normalización Min-Max pueden considerarse casos particulares de transformaciones afines cuando sus parámetros se calculan a partir de estadísticas fijas del conjunto de datos.

1.9.3 Estandarización (Standardization)

La estandarización, también conocida como Z-score normalization, transforma los valores utilizando la media y la desviación estándar de la variable:

$$Z = \frac{X - \mu_X}{\sigma_X}$$

donde:

μ = media de la variable.

σ = desviación estándar.

Después de la transformación, utilizando los mismos datos para estimar μ y σ , la variable tendrá aproximadamente:

$$\mu_Z = 0$$

$$\sigma_Z = 1$$

Por ejemplo, si:

$$X = 250$$

$$\mu = 200$$


$$\sigma = 25$$

entonces:

$$Z = \frac{250-200}{25} = 2$$

Esto significa que la observación se encuentra dos desviaciones estándar por encima de la media. La estandarización:

1. Centra los datos alrededor de cero.
2. Elimina las diferencias de escala entre variables.
3. No restringe los datos a un intervalo específico.
4. Es especialmente útil para métodos sensibles a la escala, como PCA, SVM, KNN, regresiones regularizadas y redes neuronales.



1.9.4 Normalización Min-Max (Min-Max Normalization)

La normalización Min-Max transforma una variable a un intervalo previamente definido, comúnmente:

$$[0, 1]$$

La transformación se realiza mediante:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

De esta forma:

$$X_{min} \rightarrow 0$$

$$X_{max} \rightarrow 1$$

Por ejemplo, si una propiedad presenta:

$$X_{min} = 100$$


$$X_{max} = 500$$

para una observación $X=300$:

$$X' = \frac{300-100}{500-100} = 0.5$$

Sus principales características son:

1. Coloca diferentes variables en una escala común.
2. Conserva el orden relativo de las observaciones.
3. Mantiene los valores dentro de un intervalo conocido para los datos usados al ajustar la transformación.
4. Es útil para numerosos algoritmos de Machine Learning y redes neuronales.
5. Es sensible a valores extremos, porque X_{min} y X_{max} dependen directamente de ellos.



Diferencia entre estandarización y Min-Max

La estandarización expresa cada observación en términos de su distancia respecto a la media medida en desviaciones estándar y no establece límites fijos. En cambio, la normalización Min-Max reescala los datos directamente a un intervalo determinado, normalmente $[0,1]$.

En Machine Learning, un aspecto fundamental es que los parámetros de estas transformaciones, por ejemplo, μ , σ , X_{min} , y X_{max} , deben calcularse únicamente con los datos de entrenamiento y posteriormente aplicarse sin recalcularlos a los conjuntos de validación y prueba. Esto evita data leakage.