Temas Selectos de Ingeniería Petrolera

16 de octubre de 2026

Moisés Velasco Lozano

PhD

Profesor

Universidad Nacional Autónoma de México

Faculty Research Guest

Los Alamos National Laboratory

Índice

1 Machine Learning **4**
1.1 Fundamentos . . . 4
1.2 Entrenamiento del modelo . . . 4
1.2.1 Evaluación de la precisión del modelo (Assessing Model Accuracy) . . . 5
1.2.2 Underfitting . . . 6
1.2.3 Overfitting . . . 6
1.2.4 Curvas de entrenamiento y validación . . . 7
1.2.5 Cross-validation plots . . . 7
1.2.6 Hiperparámetros (Hyperparameters) . . . 9
1.2.7 Ajuste de hiperparámetros (Hyperparameter Tuning) . . . 10
1.3 Métodos de Machine Learning . . . 12
1.4 Métodos de aprendizaje supervisado . . . 13
1.4.1 Linear Regression . . . 14
1.4.2 Ridge Regression . . . 16
1.4.3 Polynomial regression . . . 20

4 Machine Learning en Geociencias

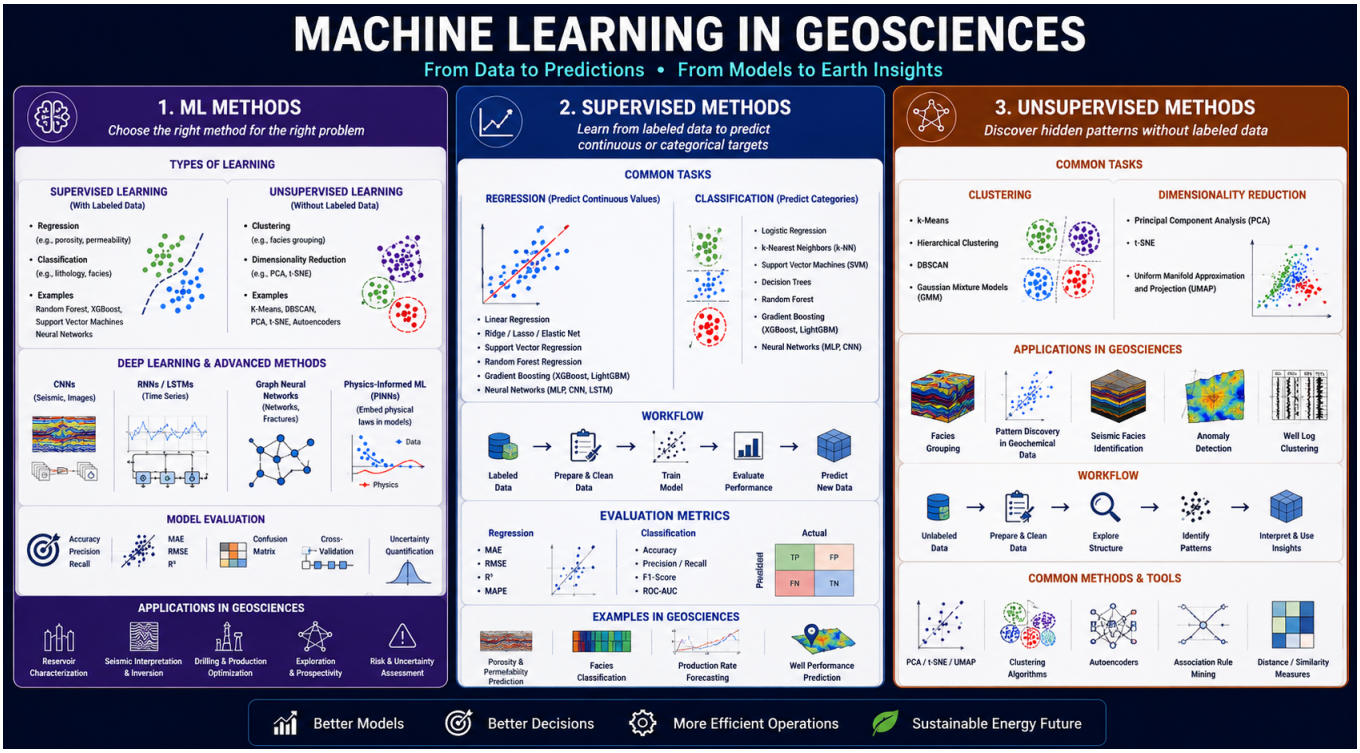

1 Machine Learning

La Inteligencia Artificial (IA) es un campo amplio de la computación cuyo objetivo es desarrollar sistemas capaces de realizar tareas que normalmente requieren algún grado de inteligencia humana, como razonar, tomar decisiones, reconocer patrones, comprender lenguaje o resolver problemas.

El Machine Learning (ML) es una rama de la Inteligencia Artificial enfocada en desarrollar algoritmos que pueden aprender patrones y relaciones directamente a partir de los datos, y utilizar ese aprendizaje para realizar predicciones, clasificaciones o identificar estructuras.

El Machine Learning (ML) comprende un conjunto de métodos computacionales capaces de identificar patrones, relaciones y estructuras a partir de los datos, permitiendo desarrollar modelos descriptivos y predictivos sin definir explícitamente todas las relaciones que gobiernan el sistema.

En esta sección se abordarán algunos de los principales métodos de Machine Learning y su aplicación en geociencias y sistemas energéticos del subsuelo, donde existe una gran cantidad de información geológica, petrofísica, geofísica y de producción. Los métodos se agruparán en tres áreas principales: clustering, para identificar grupos o estructuras naturales en los datos; regresión, para predecir variables continuas; y clasificación, para asignar observaciones a diferentes categorías o clases.

Estas herramientas permiten abordar problemas como la identificación de facies, caracterización de yacimientos, predicción de propiedades petrofísicas, clasificación de litologías y análisis de datos de producción, entre otras aplicaciones.

1.1 Fundamentos

El objetivo de machine learning es estimar el modelo f para realizar una predicción

- **Variables independientes** (predictor features): Información de entrada
- **Variables dependientes** (response features): Información de salida

El objetivo de machine learning es estimar el modelo f para realizar una predicción

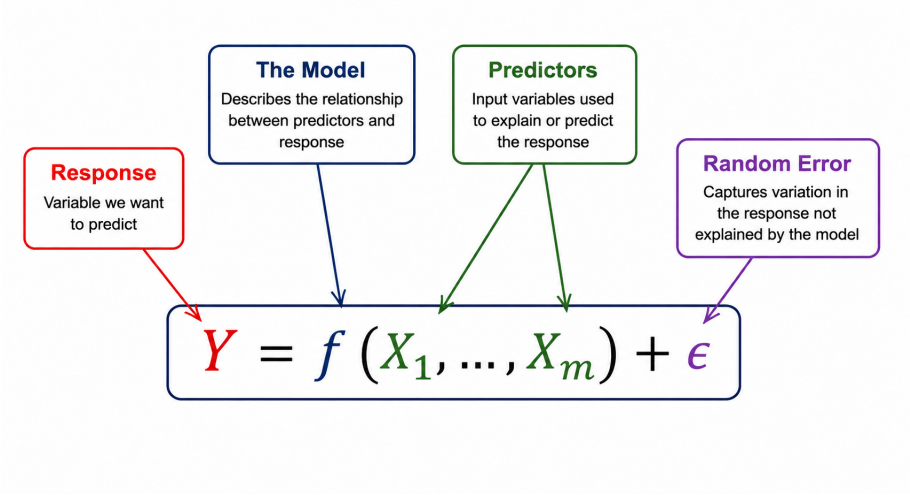

1.2 Entrenamiento del modelo

Una vez definidos los conjuntos de entrenamiento, validación y prueba, es necesario determinar si el modelo está aprendiendo correctamente los patrones presentes en los datos y, principalmente, si es capaz de generalizar hacia observaciones que no fueron utilizadas durante el entrenamiento. Un buen desempeño sobre los datos de entrenamiento no garantiza que el modelo produzca predicciones confiables sobre nuevos datos.

La evaluación del entrenamiento debe realizarse de manera continua durante el desarrollo del modelo. Para ello, se comparan las métricas obtenidas en entrenamiento y validación, se analiza la complejidad del modelo, se ajustan

sus hiperparámetros y, cuando es apropiado, se utilizan técnicas como validación cruzada (cross-validation). Este análisis permite identificar dos problemas fundamentales: underfitting y overfitting.

1.2.1 Evaluación de la precisión del modelo (Assessing Model Accuracy)

Una vez entrenado un modelo de machine learning, es necesario determinar qué tan bien reproduce los datos observados y qué tan confiables son sus predicciones. Este proceso se conoce como Assessing Model Accuracy y consiste en utilizar métricas cuantitativas para comparar los valores predichos por el modelo con los valores reales.

En problemas de regresión, donde la variable objetivo es continua (por ejemplo, porosidad, permeabilidad, saturación de agua, presión o producción), la evaluación se basa principalmente en los residuales o errores de predicción:

$$e_i = y_i - \hat{y}_i$$

donde $y_i$representa el valor observado y $\hat{y}_i$ el valor estimado. Un modelo adecuado debería producir errores relativamente pequeños y sin patrones sistemáticos. Una función de pérdida (loss function) cuantifica qué tan diferentes son las predicciones generadas por un modelo respecto a los valores reales. Durante el entrenamiento, el algoritmo busca modificar sus parámetros para minimizar esta función, por lo que la elección de la función de pérdida influye directamente en qué tipo de errores aprende a evitar el modelo. Funciones de pérdida utilizadas en el entrenamiento de modelos de machine learning:

- **Mean Absolute Error (MAE)**

El MAE representa el promedio del valor absoluto de los errores:

$$MAE = \frac{1}{n}\sum |y_i - \hat{y}_i|$$

Es fácil de interpretar porque conserva las mismas unidades de la variable objetivo. Además, es menos sensible a errores extremos que el MSE.

- **Mean Squared Error (MSE)**

El MSE proporciona mayor penalización a predicciones con errores grandes debido al término cuadrático. Es ampliamente utilizado tanto como métrica de evaluación como función de pérdida durante el entrenamiento de modelos de regresión.

$$MSE = \frac{1}{n}\sum (y_i - \hat{y}_i)^2$$

Una desventaja es que sus unidades corresponden al cuadrado de las unidades originales, lo que puede dificultar su interpretación física.

- **Root Mean Squared Error (RMSE)**

El RMSE corresponde a la raíz cuadrada del MSE:

$$RMSE = \sqrt{\frac{1}{n}\sum (y_i - \hat{y}_i)^2}$$

Su principal ventaja es que recupera las unidades originales de la variable objetivo, facilitando la interpretación. Al igual que el MSE, penaliza considerablemente los errores grandes.

COMPARACIÓN DE LAS PRINCIPALES MÉTRICAS DE EVALUACIÓN

Regresión (variable objetivo continua)

MÉTRICA	FÓRMULA	INTERPRETACIÓN	MEJOR VALOR	UNIDADES	CARACTERÍSTICAS PRINCIPALES	SENSIBILIDAD A OUTLIERS	RANGO TÍPICO
MAE (Mean Absolute Error)	$MAE = \frac{1}{n}\sum_{i=1}^{n}\lvert y_i - \hat{y}_i\rvert$	Promedio de la magnitud absoluta de los errores. Mide, en promedio, cuánto se desvían las predicciones de los valores reales.	0 (más cercano a 0, mejor)	Las mismas unidades de la variable objetivo (ej. mD, psi, %)	• Fácil de interpreter • Menos penalización a errores grandes • Robusta y estable	Baja	[0, ∞) Valores más cercanos a 0 son mejores
MSE (Mean Squared Error)	$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$	Promedio de los errores al cuadrado. Penaliza fuertemente los errores grandes.	0 (más cercano a 0, mejor)	Cuadrado de las unidades de la variable objetivo (ej. mD^2, psi^2)	• Muy utilizada como función de pérdida • Penaliza fuertemente errores grandes	Alta	[0, ∞) Valores más cercanos a 0 son mejores
RMSE (Root Mean Squared Error)	$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$	Raíz cuadrada del MSE. Conserva las unidades originales y penaliza errores grandes.	0 (más cercano a 0, mejor)	Las mismas unidades de la variable objetivo (ej. mD, psi, %)	• Fácil de interpretar • Penaliza fuertemente errores grandes • Muy usada en geociencias	Alta	[0, ∞) Valores más cercanos a 0 son mejores
R^2 (Coeficiente de Determinación)	$R^2 = 1 - \frac{\sum_{i=1}(y_i - \hat{y}_i)^2}{\sum_{i=1}(y_i - \bar{y})^2}$	Proporción de la variabilidad de los datos explicada por el modelo. Compara el modelo con usar la media como predicción.	1 (más cercano a 1, mejor)	Adimensional (sin unidades)	• Mide ajuste global • Puede ser negativo si el modelo es peor que usar la media	Media	(−∞, 1] Ideal cercano a 1; puede ser negativo
MAPE (Mean Absolute Percentage Error)	$MAPE = \frac{100}{n}\sum_{i=1}^{n}\left\lvert\frac{y_i - \hat{y}_i}{y_i}\right\rvert$	Error absoluto promedio expresado en porcentaje respecto al valor real.	0 % (más cercano a 0 %, mejor)	Porcentaje (%)	• Intuitivo y fácil de comunicar • Útil para comparar entre diferentes escalas	Alta (problemas si y_i es cercano a 0)	[0, ∞) % Valores más cercanos a 0 % son mejores

NOTA IMPORTANTE: Ninguna métrica debe interpretarse de forma aislada. Es recomendable analizar varias métricas en conjunto y complementarlas con gráficos (observado vs. predicho, residuales) y validación en datos no vistos.

1.2.2 Underfitting

El underfitting ocurre cuando el modelo es demasiado simple para representar adecuadamente las relaciones presentes en los datos. En esta situación, el modelo presenta un desempeño deficiente tanto en los datos de entrenamiento como en los de validación.

Por ejemplo, intentar representar mediante una regresión lineal una relación fuertemente no lineal puede producir underfitting. El modelo no posee suficiente flexibilidad para capturar la estructura de los datos.

Generalmente se observa:

Error de entrenamiento alto + error de validación alto

Este comportamiento se asocia con alto sesgo (high bias). Algunas alternativas para reducirlo incluyen aumentar la complejidad del modelo, incorporar variables relevantes, utilizar transformaciones de las variables, reducir una regularización excesiva o utilizar algoritmos capaces de representar relaciones más complejas.

1.2.3 Overfitting

El overfitting ocurre cuando el modelo aprende excesivamente las particularidades de los datos de entrenamiento, incluyendo ruido, anomalías y patrones que no son representativos del fenómeno general.

En este caso, el modelo puede presentar un error extremadamente bajo durante el entrenamiento, pero un error considerablemente mayor cuando se aplica a los datos de validación o prueba:

Error de entrenamiento muy bajo + error de validación significativamente mayor

El modelo presenta entonces alta varianza (high variance) y una capacidad limitada para generalizar.

El overfitting puede ser particularmente importante cuando se utilizan modelos muy complejos con conjuntos de datos relativamente pequeños. Algunas estrategias para reducirlo incluyen regularización, reducción de la complejidad del modelo, selección de variables, early stopping, dropout en redes neuronales, incorporación de más datos y validación cruzada.

1.2.4 Curvas de entrenamiento y validación

Una herramienta particularmente útil consiste en representar gráficamente la evolución del training loss y validation loss durante el entrenamiento.

En un entrenamiento adecuado, ambas pérdidas (loss functions) deberían disminuir inicialmente y eventualmente estabilizarse en valores relativamente bajos. No es necesario que sean idénticas; normalmente existe una pequeña diferencia entre ambas.

Una señal clásica de overfitting ocurre cuando:

$$Loss_{train} \downarrow \quad \text{mientras que} \quad Loss_{validation} \uparrow$$

Es decir, el modelo continúa mejorando sobre los datos de entrenamiento mientras comienza a empeorar sobre datos independientes.

En redes neuronales, este comportamiento permite utilizar early stopping: el entrenamiento se detiene cuando la pérdida de validación deja de mejorar durante determinado número de épocas.

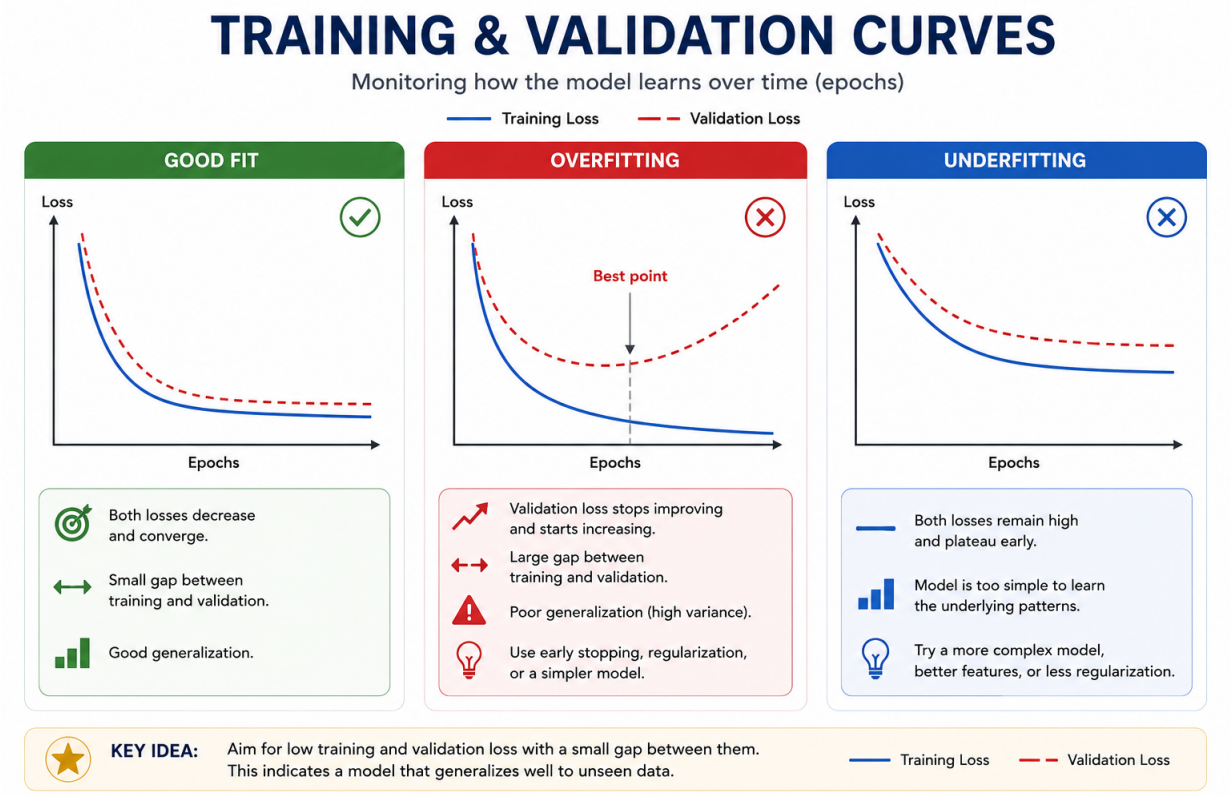

1.2.5 Cross-validation plots

Los cross-validation plots permiten visualizar el comportamiento del modelo entre los diferentes folds y son útiles para evaluar su estabilidad. Pueden mostrar métricas como $R2$, MAE, RMSE, accuracy, precision o recall para cada partición. Un modelo robusto debería presentar valores relativamente consistentes entre los diferentes folds. Una variabilidad elevada puede indicar que el desempeño depende fuertemente de qué observaciones se utilizan para entrenamiento y validación. Otra representación muy útil es la validation curve, donde se analiza cómo cambia el desempeño de entrenamiento y validación al modificar un hiperparámetro que controla la complejidad del modelo.

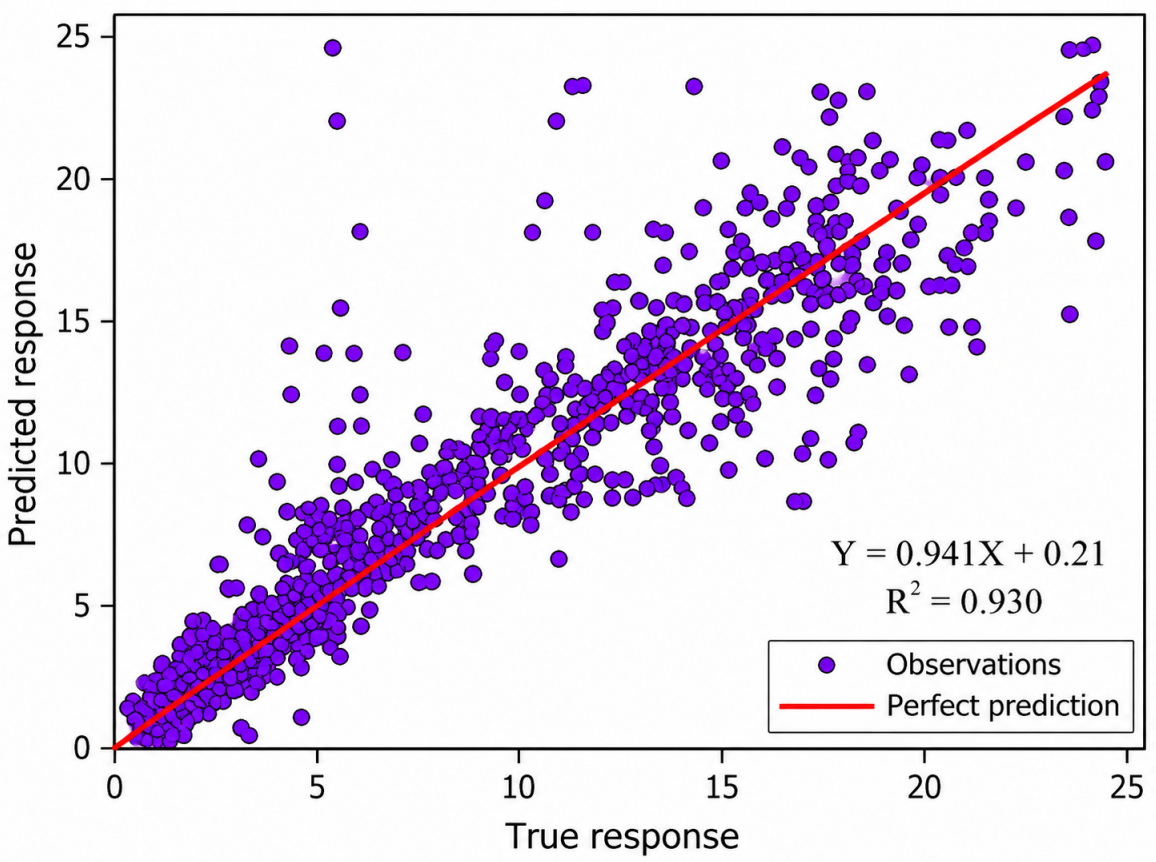

En aplicaciones de geociencias, un buen resultado de cross-validation debe interpretarse con especial cuidado debido a la autocorrelación espacial. Si muestras espacialmente cercanas aparecen simultáneamente en entrenamiento y validación, las métricas pueden ser artificialmente optimistas.

Por ejemplo, obtener $R2$ =0.95 mediante random K-fold cross-validation no necesariamente significa que el modelo tendrá el mismo desempeño al predecir una región completamente nueva. Cuando el objetivo es realizar predicciones en nuevos pozos, bloques o regiones, resulta recomendable utilizar estrategias como Spatial Cross-Validation, Group K-Fold o Leave-One-Well-Out. De esta manera, la evaluación reproduce mejor las condiciones reales bajo las cuales se utilizará posteriormente el modelo.

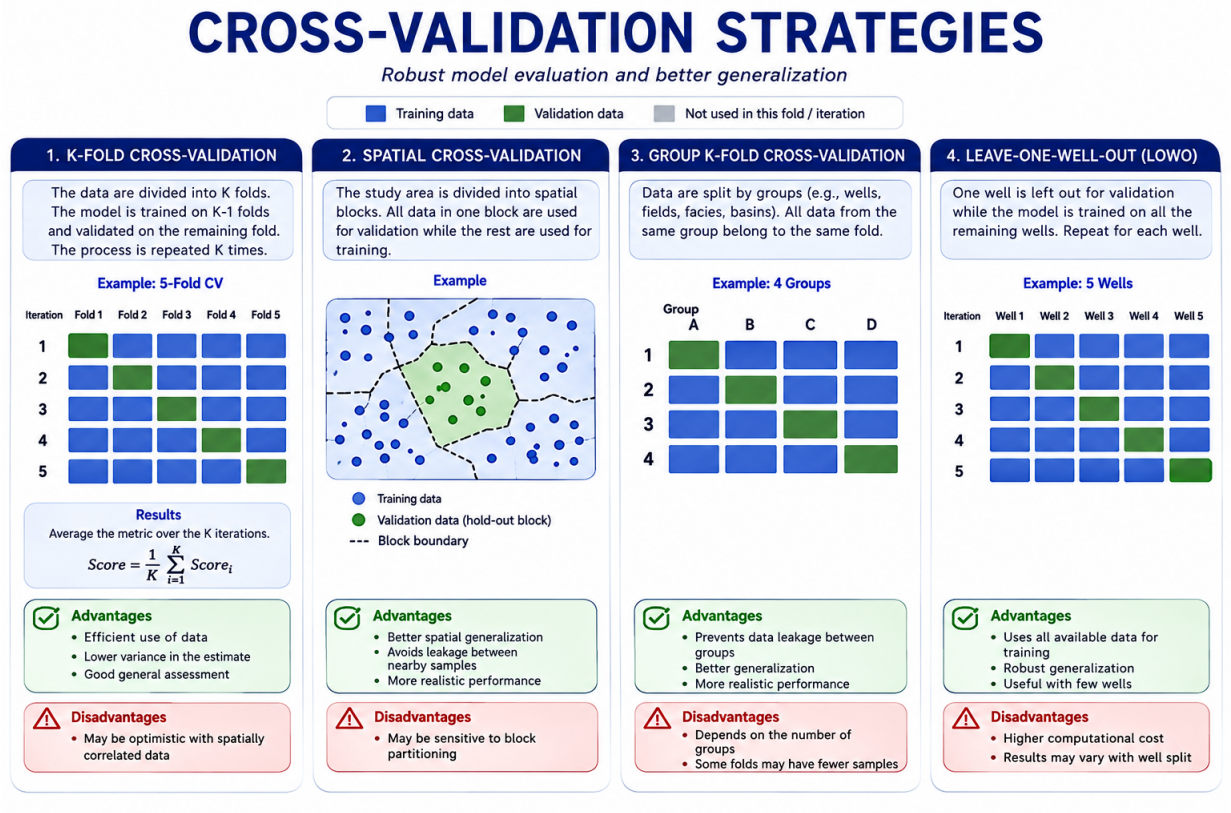

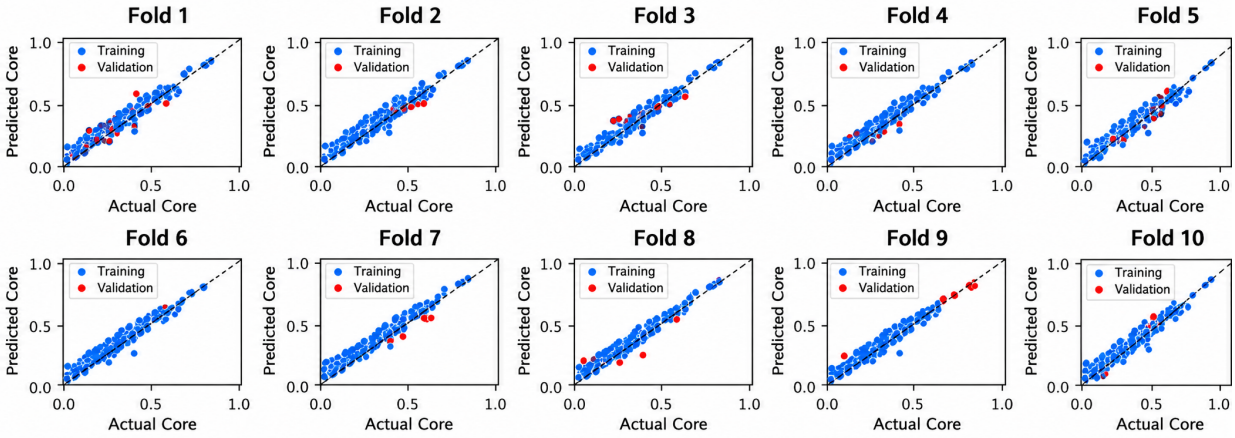

1.2.6 Hiperparámetros (Hyperparameters)

Los hiperparámetros son configuraciones del algoritmo que no son aprendidas directamente a partir de los datos, sino que deben establecerse antes o durante el proceso de entrenamiento. Estos controlan aspectos como la complejidad del modelo, la intensidad de la regularización o la manera en que ocurre el aprendizaje. Los hiperparámetros dependen del algoritmo utilizado. Algunos ejemplos son:

- número máximo de niveles de un árbol de decisión;
- número de árboles en Random Forest;

- número de vecinos k en K-Nearest Neighbors;
- parámetros de regularización en Ridge o Lasso;
- learning rate, batch size y número de épocas en redes neuronales;
- número de capas, neuronas, filtros o tamaño de los kernels en deep learning.

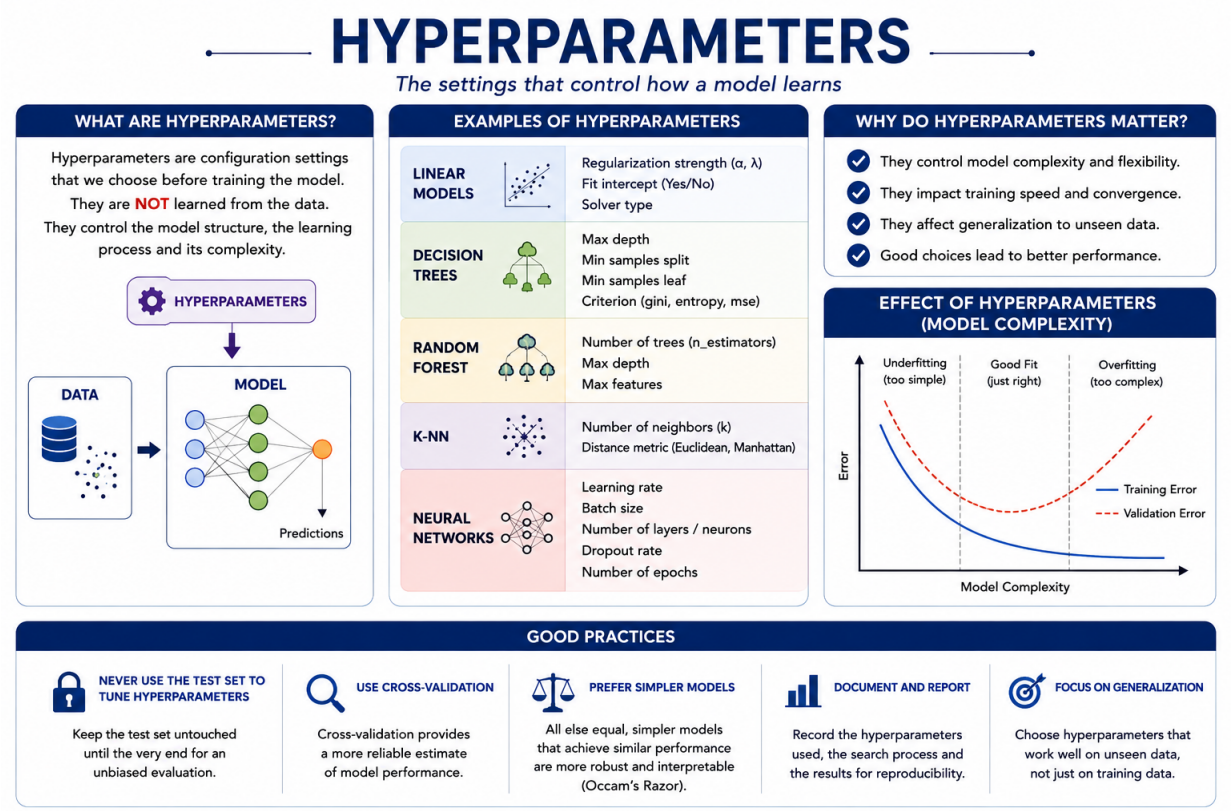

La selección de hiperparámetros debe realizarse utilizando el conjunto de validación o mediante cross-validation, y no con el conjunto de prueba. Algunas estrategias comunes son Grid Search, Random Search y métodos de optimización Bayesiana. El objetivo no es necesariamente encontrar la configuración que produzca el menor error de entrenamiento, sino aquella que presente el mejor desempeño sobre datos no utilizados para ajustar los parámetros del modelo.

1.2.7 Ajuste de hiperparámetros (Hyperparameter Tuning)

Una vez seleccionado un algoritmo, es necesario determinar la configuración de hiperparámetros que permita obtener el mejor desempeño posible. Este proceso se conoce como hyperparameter tuning y consiste en explorar diferentes combinaciones de valores para identificar aquellas que permiten al modelo generalizar adecuadamente a datos no observados. A diferencia de los parámetros internos del modelo, que se estiman durante el entrenamiento, los hiperparámetros son definidos externamente. Por ejemplo, en un Random Forest pueden ajustarse el número de árboles y su profundidad máxima; mientras que en una red neuronal pueden modificarse el learning rate, batch size, número de capas, número de neuronas y regularización.

El objetivo del hyperparameter tuning no es minimizar el error de entrenamiento, sino encontrar la configuración que produzca el mejor desempeño de validación. Para ello, las diferentes configuraciones deben compararse utilizando un conjunto de validación o, preferentemente, cross-validation. El conjunto de prueba debe mantenerse independiente durante todo este proceso. Existen diferentes estrategias para realizar esta búsqueda.

- **Grid Search** es uno de los métodos más sencillos. Consiste en definir previamente un conjunto de valores posibles para cada hiperparámetro y evaluar todas las combinaciones posibles.
- **Random Search** selecciona aleatoriamente combinaciones de hiperparámetros dentro de rangos o distribuciones previamente definidos. En lugar de evaluar todas las combinaciones posibles, se establece un número determinado de configuraciones que serán exploradas.
- **La optimización Bayesiana (Bayesian Optimization)** utiliza los resultados obtenidos en evaluaciones anteriores para decidir qué combinación de hiperparámetros debería evaluarse posteriormente. A diferencia de Grid Search y Random Search, donde cada configuración se selecciona sin utilizar directamente la información de las evaluaciones anteriores, la optimización Bayesiana construye un modelo aproximado de la relación hiperparametros-validación.

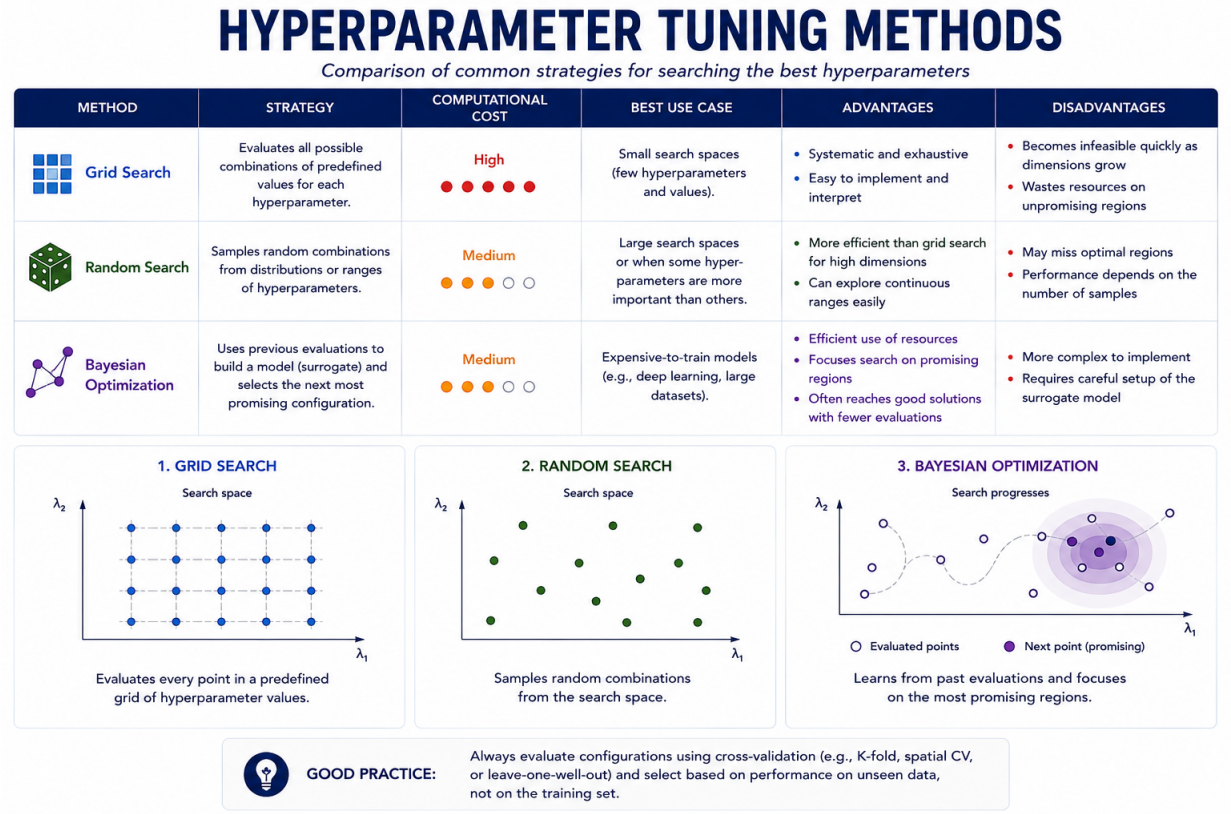

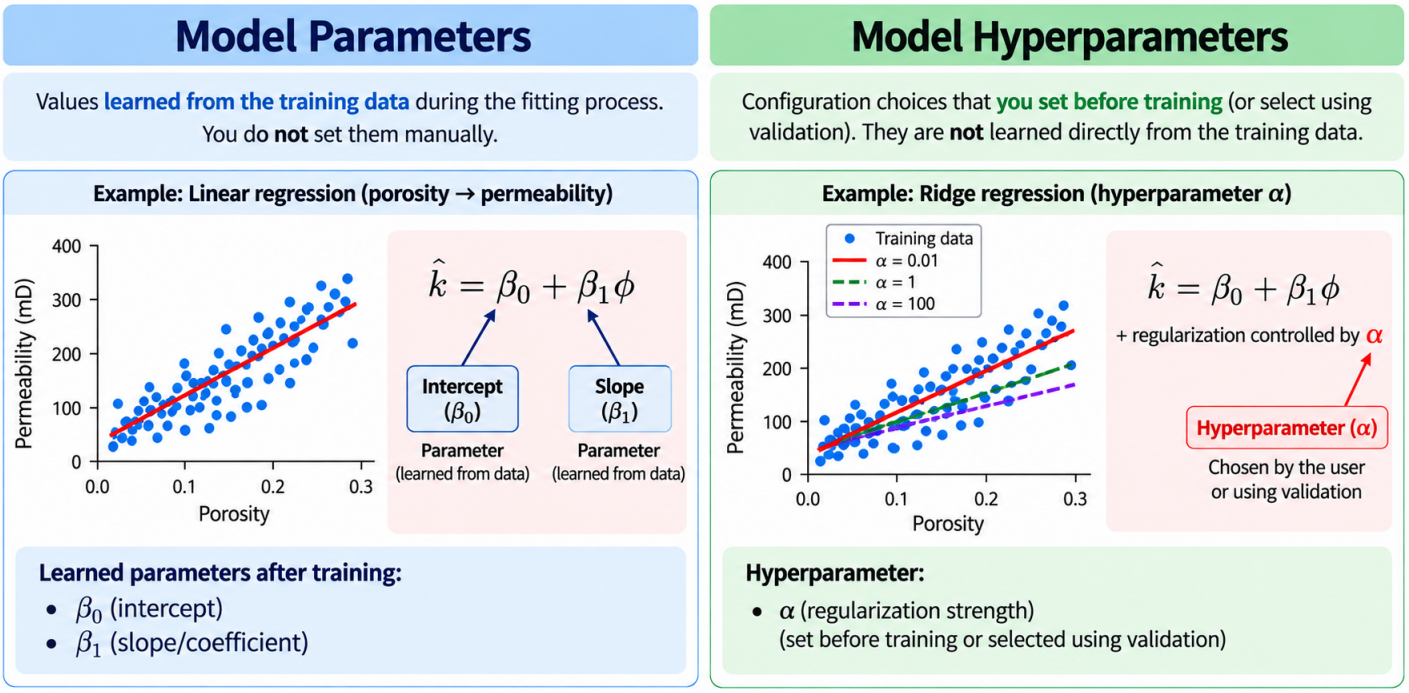

1.3 Métodos de Machine Learning

Los métodos de Machine Learning (ML) pueden clasificarse de acuerdo con la forma en que los algoritmos utilizan los datos durante el proceso de aprendizaje. La principal diferencia radica en si los datos contienen una variable objetivo conocida (label o target), si el algoritmo debe descubrir estructuras por sí mismo o si aprende mediante la interacción con un entorno.

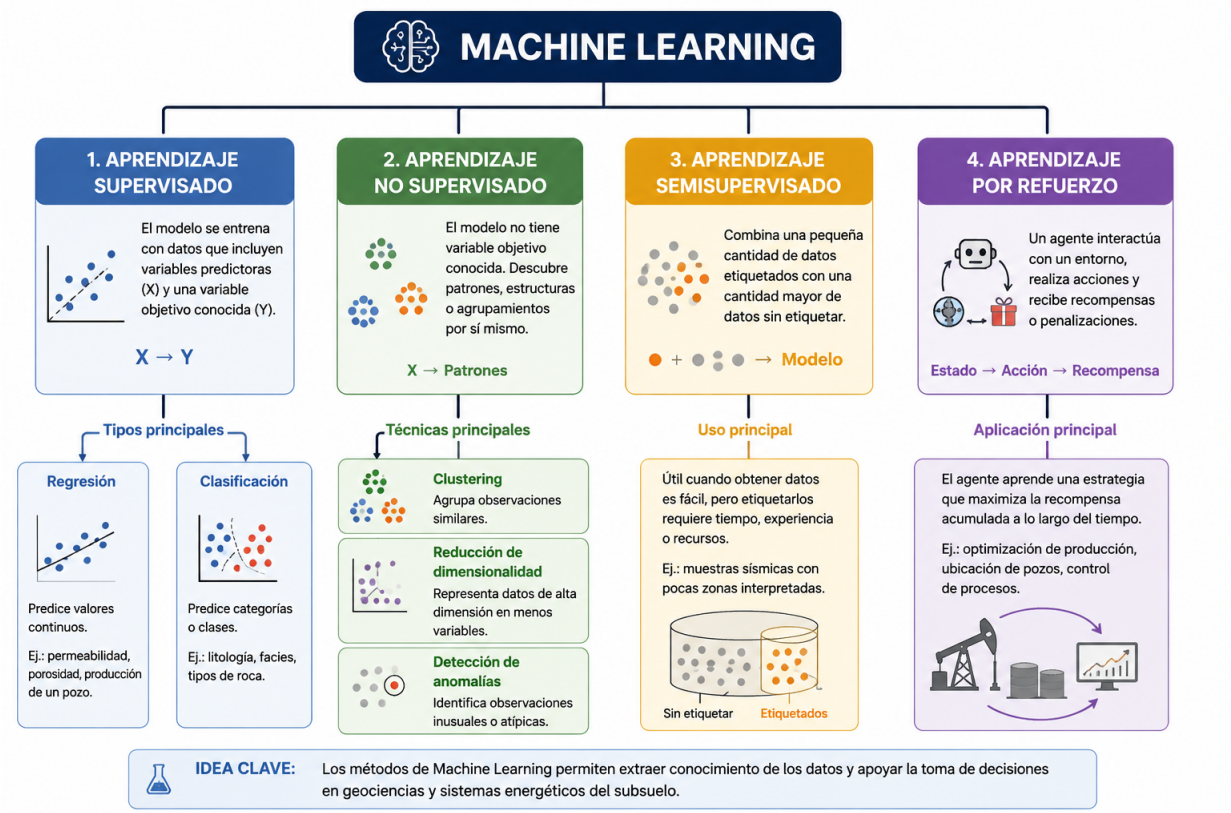

Figura 1: Ecuación de estado de gases reales

1.4 Métodos de aprendizaje supervisado

En el aprendizaje supervisado, el modelo se entrena utilizando ejemplos para los cuales se conoce tanto la información de entrada como la respuesta correcta. El objetivo es aprender una relación entre las variables predictoras X y la variable objetivo Y, para posteriormente realizar predicciones sobre nuevos datos.

Durante el entrenamiento, el modelo compara sus predicciones con los valores reales y ajusta sus parámetros para reducir el error de predicción.

$$X \longrightarrow Y$$

Los problemas supervisados se dividen principalmente en:

1. **Regresión**: cuando Y es una variable numérica continua. Por ejemplo, predecir porosidad, permeabilidad, presión o producción.
2. **Clasificación**: cuando Y representa una categoría o clase. Por ejemplo, identificar facies, litologías o tipos de roca.

Entre los algoritmos utilizados se encuentran regresión lineal y logística, KNN, árboles de decisión, Random Forest, Support Vector Machines (SVM), Gradient Boosting y redes neuronales.

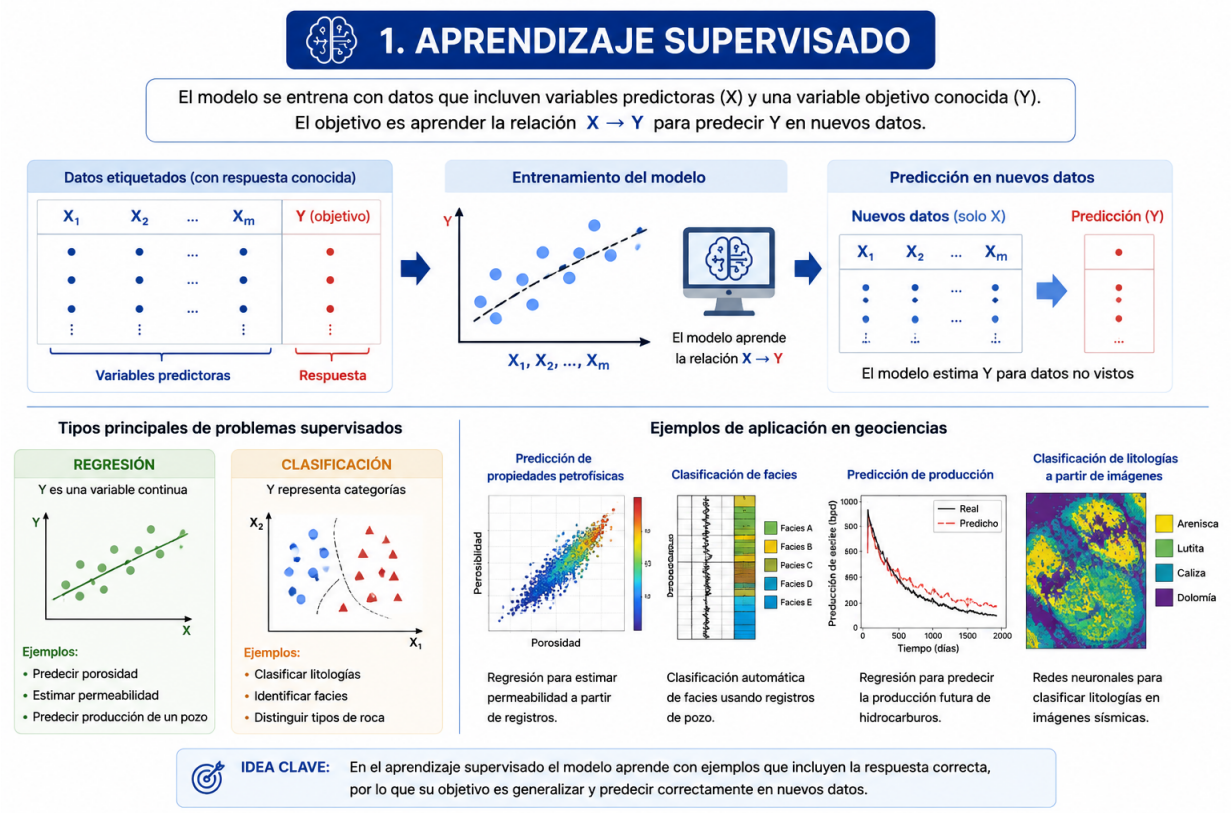

Figura 2: Ecuación de estado de gases reales

Idea clave: el modelo aprende utilizando ejemplos que incluyen la respuesta que se desea predecir.

1.4.1 Linear Regression

La regresión lineal es uno de los métodos fundamentales del aprendizaje supervisado y constituye una excelente introducción a los modelos predictivos de Machine Learning. Su objetivo es modelar la relación entre una variable objetivo continua Y y una o más variables predictoras X mediante una relación lineal.

A partir de observaciones donde conocemos tanto las variables de entrada como la respuesta, el modelo aprende los parámetros que mejor describen esta relación. Una vez entrenado, puede utilizarse para estimar el valor de Y para nuevas observaciones.

Por ejemplo, en geociencias podemos utilizar la porosidad como variable predictora x para estimar la permeabilidad y.

Cuando se utiliza una sola variable predictora, el modelo puede representarse como:

$$\hat{y} = xb_1 + b_0$$

donde:
x: variable predictora o feature.
y: valor real de la variable objetivo.
$\hat{y}$: valor predicho por el modelo.
b_0: intercepto de la recta.
b_1: pendiente o coeficiente de regresión.

El coeficiente $b_1$representa cuánto se espera que cambie y por cada unidad de incremento en x. Por ejemplo, si $b_1 > 0$, la respuesta aumenta conforme aumenta el predictor.

Sin embargo, en los modelos se tiene una diferencia entre los valores reales y los valores predecidos, es decir se tiene un residuo:

$$\Delta y_i = y_i - \hat{y}_i$$

Los residuos permiten cuantificar los errores que comete el modelo. Cuanto menores sean, mejor será el ajuste de la línea a los datos, aunque un buen ajuste en entrenamiento no garantiza por sí solo una buena generalización.

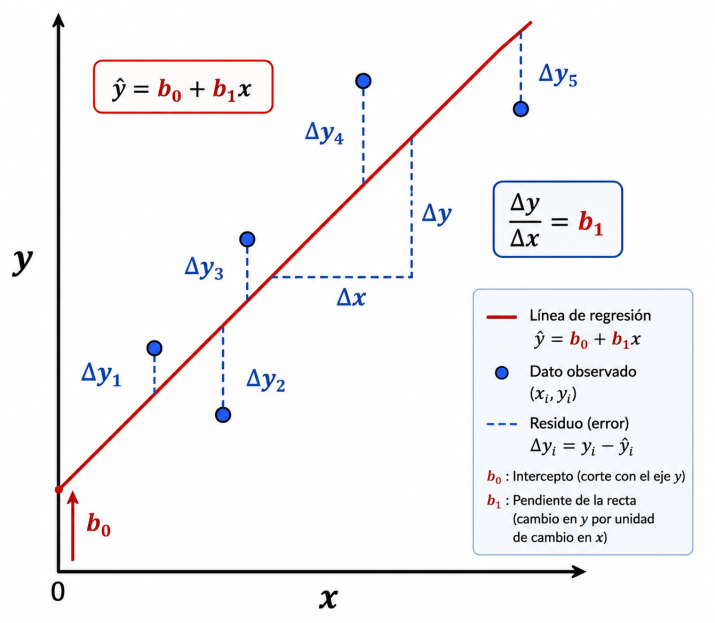

El método más común es Mínimos Cuadrados Ordinarios (Ordinary Least Squares, OLS). El objetivo es encontrar b_1 y b_o que minimicen la suma de los errores al cuadrado:

$$OLS = \sum (y_i - \hat{y}_i)^2$$

El objetivo es minimizar esta diferencia pero para la totalidad de los valores en el modelo:

$$\sum (\Delta y_i)^2 = \sum [y_i - (x_i b_1 + b_0)]^2$$

En general esto se denomina la función de pérdida (**loss function**).

En el caso que se tengan múltiples predictors, el modelo se expresa:

$$\hat{y} = b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_m X_m$$

donde la función de pérdida es:

$$\sum (\Delta y_i)^2 = \sum_i [y_i - (\sum_j x_{i,j} b_j + b_0)]^2$$

Ejemplo en geociencias. Supongamos que queremos predecir la producción:

$$Q = f(\phi, k, h, p, Sw, Vsh, TOC, \ldots)$$

Sin embargo, existe una limitación con la aplicación de la regresión lineal ya que algunas de estas propiedades pueden estar correlacionadas. Por ejemplo, ciertos registros de pozo pueden proporcionar información parcialmente redundante sobre la litología o la porosidad.

Una regresión lineal convencional podría asignar coeficientes muy grandes y opuestos a variables correlacionadas. Ridge estabiliza estos coeficientes, distribuyendo de manera más controlada su influencia sobre la predicción.

1.4.2 Ridge Regression

La regresión Ridge es una extensión de la regresión lineal que incorpora un término de regularización para controlar la magnitud de los coeficientes del modelo. Su principal objetivo es obtener modelos más estables y con mejor capacidad de generalización, especialmente cuando existen muchas variables predictoras o cuando algunas de ellas están fuertemente correlacionadas.

En una regresión lineal múltiple tenemos:

$$\hat{y} = \sum b_j X_j + b_0$$

$$\hat{y} = b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_m X_m$$

Ridge agrega una penalización sobre el tamaño de los coeficientes:

$$Loss_{Ridge} = \sum (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1} b_j^2$$

Generalmente el intercepto b_0 no se penaliza por lo que se tiene:

$$Loss_{Ridge} = \sum_i [y_i - (\sum_j x_{i,j} b_j + b_0)]^2 + \lambda \sum_{j=1} b_j^2$$

El segundo término se conoce como **penalización L2**. Aquí:

- b_j son los coeficientes asociados con las variables predictoras.
- λ es el parámetro de regularización.
- Valores grandes de b_j producen una penalización mayor.
- Normalmente, el intercepto b_0 no se penaliza.

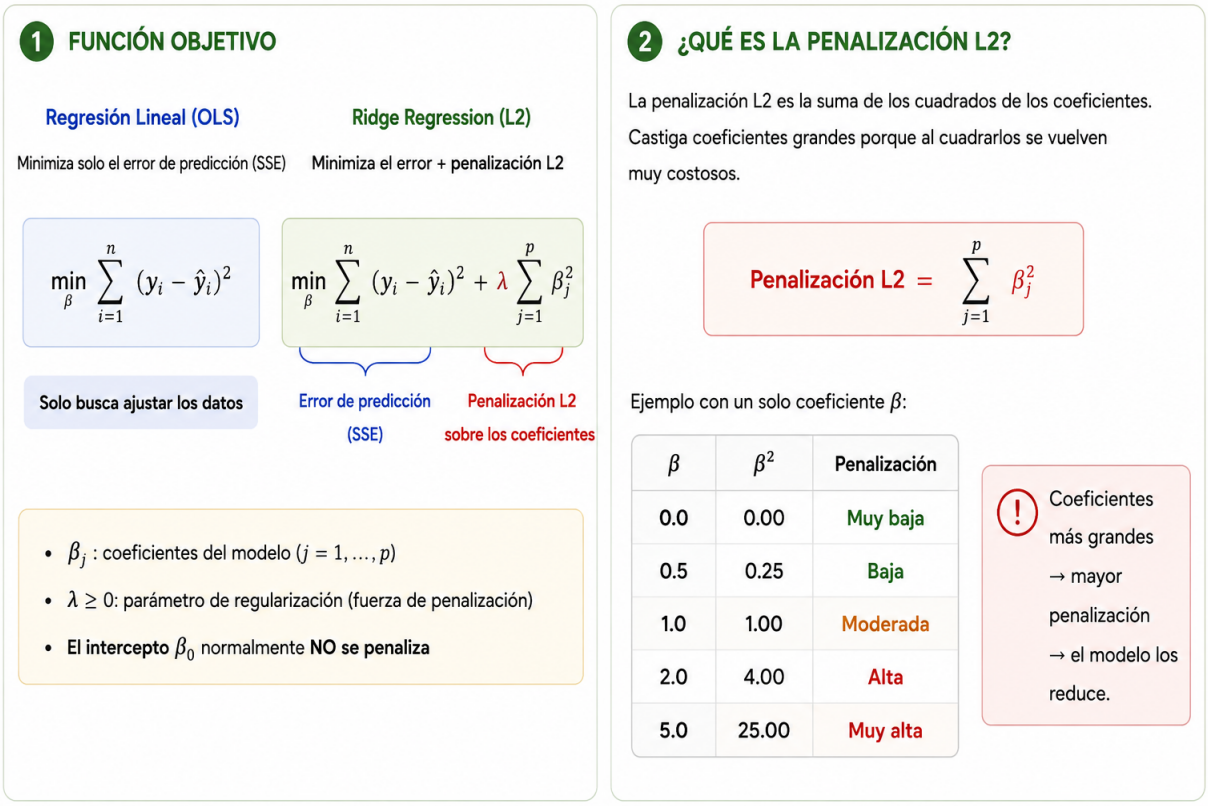

Figura 3: Ecuación de estado de gases reales

El parámetro λ controla el equilibrio entre ajustarse a los datos de entrenamiento y mantener pequeños los coeficientes.

Si:

$$\lambda = 0$$

no existe penalización y Ridge se reduce esencialmente a una regresión lineal ordinaria.
Si:

$$\lambda \uparrow$$

aumenta la penalización y los coeficientes son progresivamente reducidos hacia cero:

$$| b_j | \downarrow$$

Sin embargo, una característica importante de Ridge es que generalmente reduce los coeficientes sin llevarlos exactamente a cero.

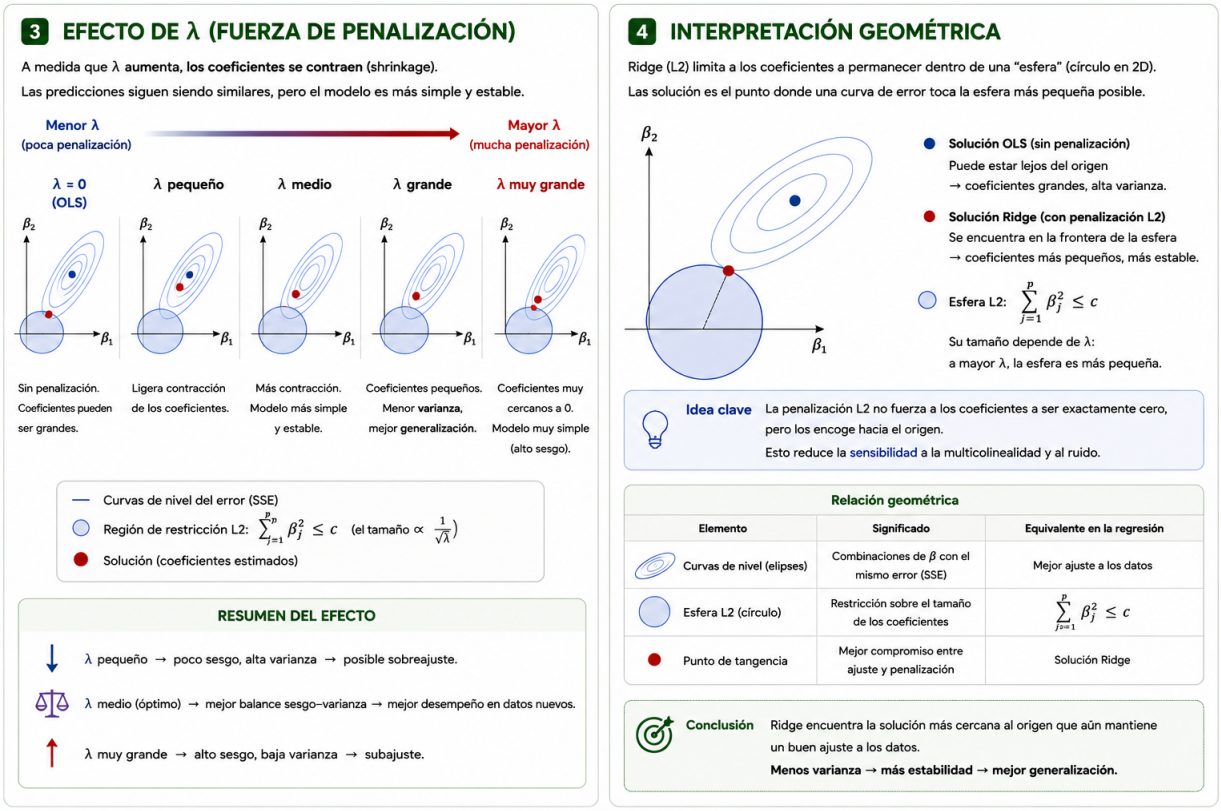

Figura 4: Ecuación de estado de gases reales

¿Por qué reducir los coeficientes?

Cuando un modelo tiene muchas variables o existen predictores altamente correlacionados, la regresión lineal puede producir coeficientes muy grandes e inestables. Pequeños cambios en los datos pueden entonces generar cambios importantes en el modelo.

Ridge introduce deliberadamente un poco de sesgo (bias) a cambio de reducir la varianza (variance) del modelo. Este compromiso se conoce como **Bias–Variance Tradeoff** y puede mejorar el desempeño sobre datos nuevos.

Variables correlacionadas

Supongamos que queremos predecir la producción de un pozo q utilizando diferentes propiedades del yacimiento:

$$q = b_0 + b_1\phi + b_2k + b_3h + b_4p + b_5S_w + b_6V_{sh} + b_7TOC + \epsilon$$

En un problema real de geociencias, estas variables no necesariamente proporcionan información completamente independiente. Algunas pueden estar fuertemente relacionadas entre sí.

Por ejemplo, podríamos tener dos registros de pozo:

$$X_1 = \text{registro de densidad}$$

$$X_2 = \text{registro neutrón}$$

Ambos contienen información relacionada con la porosidad de la formación. Por lo tanto, pueden presentar una correlación considerable:

$$X_1 \longleftrightarrow X_2$$

El problema es que el modelo recibe dos variables que explican parcialmente la misma información.

Regresión lineal

Supongamos que el modelo obtiene:

$$q = 100 + 25X_1 - 23X_2 + \cdots$$

Los coeficientes $+25$ y -23 son relativamente grandes y de signo contrario.

¿Por qué puede suceder esto?

Como X_1 y X_2contienen información similar, existen diferentes combinaciones de sus coeficientes capaces de producir predicciones parecidas. El modelo puede compensar un coeficiente con el otro:

$$25X_1 - 23X_2$$

Si las dos variables presentan valores similares, gran parte de estos términos puede cancelarse.

Esto puede producir un modelo que predice razonablemente bien los datos de entrenamiento, pero cuyos coeficientes son muy sensibles a pequeñas modificaciones en los datos.

Por ejemplo, utilizando otro conjunto de muestras podríamos obtener:

$$q = 100 + 18X_1 - 16X_2 + \cdots$$

o incluso:

$$q = 100 - 10X_1 + 12X_2 + \cdots$$

Aunque las predicciones globales podrían seguir siendo similares, la interpretación de los coeficientes cambia considerablemente. Este problema está relacionado con la **multicolinealidad**.

Ridge regression

Ridge modifica el problema de optimización agregando una penalización a coeficientes grandes:

$$Loss = OLS + \lambda(b_1^2 + b_2^2 + \cdots + b_m^2)$$

Ahora el modelo no solamente busca:

"¿Qué coeficientes producen el menor error?"

También considera:

"¿Puedo obtener un error similar utilizando coeficientes más pequeños?"

Por ejemplo, en lugar de:

$$25X_1 - 23X_2$$

Ridge podría favorecer una solución más estable como:

$$4.2X_1 + 3.8X_2$$

Ridge tiende a reducir la magnitud de los coeficientes y, ante predictores correlacionados, suele repartir la influencia entre ellos de forma más estable. Sin embargo, no garantiza que todos adopten el mismo signo. La Figura muestra una comparación de los coeficientes con cada unos los esquemas y la elección del hyperparametro λ.

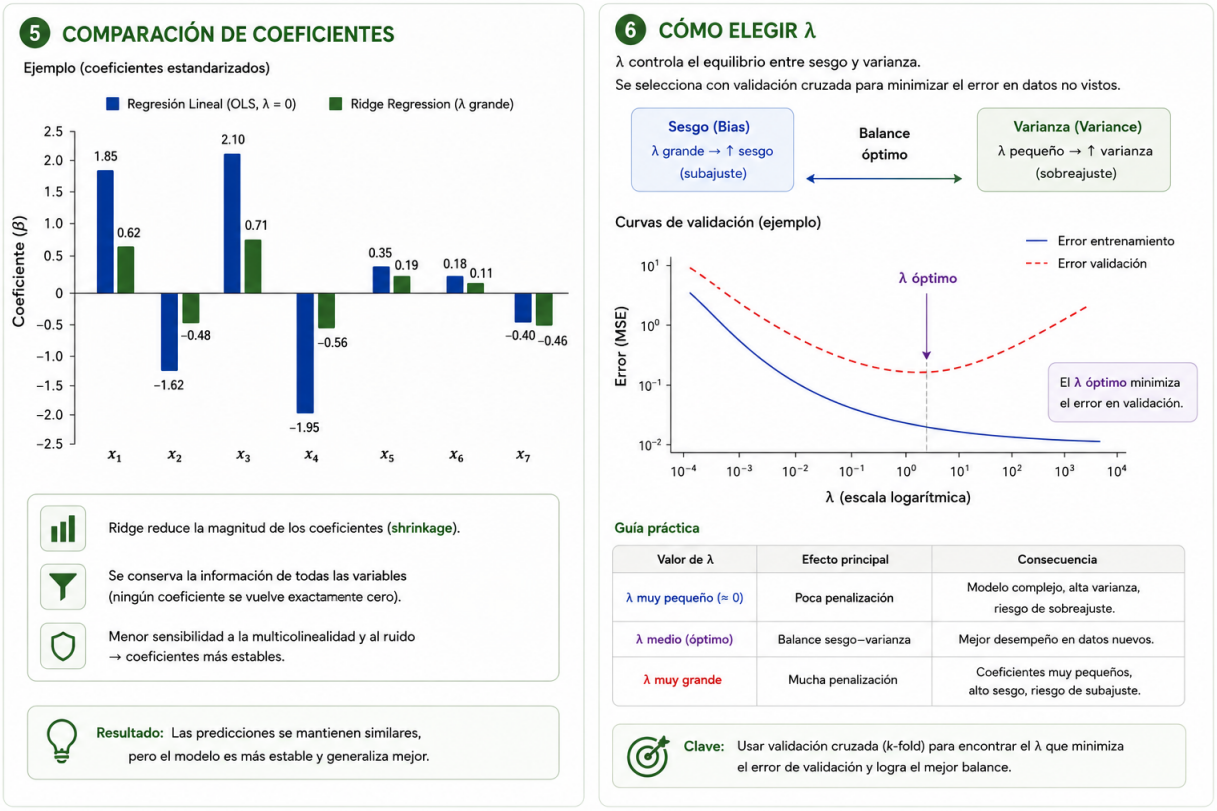

Figura 5: Ecuación de estado de gases reales

Comparación de los métodos de regresión lineal y regresión Ridge

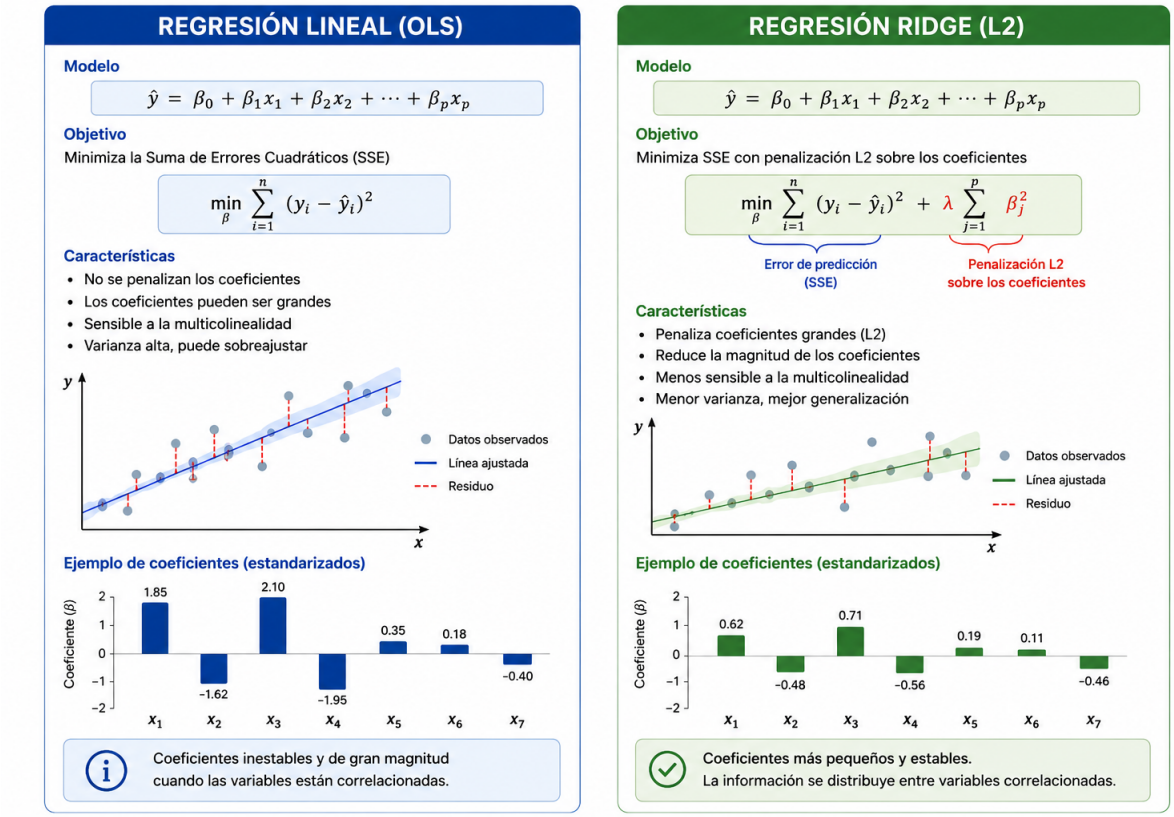

Figura 6: Ecuación de estado de gases reales

1.4.3 Polynomial regression

Para nuestro modelo de regresión lineal tenemos:

$$\hat{y} = \sum b_j X_j + b_0$$

Para el caso de regresión polinomial tenemos:

$$\hat{y} = \sum_l \sum_j b_{j,l} h_l(X_j) + b_0$$

donde:

$$h_1 = X$$

$$h_2 = X^2$$

$$h_3 = X^3$$

Ejemplo: Orden 2 ($l = 2$) y 1 feature ($j = 1$)

$$\hat{y} = b_{1,1} h_1(X_1) + b_{1,2} h_2(X_1) + b_0$$

por ejemplo para orden 3 ($l = 3$) y 3 features ($j = 3$) tenemos:

$$\hat{y} = b_o + b_{1,1}h_1(X_1) + b_{2,1}h_1(X_2) + b_{3,1}h_1(X_3) + b_{1,2}h_2(X_1) + b_{2,2}h_2(X_2) + b_{3,2}h_2(X_3) + b_{1,3}h_3(X_1) + b_{2,3}h_3(X_2) + b_{3,3}h_3(X_3)$$

en términos simples:

$$\hat{y} = b_0 + b_{1,1}X_{1,1} + b_{2,1}X_{1,2} + b_{3,1}X_{1,3} + b_{1,2}X_{2,1}^2 + b_{2,2}X_{2,2}^2 + b_{3,2}X_{3,2}^2 + b_{1,3}X_{3,1}^3 + b_{2,3}X_{3,2}^3 + b_{3,3}X_{3,3}^3$$

en forma reducida se tiene:

$$\hat{y} = \sum_{l,j} b_{j,l} h_l(X_j) + b_0$$