

Temas Selectos de Ingeniería Petrolera

21 de septiembre de 2026

Moisés Velasco Lozano

PhD

PROFESOR

Universidad Nacional Autónoma de México


FACULTY RESEARCH GUEST

Los Alamos National Laboratory

Índice

1	Machine Learning	4
1.1	Fundamentos	4
1.2	Entrenamiento del modelo	4
1.2.1	Hiperparámetros (Hyperparameters)	5
1.2.2	Evaluación de la precisión del modelo (Assessing Model Accuracy)	6
1.2.3	Underfitting	7
1.2.4	Overfitting	7
1.2.5	Curvas de entrenamiento y validación	8

4 Machine Learning en Geociencias



1 Machine Learning

La Inteligencia Artificial (IA) es un campo amplio de la computación cuyo objetivo es desarrollar sistemas capaces de realizar tareas que normalmente requieren algún grado de inteligencia humana, como razonar, tomar decisiones, reconocer patrones, comprender lenguaje o resolver problemas.

El Machine Learning (ML) es una rama de la Inteligencia Artificial enfocada en desarrollar algoritmos que pueden aprender patrones y relaciones directamente a partir de los datos, y utilizar ese aprendizaje para realizar predicciones, clasificaciones o identificar estructuras.

El Machine Learning (ML) comprende un conjunto de métodos computacionales capaces de identificar patrones, relaciones y estructuras a partir de los datos, permitiendo desarrollar modelos descriptivos y predictivos sin definir explícitamente todas las relaciones que gobiernan el sistema.

En esta sección se abordarán algunos de los principales métodos de Machine Learning y su aplicación en geociencias y sistemas energéticos del subsuelo, donde existe una gran cantidad de información geológica, petrofísica, geofísica y de producción. Los métodos se agruparán en tres áreas principales: clustering, para identificar grupos o estructuras naturales en los datos; regresión, para predecir variables continuas; y clasificación, para asignar observaciones a diferentes categorías o clases.


Estas herramientas permiten abordar problemas como la identificación de facies, caracterización de yacimientos, predicción de propiedades petrofísicas, clasificación de litologías y análisis de datos de producción, entre otras aplicaciones.

1.1 Fundamentos

El objetivo de machine learning es estimar el modelo f para realizar una predicción

- **Variables independientes** (predictor features): Información de entrada
- **Variables dependientes** (response features): Información de salida

El objetivo de machine learning es estimar el modelo f para realizar una predicción



1.2 Entrenamiento del modelo

Una vez definidos los conjuntos de entrenamiento, validación y prueba, es necesario determinar si el modelo está aprendiendo correctamente los patrones presentes en los datos y, principalmente, si es capaz de generalizar hacia observaciones que no fueron utilizadas durante el entrenamiento. Un buen desempeño sobre los datos de entrenamiento no garantiza que el modelo produzca predicciones confiables sobre nuevos datos.


La evaluación del entrenamiento debe realizarse de manera continua durante el desarrollo del modelo. Para ello, se comparan las métricas obtenidas en entrenamiento y validación, se analiza la complejidad del modelo, se ajustan

sus hiperparámetros y, cuando es apropiado, se utilizan técnicas como validación cruzada (cross-validation). Este análisis permite identificar dos problemas fundamentales: underfitting y overfitting.

1.2.1 Hiperparámetros (Hyperparameters)

Los hiperparámetros son configuraciones del algoritmo que no son aprendidas directamente a partir de los datos, sino que deben establecerse antes o durante el proceso de entrenamiento. Estos controlan aspectos como la complejidad del modelo, la intensidad de la regularización o la manera en que ocurre el aprendizaje. Los hiperparámetros dependen del algoritmo utilizado. Algunos ejemplos son:

- número máximo de niveles de un árbol de decisión;
- número de árboles en Random Forest;
- número de vecinos k en K-Nearest Neighbors;
- parámetros de regularización en Ridge o Lasso;
- learning rate, batch size y número de épocas en redes neuronales;
- número de capas, neuronas, filtros o tamaño de los kernels en deep learning.



La selección de hiperparámetros debe realizarse utilizando el conjunto de validación o mediante cross-validation, y no con el conjunto de prueba. Algunas estrategias comunes son Grid Search, Random Search y métodos de optimización Bayesiana. El objetivo no es necesariamente encontrar la configuración que produzca el menor error de entrenamiento, sino aquella que presente el mejor desempeño sobre datos no utilizados para ajustar los parámetros del modelo.

1.2.2 Evaluación de la precisión del modelo (Assessing Model Accuracy)

Una vez entrenado un modelo de machine learning, es necesario determinar qué tan bien reproduce los datos observados y qué tan confiables son sus predicciones. Este proceso se conoce como Assessing Model Accuracy y consiste en utilizar métricas cuantitativas para comparar los valores predichos por el modelo con los valores reales.

En problemas de regresión, donde la variable objetivo es continua (por ejemplo, porosidad, permeabilidad, saturación de agua, presión o producción), la evaluación se basa principalmente en los residuales o errores de predicción:

$$e_i = y_i - \hat{y}_i$$

donde y_i representa el valor observado y $\hat{y}_i$ el valor estimado. Un modelo adecuado debería producir errores relativamente pequeños y sin patrones sistemáticos. Una función de pérdida (loss function) cuantifica qué tan diferentes son las predicciones generadas por un modelo respecto a los valores reales. Durante el entrenamiento, el algoritmo busca modificar sus parámetros para minimizar esta función, por lo que la elección de la función de pérdida influye directamente en qué tipo de errores aprende a evitar el modelo. Funciones de pérdida utilizadas en el entrenamiento de modelos de machine learning:

- **Mean Absolute Error (MAE)**

El MAE representa el promedio del valor absoluto de los errores:

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

Es fácil de interpretar porque conserva las mismas unidades de la variable objetivo. Además, es menos sensible a errores extremos que el MSE.

- **Mean Squared Error (MSE)**

El MSE proporciona mayor penalización a predicciones con errores grandes debido al término cuadrático. Es ampliamente utilizado tanto como métrica de evaluación como función de pérdida durante el entrenamiento de modelos de regresión.

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

Una desventaja es que sus unidades corresponden al cuadrado de las unidades originales, lo que puede dificultar su interpretación física.

- **Root Mean Squared Error (RMSE)**

El RMSE corresponde a la raíz cuadrada del MSE:

$$RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$$

Su principal ventaja es que recupera las unidades originales de la variable objetivo, facilitando la interpretación. Al igual que el MSE, penaliza considerablemente los errores grandes.

COMPARACIÓN DE LAS PRINCIPALES MÉTRICAS DE EVALUACIÓN

Regresión (variable objetivo continua)

MÉTRICA	FÓRMULA	INTERPRETACIÓN	MEJOR VALOR	UNIDADES	CARACTERÍSTICAS PRINCIPALES	SENSIBILIDAD A OUTLIERS	RANGO TÍPICO
 MAE (Mean Absolute Error)	$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Promedio de la magnitud absoluta de los errores. Mide, en promedio, cuánto se desvían las predicciones de los valores reales.	0 (más cercano a 0, mejor)	Las mismas unidades de la variable objetivo (ej. mD, psi, %)	- Fácil de interpretar - Menos penalización a errores grandes - Robusta y estable	 Baja	$[0, \infty)$ Valores más cercanos a 0 son mejores
 MSE (Mean Squared Error)	$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Promedio de los errores al cuadrado. Penaliza fuertemente los errores grandes.	0 (más cercano a 0, mejor)	Cuadrado de las unidades de la variable objetivo (ej. mD ² , psi ²)	- Muy utilizada como función de pérdida - Penaliza fuertemente errores grandes	 Alta	$[0, \infty)$ Valores más cercanos a 0 son mejores
 RMSE (Root Mean Squared Error)	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Raíz cuadrada del MSE. Conserva las unidades originales y penaliza errores grandes.	0 (más cercano a 0, mejor)	Las mismas unidades de la variable objetivo (ej. mD, psi, %)	- Fácil de interpretar - Penaliza fuertemente errores grandes - Muy usada en geociencias	 Alta	$[0, \infty)$ Valores más cercanos a 0 son mejores
 R² (Coeficiente de Determinación)	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$	Proporción de la variabilidad de los datos explicada por el modelo. Compara el modelo con usar la media como predicción.	1 (más cercano a 1, mejor)	Adimensional (sin unidades)	- Mide ajuste global - Puede ser negativo si el modelo es peor que usar la media	 Media	$(-\infty, 1]$ Ideal cercano a 1; puede ser negativo
 MAPE (Mean Absolute Percentage Error)	$MAPE = \frac{100}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $	Error absoluto promedio expresado en porcentaje respecto al valor real.	0 % (más cercano a 0 %, mejor)	Porcentaje (%)	- Intuitivo y fácil de comunicar - Útil para comparar entre diferentes escalas	 Alta (problemas si y _i es cercano a 0)	$[0, \infty) \%$ Valores más cercanos a 0 % son mejores



NOTA IMPORTANTE: Ninguna métrica debe interpretarse de forma aislada. Es recomendable analizar varias métricas en conjunto y complementarlas con gráficos (observado vs. predicho, residuales) y validación en datos no vistos.

1.2.3 Underfitting

El underfitting ocurre cuando el modelo es demasiado simple para representar adecuadamente las relaciones presentes en los datos. En esta situación, el modelo presenta un desempeño deficiente tanto en los datos de entrenamiento como en los de validación.

Por ejemplo, intentar representar mediante una regresión lineal una relación fuertemente no lineal puede producir underfitting. El modelo no posee suficiente flexibilidad para capturar la estructura de los datos.

Generalmente se observa:

Error de entrenamiento alto + error de validación alto

Este comportamiento se asocia con alto sesgo (high bias). Algunas alternativas para reducirlo incluyen aumentar la complejidad del modelo, incorporar variables relevantes, utilizar transformaciones de las variables, reducir una regularización excesiva o utilizar algoritmos capaces de representar relaciones más complejas.

1.2.4 Overfitting

El overfitting ocurre cuando el modelo aprende excesivamente las particularidades de los datos de entrenamiento, incluyendo ruido, anomalías y patrones que no son representativos del fenómeno general.

En este caso, el modelo puede presentar un error extremadamente bajo durante el entrenamiento, pero un error considerablemente mayor cuando se aplica a los datos de validación o prueba:

Error de entrenamiento muy bajo + error de validación significativamente mayor

El modelo presenta entonces alta varianza (high variance) y una capacidad limitada para generalizar.

El overfitting puede ser particularmente importante cuando se utilizan modelos muy complejos con conjuntos de datos relativamente pequeños. Algunas estrategias para reducirlo incluyen regularización, reducción de la complejidad del modelo, selección de variables, early stopping, dropout en redes neuronales, incorporación de más datos y validación cruzada.

1.2.5 Curvas de entrenamiento y validación

Una herramienta particularmente útil consiste en representar gráficamente la evolución del training loss y validation loss durante el entrenamiento.

En un entrenamiento adecuado, ambas pérdidas (loss functions) deberían disminuir inicialmente y eventualmente estabilizarse en valores relativamente bajos. No es necesario que sean idénticas; normalmente existe una pequeña diferencia entre ambas.

Una señal clásica de overfitting ocurre cuando:

$$Loss_{train} \downarrow \text{ mientras que } Loss_{validation} \uparrow$$

Es decir, el modelo continúa mejorando sobre los datos de entrenamiento mientras comienza a empeorar sobre datos independientes.

En redes neuronales, este comportamiento permite utilizar early stopping; el entrenamiento se detiene cuando la pérdida de validación deja de mejorar durante determinado número de épocas.

